

Resumen de gráficos del TP1 · Regresión

Qué muestra cada figura del notebook **TP-regresion-AA1.ipynb** y cómo interpretarla

El notebook tiene **19 figuras numeradas** (31 gráficos en total, porque la Figura 12 son 13 gráficos). En este resumen están agrupadas las que se miran juntas. Los gráficos son los reales del notebook (rama *main*, commit 5ad1ae5) y las interpretaciones salen del texto del propio notebook. Cada grupo tiene: **qué muestra, cómo leerlo, qué significa** y una frase para la defensa.

Figura	Qué es	Idea clave
Fig. 1	Histogramas de las variables continuas	Casi todas son asimétricas: la media se aleja de la mediana.
Fig. 2	Conteo de CHAS y RAD	CHAS está muy desbalanceada (480 contra 45); RAD se concentra en 4, 5 y 24.
Fig. 3	Boxplots con el IQR	CRIM, ZN y B tienen muchísimos puntos fuera de los bigotes.
Fig. 4 y 5	Correlación de Pearson y de Spearman	LSTAT (-0.80) y RM (0.58) son las más ligadas al precio; RAD y TAX se repiten.
Fig. 6 a 8	Coherencia de outliers (CRIM, ZN, B)	La mayoría de los outliers son coherentes y se conservan; pocos son sospechosos.
Fig. 9	Efecto del escalado (RobustScaler)	Todas las variables quedan en escalas comparables; los outliers siguen ahí.
Fig. 10 y 11	Método del codo y curvatura (KNN)	Se elige $k = 2$ por mayor curvatura; el mínimo exacto está en $k = 5$.
Fig. 12.1 a 12.13	Distribuciones antes y después de imputar	Las distribuciones casi no cambian al imputar.
Fig. 13	Convergencia de las tres variantes de GD	Las tres llegan al mismo MSE (≈ 32.7) con distinto número de épocas.
Fig. 14 a 16	Curvas de error del material de clase	Batch suave, estocástico ruidoso, mini-batch en el medio.
Fig. 17 y 18	Tasa de aprendizaje y tamaño de lote	Lr demasiado grande diverge; el lote intermedio equilibra velocidad y ruido.
Fig. 19	Ridge y Lasso según alpha	El error de test nunca baja al regularizar: no hay sobreajuste.

Parte 1 · Exploración de los datos (EDA)

Figura 1 Histogramas de las variables continuas




Figura 1. Distribución de las variables numéricas continuas (histogramas con media y mediana).

Figura 1. Distribución de las variables numéricas continuas (histogramas con media y mediana).

Qué muestra. La distribución de cada variable continua (12 paneles, incluido el precio **MEDV**). Las barras cuentan viviendas por rango, la curva azul es una estimación suave de la forma, la línea roja punteada es la **media** y la verde es la **mediana**.

Cómo leerlo. Fíjate si media y mediana coinciden. Si están juntas, la variable es simétrica. Si se separan, hay una cola larga que arrastra a la media hacia los valores extremos.

Qué significa. Casi todas las variables son asimétricas:

- **CRIM**: media 4.99 contra mediana 0.29 (asimetría 4.14). Unos pocos barrios muy peligrosos arrastran el promedio.
- **ZN**: mediana 0; la mayoría de los barrios vale cero (la primera barra es enorme).
- **INDUS** y **RM**: casi simétricas. **NOX**: rango muy chico (0.38 a 0.87), de otra escala que el resto.
- **AGE** y **PTRATIO**: cola hacia valores bajos. **DIS**, **LSTAT** y **MEDV**: cola hacia valores altos; MEDV tiene un pico en 50 que parece un techo del dataset.
- **TAX**: dos grupos (bimodal), uno entre 666 y 711; correlaciona 0.90 con RAD. **B**: cola fuerte hacia valores bajos (asimetría -2.57).

Conclusión: por la asimetría, el grupo usa herramientas robustas a los extremos: IQR para los outliers, Spearman para la correlación y RobustScaler para escalar.

Para la defensa: “Las variables son asimétricas (media $\neq$ mediana), no podemos suponer normalidad. Por eso usamos IQR, Spearman y RobustScaler, que no se dejan arrastrar por los extremos.”

Figura 2 Conteo de las variables categóricas CHAS y RAD




Figura 2. Distribución de las variables categóricas CHAS y RAD.

Figura 2. Distribución de las variables categóricas CHAS y RAD.

Qué muestra. Cuántas viviendas hay en cada valor de las dos categóricas: **CHAS** (¿limita con el río? 0 = no, 1 = sí) y **RAD** (índice de acceso a autopistas).

Cómo leerlo. Barras altas son categorías frecuentes. Una barra enorme al lado de una mínima indica desbalance.

Qué significa. **CHAS** está muy desbalanceada: 480 viviendas no limitan con el río y 45 sí (91 % de ceros). **RAD** se concentra en 4 (110 viviendas), 5 (116) y 24 (132), y el 24 queda separado del resto del índice. Promediar cualquiera de las dos con KNN daría valores que no existen (0.3 en CHAS o 10.5 en RAD), por eso se imputan con **CatBoostClassifier**. En la regresión, RAD se deja numérica (es un índice ordinal) para no sumar ocho columnas con pocas filas cada una.

Para la defensa: “CHAS y RAD son categóricas: no se promedian con KNN porque daría un 0.3 o un 10.5 que no existen. Se imputan con un clasificador que solo predice categorías válidas.”

Figura 3 Boxplots de las variables continuas




Figura 3. Boxplots de las variables numéricas continuas para detección de outliers.

Qué muestra. Un boxplot por variable continua (12), con el **IQR** en el título. La caja va del cuartil 1 al 3 (el 50 % central de los datos), la línea roja es la mediana, los bigotes llegan hasta 1.5 veces el IQR y cada punto fuera es un **outlier según IQR**.

Cómo leerlo. Una caja chica con muchos puntos hacia un lado (CRIM) indica que casi todos los datos se parecen y unos pocos son enormes. Una caja ancha sin puntos (TAX, AGE) indica datos repartidos sin extremos.

Qué significa. CRIM, ZN y B tienen muchísimos puntos fuera de los bigotes (CRIM y ZN hacia arriba, B hacia abajo). RM, DIS, LSTAT y MEDV tienen unos pocos. Se usa IQR y no z-score porque los tests de Shapiro-Wilk y D'Agostino-Pearson rechazan la normalidad. Que IQR marque un punto **no significa que sea un error**: en variables asimétricas la cola larga es natural. Por eso el notebook sigue con el análisis de coherencia (Figuras 6 a 8).

Para la defensa: "Usamos IQR porque las variables no son normales. Un outlier por IQR no es necesariamente un error: lo contrastamos con las otras variables antes de decidir qué hacer."

Figuras 4 y 5 Matrices de correlación: Pearson y Spearman




Figura 4. Matriz de correlación de Pearson entre las variables del dataset.

Figura 4. Matriz de correlación de Pearson entre las variables del dataset.




Figura 5. Matriz de correlación de Spearman entre las variables del dataset.

Figura 5. Matriz de correlación de Spearman entre las variables del dataset.

Qué muestra. La correlación entre cada par de las 14 variables (13 predictoras y MEDV), de -1 a 1 .

Rojo: suben juntas. **Azul:** cuando una sube, la otra baja. **Blanco:** sin relación. La Figura 4 usa **Pearson** (relación lineal) y la Figura 5 usa **Spearman** (relación entre posiciones o rankings).

Cómo leerlo. Mirá la fila de MEDV para ver qué variables se relacionan con el precio. Fuera de esa fila, las celdas muy rojas o muy azules entre predictoras indican información repetida (**multicolinealidad**).

Qué significa.

- Con el precio, la relación más fuerte es **LSTAT** (-0.80): más población de bajo estatus, menor precio. Le sigue **RM** (0.58). AGE, TAX, INDUS, PTRATIO, CRIM y NOX rondan -0.5 .
- **RAD-TAX:** 0.90 con Pearson y 0.70 con Spearman. Es multicolinealidad real: las zonas más urbanizadas tienen impuestos más altos y mejor acceso a autopistas.
- **CRIM** parece aislada con Pearson ($\text{CRIM-ZN} = 0.01$), pero con Spearman aparece conectada ($\text{CRIM-NOX} = 0.80$, $\text{CRIM-TAX} = 0.72$): unos pocos barrios extremos distorsionan el coeficiente lineal.

Conclusión: el grupo toma Spearman como referencia, porque trabaja con rankings y no lo distorsionan los outliers ni las asimetrías. Sus signos se usan después como “relaciones esperadas” para chequear la coherencia de los outliers. La repetición entre RAD y TAX es una posible explicación de por qué Lasso termina anulando RAD.

Para la defensa: “Dos variables muy correlacionadas (RAD y TAX) aportan información repetida. Tomamos Spearman como referencia porque no lo distorsionan los outliers.”

Parte 2 · Outliers

Figuras 6, 7 y 8 Coherencia de los outliers de CRIM, ZN y B




Figura 6. Coherencia de outliers de CRIM respecto a MEDV.

Figura 6. Coherencia de outliers de CRIM respecto a MEDV.




Figura 7. Coherencia de outliers de ZN respecto a MEDV.

Figura 7. Coherencia de outliers de ZN respecto a MEDV.




Figura 8. Coherencia de outliers de B respecto a MEDV.

Figura 8. Coherencia de outliers de B respecto a MEDV.

Qué muestra. Cada una de las tres variables (CRIM, ZN y B) contra el precio MEDV. **Gris:** datos normales. **Naranja:** outliers según IQR que son coherentes con el resto de la fila (se conservan). **Rojo:** outliers incoherentes (candidatos a revisión).

Cómo se decide. Cada outlier se compara con las relaciones que predice la matriz de correlación. Para CRIM: un valor alto debería venir con MEDV bajo, RM bajo y LSTAT alto. Para ZN: MEDV alto, INDUS bajo y LSTAT bajo. Para B (sus outliers son valores bajos): MEDV bajo y LSTAT alto. Si la fila rompe la mayoría de las relaciones que se pueden evaluar (umbral 0.5), es incoherente. Los NaN no se evalúan.

Cómo leerlo. Los puntos naranjas siguen la tendencia esperada (por ejemplo, CRIM alto con MEDV bajo). Los rojos la rompen: por ejemplo, un barrio con CRIM cercano a 39 y MEDV cercano a 49, algo que no encaja con una relación negativa.

Qué significa. La mayoría de los outliers son **coherentes** (naranja): son la cola natural de una distribución asimétrica y se conservan. Los rojos son sospechosos. Después se cruzan las tres variables (**triangulación**): las filas incoherentes en más de una variable son **14, 23, 264, 298, 316, 458, 520 y 554**. De esas, siete caen en train y se eliminan (14, 23, 264, 298, 316, 458 y 554); la 520 cae en test y se conserva, porque test no se toca.

Para la defensa: “No borramos todos los outliers: solo los incoherentes en más de una variable, y solo de train. Los coherentes son datos reales extremos, y borrarlos le sacaría al modelo los casos más difíciles.”

Parte 3 · Escalado e imputación

Figura 9 Efecto del escalado con RobustScaler




Figura 9. Efecto del escalado (RobustScaler) sobre las distribuciones de train.

Figura 9. Efecto del escalado (RobustScaler) sobre las distribuciones de train.

Qué muestra. Boxplots de las 11 variables continuas de train **antes** (azul) y **después** (verde) de aplicar RobustScaler.

Cómo leerlo. Compará el eje vertical. A la izquierda va de 0 a 700 y TAX aplasta las cajas de casi todas las demás. A la derecha va de -20 a 20 y todas las cajas quedan centradas en 0 con un tamaño parecido.

Qué significa. RobustScaler resta la mediana y divide por el IQR, así que deja todas las variables en escalas comparables sin que los outliers distorsionen la escala (como pasaría con StandardScaler). **No elimina los outliers:** siguen ahí (CRIM llega a cerca de 19 y B baja hasta cerca de -18), solo que ahora en la misma escala. El escalador se ajusta (fit) solo con train y se aplica (transform) a test.

Para la defensa: “Escalar cambia la escala, no la forma de los datos ni los outliers. Usamos RobustScaler porque conservamos outliers legítimos, y lo ajustamos solo con train para evitar fuga de datos.”

Figuras 10 y 11 Método del codo y curvatura para elegir k del KNNImputer




Figura 10. Método del codo: NRMSE promedio vs. n_neighbors (k) para KNNImputer.




Figura 11. Derivada segunda del NRMSE vs. k: el máximo en valor absoluto marca el codo (mayor cambio de pendiente).

Figura 10 (izquierda): NRMSE promedio contra k. Figura 11 (derecha): derivada segunda del NRMSE contra k.

Qué muestra. Cómo se eligió **k**, la cantidad de vecinos del KNNImputer. Se ocultan a propósito valores conocidos de las 405 filas completas de train, se imputan con distintos k y se mide cuánto se equivoca la imputación (**NRMSE**, menor es mejor). La Figura 10 muestra ese error para cada k. La Figura 11 muestra su derivada segunda, es decir, cuánto cambia la pendiente de la curva.

Cómo leerlo. En la Figura 10 busca dónde la curva deja de bajar de golpe (el codo). En la Figura 11, el pico más alto en valor absoluto marca el mayor cambio de pendiente: ese k es el codo.

Qué significa. La curva **no tiene un codo clásico**: baja hasta $k = 5$ (NRMSE 0.623) y después sube, porque con muchos vecinos se promedian filas poco parecidas. La mayor curvatura está en **$k = 2$** (NRMSE 0.648): el salto grande ocurre de 1 a 2 vecinos, y de 2 a 5 el error baja solo 0.025. El grupo elige $k = 2$ por el criterio de curvatura, sabiendo que $k = 5$ daría un error de imputación algo menor.

Para la defensa: “Elegimos k con un experimento (ocultar valores y medir el error de reconstrucción), no a ojo. $k = 2$ sale de la mayor curvatura; $k = 5$ tendría un error apenas menor.”

Figuras 12.1 a 12.13 Distribuciones antes y después de imputar

Qué muestra. Para cada variable de train, el histograma **antes** de imputar (azul) y **después** (naranja), superpuestos. Las continuas (12.1 a 12.11) se imputaron con **KNNImputer**; CHAS (12.12) y RAD (12.13) con **CatBoostClassifier**, y se muestran como conteo por categoría. Los ejes de las continuas están en la escala de RobustScaler, porque la imputación se hizo sobre datos ya escalados (por eso ZN llega a cerca de 6 y no a 100).

Cómo leerlo. Si las barras naranjas calzan sobre las azules, la imputación no deformó la distribución. La parte naranja que sobresale es lo que agregó el método.

Qué significa. Las distribuciones **casi no cambian**. KNN completa con promedios de vecinos, así que los valores nuevos caen dentro del rango observado de cada variable. En CHAS y RAD, CatBoost solo asigna categorías válidas, y la proporción de 0 y 1 en CHAS se mantiene casi igual (Figura 12.12).

Para la defensa: “Comparamos la distribución antes y después de imputar para verificar que no la distorsionamos: las barras casi se superponen.”

Continuas (KNNImputer)




Fig. 12.1 · CRIM




Fig. 12.2 · ZN




Fig. 12.3 · INDUS




Fig. 12.4 · NOX




Fig. 12.5 · RM




Fig. 12.6 · AGE




Fig. 12.7 · DIS




Fig. 12.8 · TAX




Fig. 12.9 · PTRATIO




Fig. 12.10 · B




Fig. 12.11 · LSTAT

Categorías (CatBoostClassifier)




Fig. 12.12 · CHAS




Fig. 12.13 · RAD

Parte 4 · Descenso del gradiente

Figura 13 Convergencia de las tres variantes (implementación del grupo)




Figura 13. MSE de entrenamiento por época para las tres variantes.

Figura 13. MSE de entrenamiento por época para las tres variantes.

Qué muestra. El **MSE** (error cuadrático medio) de train en cada época para las tres variantes que programó el grupo: Batch (lr 0.1), Estocástico (lr 0.0005) y Mini-batch (lr 0.01, lotes de 64). El eje vertical está en **escala logarítmica**.

Cómo leerlo. Una curva que baja y se aplana indica convergencia. La escala log deja ver el tramo final, donde las diferencias son de décimas. El eje horizontal son épocas: vueltas completas por los datos.

Qué significa. Las tres bajan muy rápido en las primeras épocas y se estabilizan en el mismo nivel ($MSE \approx 32.7$), que es prácticamente el mínimo de LinearRegression. MSE final: Batch 32.6660, Estocástico 32.6859, Mini-batch 32.6715. Batch corta solo a las **461 épocas** por tolerancia; a Estocástico y Mini-batch el grupo les **fijó** 100 y 300 épocas. Por eso las épocas no son comparables: una época equivale a 1 actualización en Batch, 417 en Estocástico y 7 en Mini-batch.

Para la defensa: “Las tres variantes llegan al mismo mínimo. Cambia cuántas actualizaciones hacen por época y qué tasa de aprendizaje toleran.”

Figuras 14, 15 y 16 Curvas de error con las funciones del material de clase




Figura 14. MSE de entrenamiento y de validación por época, descenso del gradiente batch (función del material de clase).

Figura 14. MSE de entrenamiento y de validación por época, descenso del gradiente batch.




Figura 15. MSE de entrenamiento y de prueba por iteración, descenso del gradiente estocástico (función del material de clase).

Figura 15. MSE de entrenamiento y de prueba por iteración, descenso del gradiente estocástico.




Figura 16. MSE de entrenamiento y de prueba por iteración, descenso del gradiente mini-batch (función del material de clase).

Figura 16. MSE de entrenamiento y de prueba por iteración, descenso del gradiente mini-batch.

Qué muestra. Las funciones de descenso del gradiente del material de clase, aplicadas a los datos del TP con sus parámetros originales: 200 épocas, $lr = 0.01$ y lotes de 11. Muestran el error de train (azul) y de test (naranja; en la Figura 14 la función lo llama “validación”, pero es test). En la Figura 14 cada punto es una época; en las Figuras 15 y 16 cada punto es una **actualización**, no una época.

Cómo leerlo. La forma de la curva dice cómo se comporta el algoritmo: suave y decreciente es una convergencia estable; con picos que no se calman es ruido.

Qué significa.

- **Batch (Fig. 14):** baja suave desde unos 550 a 600 hasta cerca de 34 en train y 43 en test, sin ruido. Con $lr = 0.01$ no llega al mínimo en 200 épocas, por eso el grupo usa 0.1 en su versión.
- **Estocástico (Fig. 15):** unas 83.400 actualizaciones (200 épocas $\times$ 417 filas). El error de train se calcula con una sola muestra por vez, así que es ruidoso por construcción (con picos de más de 2000); conviene mirar la curva de test. Oscila sin asentarse: con $lr = 0.01$ necesita una tasa mucho menor (0.0005 en la versión del grupo).
- **Mini-batch (Fig. 16):** 38 lotes de 11 por época, unas 7.600 actualizaciones. Baja rápido y converge; oscila menos que el estocástico y más que el batch.

Conclusión: cuantas más actualizaciones por época, más chica tiene que ser la tasa de aprendizaje.

Para la defensa: “Batch es el más estable pero da un solo paso por época. SGD da muchos pasos pero ruidosos y necesita una tasa chica. Mini-batch es el punto medio.”

Figuras 17 y 18 Hiperparámetros: tasa de aprendizaje y tamaño de lote




Figura 17. MSE de entrenamiento por época según la tasa de aprendizaje (300 épocas como máximo).

Figura 17. MSE de entrenamiento por época según la tasa de aprendizaje (300 épocas como máximo).

Figura 17 · Qué muestra. Batch con cinco tasas de aprendizaje. El límite teórico para que converja es $lr = 0.176$ (2 dividido el autovalor más grande de $2/n \cdot X^T X$). Se prueban tres valores chicos (0.001, 0.01 y 0.1) y dos pegados al límite: 0.167 (95 % del límite) y 0.185 (105 %).

Cómo leerla. Con $lr = 0.001$ el error baja tan lento que a las 300 épocas sigue en MSE 195.56. Con 0.01 llega a 32.93; con 0.1 y 0.167 llega a 32.67 (0.1 en unas 30 épocas). Con 0.185 **diverge**: cada paso se pasa del mínimo y el error explota (la curva violeta sale del gráfico). La mejor tasa es la más grande que todavía converge.




Figura 18. MSE de entrenamiento por época según el tamaño del lote.

Figura 18. MSE de entrenamiento por época según el tamaño del lote.

Figura 18 · Qué muestra. Mini-batch con $lr = 0.01$ y 100 épocas, variando el tamaño de lote: 1 (es el estocástico), 8, 32, 128 y 417 (todo train: es el batch).

Cómo leerla. MSE final de train: 36.93, 32.98, 32.91, 32.82 y 43.37 (lotes 1, 8, 32, 128 y 417). Los lotes chicos actualizan más veces y bajan más rápido por época. El lote de 417 no converge en 100 épocas con $lr = 0.01$. El lote de 1 queda rebotando alrededor del mínimo (curva azul con picos). Los intermedios equilibran ambos extremos, por eso el mini-batch es el más usado. Con lotes más chicos conviene bajar la tasa.

Para la defensa: “La tasa de aprendizaje y el tamaño de lote se eligen con experimentos: una tasa muy chica es lenta, una muy grande diverge, y un lote intermedio equilibra velocidad y ruido.”

Parte 5 · Regularización

Figura 19 Ridge y Lasso: coeficientes y RMSE según alpha




Figura 19. Coeficientes y RMSE de train y test en función de alpha, para Ridge y Lasso.

Figura 19. Coeficientes y RMSE de train y test en función de alpha, para Ridge y Lasso.

Qué muestra. Arriba: los coeficientes de las 13 variables (en escala estandarizada) según **alpha**, para Ridge (izquierda) y Lasso (derecha). Abajo: el RMSE de train y de test según alpha. El eje x está en escala logarítmica. La línea punteada es el alpha elegido por validación cruzada (Ridge 67.48, Lasso 0.111).

Cómo leerlo. A la izquierda hay casi nada de castigo (equivale a LinearRegression); a la derecha, castigo fuerte. Arriba, cada línea es una variable. Abajo, buscá si el error de test baja en algún punto: esa “U” sería la señal de un sobreajuste corregido.

Qué significa.

- **Ridge** achica todos los coeficientes sin llevar ninguno a cero. **Lasso** los lleva a cero exacto de a uno, hasta que el modelo solo predice el promedio; RM y LSTAT son las que más aguantan.
- El error de train sube siempre con alpha y el de test **nunca baja**: no aparece la U del sobreajuste. Sin varianza de sobra, regularizar solo suma sesgo.
- El alpha de la validación cruzada cae al final de la zona plana y se aleja de la regresión lineal en menos de una décima de RMSE: optimizarlo casi no cambia el resultado.

Conclusión: ningún modelo regularizado mejora a LinearRegression en test (RMSE 6.4267 contra 6.4774 de ElasticNet, 6.4793 de Lasso y 6.5089 de Ridge).

Para la defensa: “Regularizamos y no mejoró: el modelo no sobreajusta, así que el castigo solo agrega sesgo. Nos quedamos con LinearRegression.”

Glosario rápido de lo que aparece en los gráficos

Término	Qué significa
Media y mediana	La media es el promedio; la mediana es el valor del medio. Si se separan, la variable tiene una cola larga.
Asimetría (skew)	0 es simétrica; positivo es cola a la derecha; negativo es cola a la izquierda.
Cuartiles e IQR	Q1 y Q3 dejan el 25 % y el 75 % de los datos por debajo. $IQR = Q3 - Q1$ es el ancho de la caja. Un punto es outlier si está a más de $1.5 \times IQR$ de la caja.
Pearson y Spearman	Pearson mide relación lineal y se distorsiona con extremos. Spearman compara posiciones (rankings) y es más robusto.
Multicolinealidad	Dos o más predictoras que cuentan casi lo mismo (como RAD y TAX).
fit y transform	fit aprende los parámetros (mediana e IQR, o los vecinos) y solo se hace con train. transform los aplica a train y a test. fit_transform hace las dos cosas juntas, y se usa solo sobre train.
NRMSE	Error relativo de la imputación: cuánto se equivoca al reconstruir valores que se ocultaron a propósito. Menor es mejor.
MSE y RMSE	MSE es el error cuadrático medio. RMSE es su raíz cuadrada y queda en las unidades del precio (miles de dólares).
Época e iteración	Una época es una vuelta completa por los datos de train. Una iteración (o actualización) es un paso del gradiente: Batch hace 1 por época, Estocástico 417 y Mini-batch (lotes de 64) 7.
lr (tasa de aprendizaje)	El tamaño de cada paso del gradiente. Muy chica es lenta; muy grande diverge.
alpha	La intensidad del castigo en Ridge, Lasso y ElasticNet. Su escala no es comparable entre Ridge y Lasso.
Escala logarítmica	Cada marca del eje multiplica por 10 en vez de sumar. Permite ver valores muy distintos en un mismo gráfico.