

# Capítulo 0: Fundamentos previos para Aprendizaje Automático 1

February 2025

# Contents

|          |                                                                             |           |
|----------|-----------------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Introducción</b>                                                         | <b>4</b>  |
| 1.1      | Tipos de variables . . . . .                                                | 4         |
| 1.2      | Importancia en la preparación de datos . . . . .                            | 5         |
| 1.3      | Herramientas recomendadas . . . . .                                         | 5         |
| <b>2</b> | <b>Visualización de datos</b>                                               | <b>6</b>  |
| 2.1      | Histograma . . . . .                                                        | 6         |
| 2.2      | Diagrama de caja -boxplot- . . . . .                                        | 6         |
| 2.3      | Gráficos de violines . . . . .                                              | 7         |
| 2.4      | Diagramas de dispersión -scatterplots- . . . . .                            | 8         |
| 2.5      | Matriz de correlación . . . . .                                             | 8         |
| 2.6      | Gráficos de distribución conjunta . . . . .                                 | 10        |
| <b>3</b> | <b>Valores faltantes</b>                                                    | <b>10</b> |
| 3.1      | Tipos de valores faltantes . . . . .                                        | 11        |
| 3.2      | Estrategias de imputación . . . . .                                         | 12        |
| 3.2.1    | Investigar la causa . . . . .                                               | 12        |
| 3.2.2    | Imputación simple . . . . .                                                 | 12        |
| 3.2.3    | Imputación basada en algoritmos de aprendizaje . . . . .                    | 13        |
| 3.2.4    | Imputación basada en criterios u observaciones . . . . .                    | 13        |
| 3.2.5    | Eliminación . . . . .                                                       | 14        |
| <b>4</b> | <b>Outliers -valores atípicos-</b>                                          | <b>14</b> |
| 4.1      | Tipos de outliers . . . . .                                                 | 14        |
| 4.2      | Métodos de detección de outliers . . . . .                                  | 15        |
| 4.3      | Tratamiento . . . . .                                                       | 15        |
| <b>5</b> | <b>Feature Engineering -ingeniería de características-</b>                  | <b>16</b> |
| 5.1      | Variables numéricas . . . . .                                               | 16        |
| 5.1.1    | Escalado de datos . . . . .                                                 | 16        |
| 5.2      | Otras transformaciones numéricas . . . . .                                  | 18        |
| 5.2.1    | Transformación logarítmica . . . . .                                        | 18        |
| 5.2.2    | Transformación raíz cuadrada . . . . .                                      | 19        |
| 5.2.3    | Transformación Box-Cox . . . . .                                            | 19        |
| 5.2.4    | Transformación Yeo-Johnson . . . . .                                        | 19        |
| 5.2.5    | Transformaciones manuales . . . . .                                         | 19        |
| 5.3      | Variables categóricas . . . . .                                             | 19        |
| 5.3.1    | Limpieza . . . . .                                                          | 19        |
| 5.3.2    | Valores no vistos anteriormente . . . . .                                   | 20        |
| 5.3.3    | Codificación dummy -Dummy encoding y One Hot En-<br>coding (OHE)- . . . . . | 20        |
| 5.3.4    | Codificación por etiquetas -Label encoding- . . . . .                       | 21        |
| 5.3.5    | Codificación ordinal -Ordinal encoding- . . . . .                           | 21        |
| 5.3.6    | Codificación binaria -binary encoding- . . . . .                            | 22        |

|        |                                                    |    |
|--------|----------------------------------------------------|----|
| 5.3.7  | Codificación por frecuencia -frequency encoding-   | 23 |
| 5.3.8  | Codificación por variable target -target encoding- | 23 |
| 5.3.9  | Codificación cíclica -circular encoding-           | 24 |
| 5.3.10 | Otras codificaciones.                              | 25 |
| 5.4    | Tratamiento de variables correlacionadas           | 25 |

# 1 Introducción

El aprendizaje automático es una disciplina que permite a los sistemas aprender patrones a partir de datos para realizar predicciones o clasificaciones. En este curso, nos enfocaremos en el modelado y evaluación de algoritmos de aprendizaje automático, sin profundizar en las etapas de preprocesamiento de datos.

Este capítulo tiene como objetivo establecer un marco de referencia sobre los conocimientos previos necesarios para seguir el curso con fluidez. No se explicarán en profundidad, pero se proporcionarán referencias y una breve descripción de cada concepto.

## 1.1 Tipos de variables

En un conjunto de datos, cada una de las variables puede, por lo general, encajar dentro de la siguiente clasificación:

- **Variables numéricas:** aquellas donde hay un rango continuo de valores numéricos. También llamadas variables *cuantitativas*. Por ejemplo, edades, pesos, distancias, temperaturas, precios, puntajes, etc. En algunos casos, de rangos conocidos o acotados (por ejemplo, una edad no puede ser negativa, y en el caso de un ser humano, se puede pensar una edad mayor a cien años como un valor atípico, o una temperatura, que sí puede ser negativa, salvo que la ubicación sea el caribe). Hay casos especiales, como datos geoespaciales, que tienen transformaciones particulares.
- **Variables categóricas:** aquellas que toman valores no numéricos, llamadas también *cualitativas*. Por ejemplo, ciudades, calles, países, géneros, patentes, etc. Es de destacar que pueden ser números (por ejemplo, códigos postales) pero esto no quiere decir que sean variables numéricas: el código postal de Rosario es 2000, el de Pinamar es 7167 y que uno sea más grande que el otro, más chico o múltiplo no tiene ninguna implicancia, simplemente son valores distintos. Las hay también donde todos los valores de la variables son conocidos (por ejemplo, los días de la semana), así como también las que pueden tomar valores "nunca antes vistos", como por ejemplo, si en un conjunto de datos sólo se tienen los colores "azul" y "rojo", y en el conjunto de prueba se encuentra el color "amarillo". Cuando una variable categórica solo puede tomar dos valores, también se la puede pensar como "valor" y "no valor" (es análogo si sólo puede tomar tres valores: "valor 1", "valor 2" y "valor que no es ni el 1 ni el 2"). Entender qué propiedades tiene la variable tendrá mucha importancia a la hora de efectuar preprocesamientos correspondientes.
- **Variables de fecha:** aquellas dentro del format "yyyy-mm-dd hh:mm:ss.fff" (y puede incluir *timezone*). En algunos casos, los datos vienen acompañados de un *timestamp* en el que fueron procesados, del cual se puede extraer mucha información: año, mes, estación, día de la semana, hora, minuto, cantidad de segundos entre una muestra y otra, etc. Según el caso, pueden

ser numéricas o categóricas (por ejemplo, el mes, por más que pueda representarse como un número, es una variable categórica). El mes, el día de la semana o el día en el año son ejemplos de variables cíclicas, es decir, son periódicas, y esto puede tener luego alguna implicancia en el preprocesamiento de datos.

## 1.2 Importancia en la preparación de datos

En este capítulo introductorio se verán algunas técnicas para realizar un preprocesamiento de datos. No sólo porque sea necesario (por ejemplo, si el algoritmo de aprendizaje requiere calcular la media de la variable y la misma toma valores nulos o de texto eventualmente, arrojará error), sino porque el proceso de entrenamiento de un algoritmo es costoso y no necesariamente tan inteligente como se cree, y se pueden aprovechar los conocimientos, técnicas y estrategias disponibles para realizar una buena preparación de datos que pueda mejorar significativamente el rendimiento de los algoritmos y evitar sesgos o errores en los resultados y en su interpretabilidad. Sin una adecuada preparación, incluso los modelos más avanzados pueden generar resultados inexactos y/o poco confiables.

Las principales tareas dentro de la preparación de datos incluyen:

- Identificación y tratamiento de valores faltantes.
- Detección y manejo de valores atípicos (outliers).
- Normalización y estandarización de datos.
- Codificación de variables categóricas.
- Selección y creación de características relevantes.

## 1.3 Herramientas recomendadas

Si bien existen de naturaleza variada, en este curso utilizaremos las siguientes bibliotecas para realizar el preprocesamiento de datos:

- Pandas: permite el manejo eficiente de datos tabulares, con funciones para limpiar, transformar y analizar información estructurada.
- NumPy: permite hacer operaciones matemáticas y manejar eficientemente matrices y arrays numéricos.
- Matplotlib: permite la creación de gráficos básicos y avanzados, útil para exploración de datos.
- Seaborn: basada en Matplotlib, proporciona visualizaciones más estilizadas y análisis estadísticos.
- Plotly: permite realizar gráficos interactivos para análisis exploratorio avanzado.

- **Scikit learn:** proporciona herramientas para normalización, estandarización, imputación de valores faltantes y selección de características. Además, luego, también se utilizará para entrenar, validar y testear algoritmos de aprendizaje.

Más adelante, se incorporarán más bibliotecas para interpretabilidad de resultados, redes neuronales, entre otros.

## 2 Visualización de datos

### 2.1 Histograma

El histograma es uno de los métodos gráficos más antiguos para presentar información univariada. Los datos se agrupan en clases o intervalos que se señalan en el eje horizontal, mientras que en el vertical se coloca alguna medida indicativa de la cantidad de observaciones en cada intervalo. Si se grafica la frecuencia absoluta o relativa, todos los intervalos deben tener la misma amplitud para que la representación sea válida. En caso contrario, se debe graficar la densidad (frecuencia relativa de una clase sobre su amplitud).

No olvidar que un histograma **no es un gráfico de barras**. Es una estimación de la función de densidad de la variable.

La descripción de la distribución lograda depende de la amplitud elegida para los intervalos. Si la amplitud es muy pequeña, el histograma presentará muchos picos y se oscurecerá la visualización de la forma general de la distribución. Por el contrario, si la amplitud es muy grande, pueden perderse algunas características de la misma.




Figure 1: Histograma de distintas variables explicativas en dataset de vinos.

### 2.2 Diagrama de caja -boxplot-

El boxplot es una de las herramientas más populares para representar la distribución de una variable cuantitativa, principalmente porque permite comparar grupos con facilidad.

Los elementos que componen a un boxplot son:

- Caja: se extiende desde el cuartil inferior o  $Q1$  (cuantil 0.25) hasta el cuartil superior o  $Q3$  (cuantil 0.75). Su longitud es el rango intercuartil y representa el recorrido del 50 por ciento central de los valores.
- Mediana: representada con una línea en el interior de la caja.
- Bigotes: se extienden desde la caja hasta el valor mínimo y máximo observado. Opcionalmente, se extienden hasta el valor adyacente inferior (menor observación mayor o igual que  $Q1 - 1.5RI$ ) y el valor adyacente superior (mayor observación menor o igual que  $Q3 + 1.5RI$ ).
- Valores externos: observaciones más allá de los valores adyacentes. Se grafican en forma individual. Pueden no existir, cuando los valores adyacentes coinciden con el mínimo o el máximo.

Las distancias de los cuartiles a la mediana dan información acerca de la forma de la distribución.

- Si una distancia es mayor a la otra, la distribución es asimétrica.
- Si existen outliers (observaciones muy grandes o muy pequeñas), aparecen como valores externos.




Figure 2: Boxplots de diferentes características del dataset de vinos.

## 2.3 Gráficos de violines

Los gráficos de violines persiguen el mismo objetivo que los boxplots, pero mostrando en lugar de cajas, curvas de densidad.

En estos gráficos, las curvas de densidad se rotan 90 grados y se dibujan en espejo (la misma curva enfrentada). El aspecto resultante le da el nombre de violín al gráfico.

Comienzan y terminan en el mínimo y máximo valor observado, respectivamente. Los violines pueden mostrar más matices de las distribuciones.

Su uso se justifica si se tiene una suficiente cantidad de datos como para que la estimación de la densidad sea precisa.




Figure 3: Violinplots de distintas variables explicativas en dataset de vinos.

## 2.4 Diagramas de dispersión -scatterplots-

El diagrama de dispersión suele emplearse como primera herramienta exploratoria cuando se desea estudiar la relación entre dos variables cuantitativas.

## 2.5 Matriz de correlación

Se llama correlación a la medida estadística que evalúa la relación entre dos o más variables numéricas. A mayor correlación, más "similar" es la información que brindan los predictores.

La matriz de correlación es una herramienta estadística que muestra la relación entre las distintas variables de un conjunto de datos. Cada celda de la matriz de correlación contiene un valor numérico que representa el grado de correlación entre dos variables. Este valor oscila entre -1 y 1. Recordar que la correlación no implica **causalidad**. Los más conocidos son la correlación de Pearson, correlación de Spearman y correlación de Kendall (pero hay muchos más).

La **correlación de Pearson** mide la relación lineal entre dos variables continuas. Su valor varía entre  $[-1, 1]$ , donde:

- $r = 1$ : Correlación positiva perfecta (ambas variables aumentan juntas).
- $r = -1$ : Correlación negativa perfecta (una variable aumenta mientras la otra disminuye).
- $r = 0$ : No existe correlación **lineal**.

Es adecuada para datos que siguen una distribución normal y tienen una relación lineal. La fórmula es la siguiente:

$$r = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum (X_i - \bar{X})^2 \sum (Y_i - \bar{Y})^2}}$$

donde  $X_i$  y  $Y_i$  son los valores de las variables  $X$  y  $Y$ , respectivamente, y  $\bar{X}$  y  $\bar{Y}$  son sus medias.






Figure 4: Scatterplots de distintas variables explicativas en dataset de vinos.

La **correlación de Spearman** es una medida no paramétrica que evalúa la relación monótona entre dos variables. Es útil cuando las variables no siguen una relación lineal pero sí tienen una relación consistente en términos de aumento o disminución. Su valor también varía entre  $[-1, 1]$ . La fórmula para la correlación de Spearman es:

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$$

donde  $d_i$  es la diferencia entre los rangos de las observaciones  $X_i$  y  $Y_i$ , y  $n$  es el número total de observaciones.

La **correlación de Kendall** también es una medida no paramétrica y más robusta frente a valores atípicos. Se utiliza para evaluar la relación monótona entre dos variables en situaciones donde se desea mayor robustez frente a los

valores atípicos, o cuando las muestras son pequeñas. Su fórmula es la siguiente:

$$\tau = \frac{(C - D)}{\frac{n(n-1)}{2}}$$

donde  $C$  es el número de pares concordantes (pares de observaciones en los que ambas variables siguen la misma tendencia),  $D$  es el número de pares discordantes (pares de observaciones en los que las variables siguen tendencias opuestas), y  $n$  es el número de observaciones.

La elección del tipo de correlación depende de las características de los datos y de los algoritmos a utilizar.




Figure 5: Correlación lineal entre dos variables.

## 2.6 Gráficos de distribución conjunta

## 3 Valores faltantes

Los valores faltantes son datos ausentes en un conjunto de datos, lo que puede afectar la calidad del modelo si no se manejan adecuadamente [2]. Se deben




Figure 6: Matriz de correlación Pearson para las variables explicativas del dataset de vinos.

tomar decisiones: la mayoría de los algoritmos no aceptan que la entrada sea un dato de valor nulo, y aún si pudieran soportar ese tipo de valor, es conveniente realizar un preprocesamiento para obtener resultados estadísticos más acertados.

### 3.1 Tipos de valores faltantes

Los valores faltantes pueden clasificarse en tres categorías principales:

- **MCAR (Missing Completely at Random)**: La ausencia de datos es completamente aleatoria y no depende de otras variables observadas ni no observadas en el conjunto de datos.
- **MAR (Missing at Random)**: La ausencia de datos depende de otras variables observadas pero no del valor de la variable en sí.
- **MNAR (Missing Not at Random)**: La ausencia de datos está relacionada con el valor que falta, lo que introduce un sesgo sistemático en los datos.

Cuando los datos faltantes son MCAR, no contienen ningún tipo de información. Remediar esta situación incluye utilizar métodos que sean lo menos destructivos posibles.

Cuando los datos faltantes son MAR, la información faltante está relacionada con los datos observados, pero no con los datos no observados. Podemos identificar este tipo de datos ausentes analizando su relación con la información que sí tenemos disponible. Por ejemplo, en un estudio de salud, podríamos notar que la presión arterial de los pacientes tiende a faltar con mayor frecuencia en aquellos que tienen edades avanzadas. Esto sugiere que la falta de datos no es completamente aleatoria, sino que está vinculada a una variable observada (la edad). Este tipo de datos ausentes es más común que MCAR y, afortunadamente, existen estrategias eficaces para abordarlo. La mayoría de los métodos de imputación de datos asumen que los valores faltantes son MAR.

Por último, tenemos MNAR. Esto sucede cuando ni MCAR ni MAR se cumplen. En otras palabras, la información faltante está relacionada con datos no observados, lo que dificulta su detección y tratamiento. Un ejemplo sería un cuestionario sobre ingresos personales en el que las personas con ingresos más altos optan por no responder. En este caso, los valores ausentes no son aleatorios ni explicables por los datos observados, sino que dependen de la información que falta. MNAR puede parecer MCAR, por lo que nuestro objetivo principal es determinar si realmente lo es o si hay un patrón oculto detrás de los datos faltantes. Todo esto debería hacerse en la etapa del **análisis exploratorio de datos (EDA)**.

Lógicamente, también podemos tener una combinación de dos o incluso los tres casos. En conjuntos de datos, puede darse que algunas columnas sean MCAR y otras MAR. Tratar correctamente estos valores puede requerir cierto conocimiento en el marco del problema.

## 3.2 Estrategias de imputación

En esta subsección, se discuten posibles soluciones para el tratamiento de datos faltantes. Es de gran importancia observar la distribución de los datos antes y después de realizar la imputación, de forma tal de asegurar no alterar la misma significativamente.

### 3.2.1 Investigar la causa

El método más adecuado probablemente sea el de encontrar cual es la causa de que haya valores faltantes en el conjunto de datos e intentar solucionar ese problema. Por ejemplo, si un script que actualiza la base tiene un error al procesar una variable. Si se resuelve este inconveniente, y si aún se dispone de las fuentes de información, se pueden reponer los valores faltantes. Lógicamente, este método escapa el alcance de esta materia, donde los dataset que se brindarán están offline.

### 3.2.2 Imputación simple

Se refiere al método en el que se selecciona un único valor para cada variable y todos los valores faltantes se reemplazan por ese valor. Lo más común es utilizar

la moda en una variable categórica y la media o la mediana en una variable numérica. Se debe prestar especial atención en la cantidad de faltantes, ya que este método distorsionará las distribuciones de las variables. Se debe observar la distribución antes y después de ejecutar la imputación. Por ejemplo, en una distribución bimodal, la imputación por moda aumentará la frecuencia del valor con más ocurrencias, despreciando el segundo pico. A su vez, las imputaciones por media pueden estar muy influenciadas por valores atípicos.

En el caso de distribuciones multimodales, se puede pensar en técnicas apenas más complejas, como por ejemplo asignarle una probabilidad a cada pico (acorde a la frecuencia vista de los datos de entrenamiento) para rellenar. No deja de ser imputación simple.

Como ventaja, se puede mencionar que es computacionalmente muy rápido y de fácil comprensión, ya que es muy simple. Como desventaja, reduce la varianza de los datos (estamos agregando información de varianza nula), además de que no observa las relaciones entre las distintas características y en la práctica no mejora el rendimiento de un algoritmo de aprendizaje.

Por ejemplo, en un dataset de datos de casas, donde un predictor puede ser el número de habitaciones y otro el número de baños, puede que la media del número de baños sea tres. La imputación por este valor puede resultar extraña si para alguna de las casas a imputar sólo tiene una habitación, ya que es poco probable que una casa tenga una habitación y tres baños. Esto motiva a desarrollar imputaciones más complejas, basadas en algoritmos de aprendizaje.

### 3.2.3 Imputación basada en algoritmos de aprendizaje

Cualquier algoritmo de aprendizaje automático puede usarse para la imputación de valores faltantes, tomando como variable target aquella que tiene faltantes. Por ejemplo, si se observa una relación lineal entre  $x_1$  y  $x_2$ , los faltantes en  $x_2$  pueden modelarse como una regresión lineal basada en los valores de  $x_1$  y viceversa.

El método más adoptado en la práctica probablemente sea el KNN imputer, un algoritmo basado en K Nearest Neighbours (aprendizaje no supervisado), donde las observaciones del dataset intentarán agruparse en clusters y los valores faltantes serán luego rellenados por la predicción del modelo de KNN.

Como ventaja, es probable que se obtengan mejores resultados. Como desventaja, se ejecuta un modelo más complejo y por lo tanto con baja interpretabilidad, por lo que debe asegurarse de que la imputación simple no sea conveniente a la hora de usar estos algoritmos.

### 3.2.4 Imputación basada en criterios u observaciones

Las imputaciones también pueden basarse en algún criterio acorde al contexto del problema. Por ejemplo, si se tiene un dataset que tiene un valor por día de la altura del Río Paraná, ordenado cronológicamente, y se detecta un faltante, podría imputarse con el promedio del dato del día anterior y del día posterior,

generando un continuo en la serie de tiempo. Siempre se le debe encontrar coherencia al método utilizado, porque si el dataset fuese de venta de helados de una heladería en su lugar, es bastante probable de que imputar con el promedio de días contiguos no sea la mejor idea, ya que probablemente se venda más en los fines de semana. En este caso sería más coherente observar como distribuye la variable respecto del día de la semana y en todo caso, imputar un faltante de un sábado con el promedio de ventas del sábado anterior y el sábado siguiente. Otro ejemplo puede ser que, en un dataset de cantidad de lluvia diaria donde las variables sean "fecha", "ciudad", "cantidad de lluvia[mm]", no sea muy útil imputar por un estadístico de forma global puesto que probablemente la cantidad de lluvia en Salta no sea la misma que en Rosario, por lo que primero puede hacerse un agrupamiento por ciudad y luego imputar. Es importante notar que las suposiciones que se hagan, se pueden demostrar con diversas herramientas de visualización de datos, lo cual le agrega valor al proyecto.

En estos ejemplos, observar que la imputación usada es un método **simple** (medias), pero con un criterio más adecuado acorde al contexto.

### 3.2.5 Eliminación

Se debe considerar como de último recurso. Pueden descartarse observaciones con cualquier cantidad de valores faltantes o fijar un umbral (por ejemplo, descartar observaciones que contengan al menos un cuarenta por ciento de valores faltantes, siempre acompañado de una explicación de por qué cuarenta y no cincuenta o treinta).

Descartar observaciones nunca debe superar el cinco por ciento del conjunto de datos, para no tener un desvío estadístico significativo.

## 4 Outliers -valores atípicos-

Con valores atípicos se hace referencia a valores que son distintos al resto. Por lo general, valores extremos (muy chicos o muy grandes), e incluso por lo general se refiere a aquellos que están por debajo del  $Q1 - 1.5RI$  o por encima del  $Q3 + 1.5RI$ , aunque no necesariamente hay que tomar esta definición.

Como se verá más adelante, los valores extremos influirán en el ajuste de los modelos, especialmente en aquellos que sean lineales (modelos basados en árboles son menos afectados). Entonces, merecen la pena una observación.

En primer lugar, el contexto de la variable puede indicar si el valor atípico puede tratarse de un error o no: es probable que una temperatura ambiente de 200°C sea un error de medición pero una cantidad de lluvia de 150 mm en un día, si bien es un valor no habitual, puede ser verdadero.

### 4.1 Tipos de outliers

- Globales: aquellos que se alejan significativamente del resto de los datos, sin importar el contexto. En un conjunto de ingresos anuales entre 20.000 y 100.000 USD, un ingreso de 10 millones es un global outlier.

- **Contextuales:** no son necesariamente extraños por sí solos, pero lo son dado un contexto (como tiempo, ubicación, etc.). Una temperatura de 30°C en verano, puede ser normal. En invierno, es claramente un outlier contextual.
- **Colectivos:** un conjunto de observaciones que, en grupo, representan un patrón anómalo, aunque individualmente los puntos no parezcan extraños. En una red de tráfico, unos pocos paquetes enviados a alta velocidad pueden ser normales, pero una ráfaga continua desde una IP puede indicar un ataque (DoS attack).

## 4.2 Métodos de detección de outliers

- **Basados en estadística:** utilizan medidas como la media, desviación estándar o el rango intercuartílico (IQR). Un ejemplo clásico es marcar como outliers los valores mayores a  $Q3 + 1,5 \times IQR$ . Son útiles para distribuciones univariadas, pero poco efectivos en datos multivariantes o no gaussianos.
- **Basados en distancia:** calculan qué tan alejados están los puntos entre sí. Por ejemplo, usando *K-Nearest Neighbors* o *DBSCAN*, un punto se considera outlier si está lejos de sus vecinos más cercanos.
- **Basados en densidad:** comparan la densidad local de un punto con la de sus vecinos. Un ejemplo es el algoritmo *Local Outlier Factor (LOF)*, que identifica como outliers a los puntos que están en regiones de baja densidad relativa.
- **Basados en modelos:** entrenan un modelo y consideran outliers aquellos puntos que no se ajustan bien. Ejemplos incluyen *Isolation Forest*, que separa datos de forma aleatoria en árboles, y *Autoencoders*, donde un alto error de reconstrucción puede indicar anomalías.

## 4.3 Tratamiento

La decisión sobre cómo tratar los outliers depende del problema específico y del tipo de modelo a entrenar.

En el caso de errores, lo que se recomienda es aplicar un tratamiento al valor. En el caso de valores no habituales, pero reales, los valores pueden tratarse para mejorar la eficiencia del modelo en general pero se debe comprender que se está limitando el dominio de la solución al problema: es probable que si se descartan observaciones de 150 mm de lluvia, entonces luego no se pueda predecir días con esa cantidad de lluvia. Se debe ser muy cuidadoso al tratar los valores atípicos reales.

El tratamiento de los valores atípicos es similar al de valores faltantes, ya que las observaciones se pueden eliminar, imputar por métodos simples o por métodos más complejos. También es común indicarlos, es decir, crear nuevas

variables que sean booleanas y que solo indiquen cuando otra variable presenta valores atípicos (en el ejemplo de la lluvia en un día, esta nueva variable sería "llovió mucho").

Si los valores atípicos se mantienen, se recomienda utilizar siempre técnicas robustas para escalar y/o aplicar transformaciones a los datos.

Si los outliers son el objetivo del modelo (por ejemplo un algoritmo que intente predecir temperaturas extremas), se deben conservar explícitamente.

En todos los casos, se debe considerar como son afectados los algoritmos de aprendizaje ante outliers.

## 5 Feature Engineering -ingeniería de características-

El proceso de transformación y selección de variables es una estrategia utilizada para poder hacer uso de un modelo y mejorar su desempeño.

No es necesario (ni recomendable) realizar todos los procesos de Ingeniería de Características habido y por haber, es necesario reconocer qué preprocesamiento requiere el modelo a utilizar. Por ejemplo, no es posible utilizar variables de texto en una regresión lineal o una red neuronal, pero si es posible hacerlo en un bosque de árboles de decisión. Sin embargo, en el ciclo de vida de un modelo de aprendizaje automático es recomendable utilizar diversas estrategias para poder compararlas entre sí y obtener la que presenta mejores resultados, por lo que es probable que este tipo de codificaciones deba hacerse de todas formas.

### 5.1 Variables numéricas

#### 5.1.1 Escalado de datos

En numerosas oportunidades se encontrará que a los datos numéricos del conjunto de datos es conveniente aplicar una transformación de escalado, ya sea para asegurar la convergencia del algoritmo (y mejorar ampliamente la rapidez de convergencia, como se verá en el caso de Redes Neuronales), por necesidad explícita (existen algoritmos que toman la magnitud de la variable, por ejemplo, KNN calcula distancias euclídeas, o, como se verá en los próximos capítulos, la regularización, que depende de la magnitud de los coeficientes obtenidos para cada variable) o para realizar un correcto análisis de resultados.

Escalado refiere a realizar la siguiente transformación, para cada variable:

$$X_{scaled} = (X - a)/b$$

entre las más conocidas:

**Estandarización** También llamada normalización, consiste en escalar los datos de una columna mediante la sustracción de su media y dividiéndolos por su desvío estándar, de forma similar a como se obtienen los *Z - score* (de allí su nombre). Esta transformación sólo escala los valores de la variable, por lo



| Método               | Ecuación                                           |
|----------------------|----------------------------------------------------|
| Estandarización      | $X_{scaled} = \frac{X-\mu}{\sigma}$                |
| Min-Max Scaling      | $X_{scaled} = \frac{X-X_{min}}{X_{max}-X_{min}}$   |
| Max Abs Scaling      | $X_{scaled} = \frac{X}{ X_{max} }$                 |
| Robust Scaling       | $X_{scaled} = \frac{X-\text{mediana}}{\text{IQR}}$ |
| Escalado Logarítmico | $X_{scaled} = \log(X + c)$                         |

Table 1: Métodos de escalado más habituales.

tanto, no cambia su distribución, por lo que su nombre también puede prestar confusiones.

$$X_{scaled} = \frac{X-\mu}{\sigma}$$

Presenta buena velocidad de cómputo (la media y desvío estándar son operaciones rápidas), y en caso de no tener valores atípicos importantes (recordar que los valores extremos afectan la media y el desvío estándar de forma importante), en líneas generales es el método de escalado más utilizado. Revertir el escalado también es sencillo.

Por otro lado, es muy sensible a variables de muy poca varianza (desvío estándar nulo), aunque este tipo de variables en realidad es conveniente no usarlas. Tampoco es recomendable utilizarla para datos dispersos.

#### Min-Max scaling

$$X_{scaled} = \frac{X-X_{min}}{X_{max}-X_{min}}$$

Los valores de la variable quedarán necesariamente dentro del rango  $[0, 1]$ , con una excepción. Si se escala un conjunto de entrenamiento con el  $X_{min}$  y  $X_{max}$  correspondiente, es posible que en el conjunto de prueba o en la puesta en producción aparezcan datos cuyo valor sea inferior a  $X_{min}$  o superior a  $X_{max}$ . Esto no es necesariamente malo, ya que se trata de valores que están por fuera de la escala utilizada para el entrenamiento, pero sí se puede emplear una variante de este escalado, donde si se da esta situación, se utilizan el 0 como tope mínimo y el 1 como tope máximo.

Presenta similitudes con el escalado estándar: los cálculos son rápidos, revertir el escalado es sencillo pero tampoco es útil para datos constantes (puesto que  $X_{min} = X_{max}$ ) ni para datos dispersos.

#### Max-Abs scaling

$$X_{scaled} = \frac{X}{|X_{max}|}$$

Presenta similitudes con las ventajas y desventajas del escalado previo, con la diferencia de que el rango de la variable ahora será  $[-1, 1]$  (siempre que la variable tome valores de distinto signo).

Sí puede usarse para variables con poca varianza. Aunque este tipo de variables aportan poca información a un algoritmo de aprendizaje.

### Robust scaling

$$X_{scaled} = \frac{X - \text{mediana}}{IQR}$$

En este caso, no se toman la media ni el desvío estándar como en la estandarización sino la mediana y un rango intercuartílico, que son medidas más robustas a valores atípicos. Por lo general no se toma el  $IQR = Q3 - Q1$  sino aquel correspondiente a los cuantiles  $0.1 - 0.9$  o  $0.05 - 0.95$ , aunque de la cantidad de valores atípicos, de sus valores y del contexto del problema.

De todas formas, antes de utilizar este método de escalado, es recomendable hacer un análisis de valores atípicos. El resto de las ventajas y desventajas son similares a los casos anteriores (fácil reversión, y no muy útil para variables donde  $Q1 = Q3$ ). Además ignoran por completo los datos por fuera del  $IQR$ .

## 5.2 Otras transformaciones numéricas

### 5.2.1 Transformación logarítmica

Es una herramienta útil para variables cuya distribución esté muy sesgada. En el histograma de la izquierda de la figura 7, se observa una asimetría importante: gran cantidad de datos poseen un valor bajo. Para poder conocer el impacto que esta variable podría tener, hay que considerar el modelo. En el caso de modelos lineales, donde se supone que existe una relación lineal entre este predictor y la variable respuesta, un aumento en la variable supone un aumento proporcional en la respuesta sin importar cuál sea el valor de la variable, y esto puede tener sentido o no dependiendo del problema, pero también es usual encontrarse con problemas donde a medida que aumente la variable, disminuya la pendiente con la que aumenta la target, reflejando su relación no lineal. Una transformación logarítmica podría crear, en este último caso, esa dependencia lineal.

La transformación

$$y = \log_b(x_i + a) \tag{1}$$

se puede interpretar como que una variación en  $x_i$  resulta en una variación  $b$  veces  $y$ . El parámetro  $b$  suele tomar los valores 2,  $e$  o 10, siendo 2 el más común, y  $a$  es un parámetro que sirve para que este logaritmo pueda ejecutarse, ya que sólo puede aplicarse a reales positivos y presenta pendientes muy abruptas cerca del 0.




Figure 7: Histograma de una variable con distribución sesgada hacia la izquierda previo y luego de aplicar una transformación logarítmica.

### 5.2.2 Transformación raíz cuadrada

### 5.2.3 Transformación Box-Cox

### 5.2.4 Transformación Yeo-Johnson

### 5.2.5 Transformaciones manuales

## 5.3 Variables categóricas

### 5.3.1 Limpieza

Si la variable "ciudad" de nuestro dataset contiene los siguientes valores únicos: ["rosario", "Rosario", "roasrio", "Rosarioi", "Rosario."], ¿crees que se está haciendo referencia a distintas ciudades? ¿o a la misma ciudad, pero con errores de tipeo?

Es importante efectuar una limpieza en este tipo de variables ya que en caso contrario, el algoritmo de ML que se emplee luego tendrá en cuenta que son ciudades distintas, y no podrá llegar a las conclusiones esperadas.

Si bien no hay una regla que pueda adaptarse a todos los conjuntos de datos, ya que pueden ser de naturaleza muy variada, si se puede dar algunas generalidades, que sólo serán válidas según el caso:

- obtener y observar los valores únicos de la variable. En caso de que no sean una cantidad abismal, es posible detectar este tipo de errores fácilmente y reemplazarlos.
- procesar las variables transformando todas sus letras a minúscula.
- ignorar caracteres especiales y espacios.
- pensar en abreviaturas que puedan vincularse entre sí (por ejemplo, BsAs y Buenos Aires).

- otros.

### 5.3.2 Valores no vistos anteriormente

Es posible que en el dataset de entrenamiento y prueba que se utilice, una variable categórica tome cierta cantidad de valores, por ejemplo, la variable "ciudad" y sus valores "Rosario", "Santa Fe", "Paraná". Suponga que el algoritmo ya se encuentra entrenado, testeado y desplegado en producción, y a la hora de utilizarlo, el usuario desea realizar un estimativo en la ciudad "Posadas". El algoritmo no fue entrenado con esta variable, por lo que, en primera instancia, se tendrá un error. Esto es lo que se conoce como valores no vistos anteriormente, o *unseen values*.

Lógicamente aquí sucedió un error en el planteo del problema, donde el cliente habrá asegurado que el algoritmo sólo se podría usar en las ciudades "Rosario", "Santa Fe" y "Paraná". Pero es necesario comprender si la variable puede tomar valores nuevos o no, ya que de eso dependerá su codificación. En algunos casos, la variable, por contexto, no puede tomar valores nuevos (por ejemplo, el día de la semana), y en otros, como el ejemplo dado, si.

Otro caso que puede suceder es si efectivamente en el conjunto de datos de entrenamiento se observa la variable "día de la semana", pero en ningún dato está el día "domingo". Debe averiguarse la causa, si es porque no se registró nunca un dato de ese día o si el modelo de negocio no lo permite, ya que en función de eso podrán llegar o no datos a producción con el día de la semana "domingo".

### 5.3.3 Codificación dummy -Dummy encoding y One Hot Encoding (OHE)-

La manera más simple de trabajar con variables categóricas es crear **variables dummy**, que consiste en generar tantas variables como categorías tenga la variable original, que solo pueden tomar los valores 0 o 1, y que se encarguen cada una de indicar si para esa observación la categoría de la variable es la categoría  $x$  o no.

Por ejemplo, para la variable "día de la semana", donde en el conjunto de entrenamiento toma los valores únicos "lunes", "martes", "miércoles", "jueves" y "viernes", se muestran algunas observaciones del dataset en la tabla 2 y su correspondiente transformación dummy en la tabla 3.

La primer columna de la tabla 3 indica si "el día de la semana es lunes o no", la segunda columna indica si "el día de la semana es martes o no" y así sucesivamente. Un detalle adicional es que la última columna no aporta valor **siempre y cuando sea una condición verdadera la de que si el día no es lunes, ni martes, ni miércoles, ni jueves, es viernes**. Si esto es efectivamente así, la última columna puede obviarse, ya que no aporta varianza al conjunto de datos. Ahora, si también es válido que el día pueda ser sábado o domingo, entonces la columna *vi* debe mantenerse, y cuando todas las columnas sean nulas, significará que el día es sábado o domingo.

| Día de la Semana | lu | ma | mi | ju | vi |
|------------------|----|----|----|----|----|
| Lunes            | 1  | 0  | 0  | 0  | 0  |
| Miércoles        | 0  | 0  | 1  | 0  | 0  |
| Viernes          | 0  | 0  | 0  | 0  | 1  |
| Martes           | 0  | 1  | 0  | 0  | 0  |
| Jueves           | 0  | 0  | 0  | 1  | 0  |
| Lunes            | 1  | 0  | 0  | 0  | 0  |
| Viernes          | 0  | 0  | 0  | 0  | 1  |
| Miércoles        | 0  | 0  | 1  | 0  | 0  |

Table 2: Variable categórica: Día de la semana. Table 3: Codificación dummy para la variable "Día de la semana".

Es un método muy simple (fácil de interpretar luego, lo cual se verá en los siguientes capítulos que es muy importante). Sin embargo, si bien ahora el conjunto de datos puede utilizarse para entrenar un algoritmo como el de regresión lineal, es de destacar que se agregan tantas variables como categorías tenga la variable original, lo que puede agregar **información dispersa (sparse data)**. No es necesariamente algo malo, simplemente se debe tener en cuenta. Es importante nunca crear más variables que observaciones tenga el dataset.

Se conoce como **One Hot Encoding (OHE)** a la codificación donde se conservan todas las categorías de la variable original como nuevas variables y **Dummy Encoding** a la codificación donde se deja una de las variables fuera.

#### 5.3.4 Codificación por etiquetas -Label encoding-

Es un método que relaciona y reemplaza directamente cada categoría con un número. Cuando solo hay dos categorías, es el método más utilizado, puesto que convierte la columna en una variable booleana. Para mayor cantidad de categorías no suele funcionar bien, ya que se le estaría asignando un valor numérico a algo que no lo tiene. Por ejemplo, si se le asigna el 2 a febrero y el 4 a abril, se estaría diciendo que abril es el doble que febrero, lo cual, en la mayoría de los casos, carecerá de sentido.

#### 5.3.5 Codificación ordinal -Ordinal encoding-

Similar a Label encoding, pero además de relacionar una categoría con un número, se busca establecer una magnitud para cada categoría. Por ejemplo, si la variable es la calidad de un equipo, pero cuyos valores de la variable son "mal", "bien", "muy bien", "excelente", se podrían asociar como muestra la tabla 4.

En este ejemplo, es pasar la calificación que tiene palabras a números que podrían ser equivalentes. Otro ejemplo podría ser una variable que determina

| Categoría | Valor |
|-----------|-------|
| mal       | 3     |
| bien      | 6     |
| muy bien  | 8     |
| excelente | 10    |

Table 4: Codificación ordinal de categorías.

si el precio de una acción va a "subir", "mantenerse" o "bajar", lo que podría traducirse en 1, 0 y -1, lo cual genera cierto sentido. También se podrían asignar los valores "subir": 8, "mantenerse": 3.14, "bajar": 6, pero aquí no se está respetando el sentido real de los valores de la variable original.

En caso de usarse, se debe hacer con mucha precaución, ya que es importante que la codificación genere coherencia para que el algoritmo de aprendizaje pueda obtener resultados significativos. Presenta algunas ventajas: no se generan nuevas variables y preserva un cierto orden de los valores.

### 5.3.6 Codificación binaria -binary encoding-

Esta codificación propone asignar un valor entero a cada categoría, como en los casos anteriores, pero luego descomponer estos valores en su codificación binaria. La cantidad de variables a generar dependerá de la cantidad de dígitos necesarios en binario para determinar el entero máximo que se haya elegido.

| Categoría | Valor |
|-----------|-------|
| Rojos     | 1     |
| Azul      | 2     |
| Verde     | 3     |
| Amarillo  | 4     |

Table 5: Asignación de valores a las categorías.

| Categoría | Decimal | Binario | X1 | X2 |
|-----------|---------|---------|----|----|
| Rojos     | 1       | 01      | 0  | 1  |
| Azul      | 2       | 10      | 1  | 0  |
| Verde     | 3       | 11      | 1  | 1  |
| Amarillo  | 4       | 100     | 1  | 0  |

Table 6: Codificación Binary Encoding.

En el caso de la tabla 6, solo se requieren dos variables para representar cuatro categorías, donde el Dummy encoding necesita al menos tres. Además, la información ya no es tan dispersa (menor cantidad de ceros). Si fuesen mil variables, Dummy encoding requeriría 999 columnas mientras que con este método sería suficiente con 10. Como gran ventaja entonces se presenta la reducción de la dimensionalidad respecto de otros métodos.

La gran desventaja es la interpretabilidad de las variables generadas, ya que los valores fueron asignados prácticamente al azar (¿qué podría pasar si al Rojo se le asigna el 2 y al Azul el 1?).

### 5.3.7 Codificación por frecuencia -frequency encoding-

Consiste en reemplazar cada variable categórica por un número, pero no cualquier número, sino su frecuencia de aparición en la columna (también llamado "count encoding"). No es muy usado, pierde gran poder de predicción si hay etiquetas con frecuencias similares, y por más que sean distintas, podría no agregar ninguna información adicional y sólo ruido. Como ejemplo donde podría servir, si se tiene un dataset donde cada observación hace referencia a una medición defectuosa de un sensor en una industria, una variable categórica podría ser el id del sensor. Si se codifica de esta forma, los sensores con mayor tendencia a ser defectuosos tendrían valores más altos que los que suelen funcionar correctamente, y si la variable target tiene cierta correlación con este valor, podría ser útil.

### 5.3.8 Codificación por variable target -target encoding-

Consiste en codificar según un estadístico que relacione la variable con la variable target. Por ejemplo, para predecir si un usuario hará una compra en un sitio web (compra = 1) o no (compra = 0), uno de los atributos puede ser la fuente de tráfico, es decir, desde dónde llegó el usuario al sitio web (Google, Facebook, Instagram, etc.). Se puede reemplazar cada categoría por la media de la variable objetivo (variable "compra").

| Fuente de tráfico | Compra (Target) |
|-------------------|-----------------|
| Google            | 1               |
| Google            | 0               |
| Google            | 1               |
| Facebook          | 0               |
| Facebook          | 0               |
| Instagram         | 1               |
| Instagram         | 1               |
| Instagram         | 1               |

Table 7: Datos originales con la variable categórica.

| Fuente de tráfico | Promedio de Compra       |
|-------------------|--------------------------|
| Google            | $\frac{1+0+1}{3} = 0.67$ |
| Facebook          | $\frac{0+0}{2} = 0.00$   |
| Instagram         | $\frac{1+1+1}{3} = 1.00$ |

Table 8: Cálculo del Target encoding.

| Fuente de Tráfico (ya codificada) |
|-----------------------------------|
| 0.67                              |
| 0.67                              |
| 0.67                              |
| 0.00                              |
| 0.00                              |
| 1.00                              |
| 1.00                              |
| 1.00                              |

Table 9: Variable categórica reemplazada por Target encoding.

Nuevamente se tiene una forma de codificar que no aumenta la dimensionalidad, y puede capturar ciertas relaciones estadísticas.

En caso de usarlo, procurar que haya suficientes muestras para cada valor de la variable categórica, puesto que si son "pocas", se estaría confiando en que estos pocos datos pueden representar perfectamente la población de esa categoría. De ahí que se diga que este método tiende a generar *sobreaajuste - overfitting-*. Por ejemplo, no es lo mismo un hotel con 3 comentarios en Google de 5 estrellas, que uno con 10.000 comentarios con un promedio de 4.8 estrellas.

Otro detalle a tener en cuenta son los valores no vistos. ¿Qué sucedería si aparece una nueva "Fuente de tráfico"? No se tendrían datos suficientes para generar un valor para la codificación. En todo caso, se debería proponer una solución a que valor tomar. Y esto depende mucho del contexto.

### 5.3.9 Codificación cíclica -circular encoding-

La codificación cíclica se puede usar cuando una variable categórica tiene una naturaleza cíclica o periódica, usualmente en derivados de una fecha. Es útil cuando los valores tienen una relación circular, como los días de la semana, los meses del año, las horas del día, la dirección del viento, posiciones angulares, ciclos biológicos, etc. Consiste en hacer primero un label encoding (con valores del 1 al  $n_{categorias}$ ) y aplicarle dos transformaciones trigonométricas para generar dos nuevas variables.

$$X_1 = \sin\left(\frac{2\pi \cdot \text{valor}}{\text{número de categorías}}\right)$$

$$X_2 = \cos\left(\frac{2\pi \cdot \text{valor}}{\text{número de categorías}}\right)$$

En el caso de los meses del año, se requieren once variables para un Dummy encoding, en las horas del día son veintitrés variables, mientras que en esta codificación es suficiente con dos en ambos casos.



| Mes        | Seno ( $X_1$ )                                            | Coseno ( $X_2$ )                                         |
|------------|-----------------------------------------------------------|----------------------------------------------------------|
| Enero      | $\sin\left(\frac{2\pi \cdot 1}{12}\right) \approx 0.50$   | $\cos\left(\frac{2\pi \cdot 1}{12}\right) \approx 0.87$  |
| Febrero    | $\sin\left(\frac{2\pi \cdot 2}{12}\right) \approx 0.87$   | $\cos\left(\frac{2\pi \cdot 2}{12}\right) \approx 0.50$  |
| Marzo      | $\sin\left(\frac{2\pi \cdot 3}{12}\right) \approx 1.00$   | $\cos\left(\frac{2\pi \cdot 3}{12}\right) \approx 0.00$  |
| Abril      | $\sin\left(\frac{2\pi \cdot 4}{12}\right) \approx 0.87$   | $\cos\left(\frac{2\pi \cdot 4}{12}\right) \approx -0.50$ |
| Mayo       | $\sin\left(\frac{2\pi \cdot 5}{12}\right) \approx 0.50$   | $\cos\left(\frac{2\pi \cdot 5}{12}\right) \approx -0.87$ |
| Junio      | $\sin\left(\frac{2\pi \cdot 6}{12}\right) \approx 0.00$   | $\cos\left(\frac{2\pi \cdot 6}{12}\right) \approx -1.00$ |
| Julio      | $\sin\left(\frac{2\pi \cdot 7}{12}\right) \approx -0.50$  | $\cos\left(\frac{2\pi \cdot 7}{12}\right) \approx -0.87$ |
| Agosto     | $\sin\left(\frac{2\pi \cdot 8}{12}\right) \approx -0.87$  | $\cos\left(\frac{2\pi \cdot 8}{12}\right) \approx -0.50$ |
| Septiembre | $\sin\left(\frac{2\pi \cdot 9}{12}\right) \approx -1.00$  | $\cos\left(\frac{2\pi \cdot 9}{12}\right) \approx 0.00$  |
| Octubre    | $\sin\left(\frac{2\pi \cdot 10}{12}\right) \approx -0.87$ | $\cos\left(\frac{2\pi \cdot 10}{12}\right) \approx 0.50$ |
| Noviembre  | $\sin\left(\frac{2\pi \cdot 11}{12}\right) \approx -0.50$ | $\cos\left(\frac{2\pi \cdot 11}{12}\right) \approx 0.87$ |
| Diciembre  | $\sin\left(\frac{2\pi \cdot 12}{12}\right) \approx 0.00$  | $\cos\left(\frac{2\pi \cdot 12}{12}\right) \approx 1.00$ |

Table 10: Codificación cíclica de los meses del año.

Además de mantener una dimensionalidad baja respecto de OHE, también conserva cierta relación entre meses contiguos (por ejemplo, enero y febrero son menos distintos entre sí que enero y julio, como muestra la tabla 10). En el caso de OHE, los meses serían completamente distintos todos entre sí. Lógicamente esto puede ser bueno o malo en el algoritmo de aprendizaje, según la relación estadística entre estas variables y la variable target.

#### 5.3.10 Otras codificaciones.

Existe una cantidad prácticamente infinita de codificaciones que se pueden realizar. Se los invita a explorar otras opciones en internet y no sólo quedarse con las brindadas aquí. Es posible que muchas de ellas solo se apliquen en casos muy específicos.

### 5.4 Tratamiento de variables correlacionadas

Se ha mencionado en 2.5 la existencia de predictores correlacionados y como medir su correlación. Por lo general, los modelos de aprendizaje no funcionan correctamente con variables muy correlacionadas, dado que están aportando información similar. El problema en sí es si esta información es muy importante. Si una variable explicativa tiene gran capacidad predictiva sobre la salida y además esta información es compartida con otra variable, esta variable también será altamente predictiva. Pero en realidad, cuando una de ellas es predictiva, la otra se vuelve obsoleta, ya que dan la misma información, y esto puede llevar a conclusiones erróneas sobre la interpretabilidad del modelo. Se podría pensar que lo lógico es eliminar una de ellas, pero hay que tener cuidado, porque si

bien la información conjunta puede ser importante, también lo puede ser su información disjunta, es decir, la que no comparten (ya que la correlación por lo general no es perfecta).

Por lo general, el tratamiento de variables correlacionadas conlleva realizar **reducción de dimensionalidad**, que puede hacerse de diversas formas:

- con algoritmos como PCA (data mining).
- creando una variable con información de ambas: esto puede ser manual o con un filtro de correlación.
- eliminando una variable. Bueno, es reducción de dimensionalidad, pero se puede estar perdiendo información valiosa (disjunta).

Para un ejemplo donde omitir variables por alta correlación es muy poco acertado, ver el notebook **correlacion.ipynb**.

## References

- [1] Charu C. Aggarwal. *Outlier Analysis*.
- [2] Stef van Buuren. *Flexible Imputation of Missing Data*.