




Modelos lineales para Clasificación




y es categórica



Classification

y es numérica




Regression

Problemas de Clasificación




Algoritmos de Clasificación


Logistic Regression




Decision Tree




Random Forest




Support Vector Machine



K Nearest Neighbour



Naive Bayes



Clasificación Binaria vs Multi-clase



Dónde aparece


Binaria (dos valores posibles): detección de fraude, diagnóstico médico, spam, predecir si algo va a pasar o no.

Multiclase (más de dos): señales de tránsito, cepa de un vino, detección de objetos, análisis de sentimiento.

Otra forma de decirlo: la variable **es o no es** algo, o **cuál de varias cosas** es.

En muchos de estos problemas una clase es mucho más rara que la otra. Guardemos ese dato.

Ejemplo de default en tarjeta de crédito



Las *features* son ingresos anuales y los saldos mensuales de tarjetas de crédito. Los que incumplieron en sus pagos se muestran en naranja, los que no en azul.

¿Y si usamos regresión lineal?



La idea, que parece razonable

Codificamos las clases como números: 0 y 1.

Ajustamos una recta por mínimos cuadrados, igual que en las clases anteriores.

$$\textit{Diagnóstico médico} \quad Y = \begin{cases} 0 & \text{if stroke;} \\ 1 & \text{if drug overdose.} \end{cases}$$


Podríamos ajustar una regresión lineal a esta respuesta binaria y predecir drug overdose si $Y > 0.5$ y un stroke en caso contrario.

Funciona... más o menos. Veamos qué se rompe.

Ajuste de la regresión lineal


¿Qué tal el ajuste? ¿Parece bueno?

¿La recta puede definir **probabilidad** de pertenencia a una clase?



Problema 1: el umbral es frágil

Por qué la regresión lineal no sirve para clasificar



Además, la recta predice valores negativos y mayores a 1: esos números no pueden ser probabilidades.



Problema 2: y en multiclase, peor

$$Y = \begin{cases} 1 & \text{if epileptic seizure;} \\ 2 & \text{if stroke;} \\ 3 & \text{if drug overdose,} \end{cases}$$

No hay forma de asignar valores en este problema y conservar el sentido de los mismos (el problema es el mismo que el de la codificación ordinal).



Lo que necesitamos

Una salida que esté **siempre entre 0 y 1**, para poder leerla como probabilidad.

Que no se desarme porque apareció un dato lejano.

Que se pueda extender a más de dos clases sin inventar órdenes falsos.


Y a ser posible, que por dentro siga siendo **lineal**, para reusar todo lo que ya sabemos.

Regresión logística

(empecemos con problemas binarios)

La idea completa, en un esquema

La regresión logística, de punta a punta




Lo único que se aprende son los β . Todo lo demás es siempre igual.

¿Y la función de pérdida? ¿Qué voy a **minimizar** para obtener los mejores coeficientes?

Función sigmoidea

Nunca es mayor a uno ni menor a cero.
Justo lo que necesitamos, mapear de los
reales al conjunto $[0,1]$


$$f(x) = \frac{1}{1 + e^{-x}}$$



Función de decisión

Consiste en elegir un *threshold* para separar las clases

No necesariamente es 0.5



Función logística

segunda aproximación: función logística

$$p(X) = \beta_0 + \beta_1 X. \longrightarrow p(X) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}}.$$

primer aproximación

*razón de
probabilidad*

$$\frac{p(X)}{1 - p(X)} = e^{\beta_0 + \beta_1 X} \longrightarrow \log \left(\frac{p(X)}{1 - p(X)} \right) = \beta_0 + \beta_1 X.$$

odds (chances)

log odds or logit. (logaritmo de las chances)



Razón de Probabilidad - Odds: las chances

Si 9 de cada 10 personas caen en default: $p = 0,9 \rightarrow \text{odds} = 0,9 / 0,1 = \mathbf{9}$. Nueve veces más probable que pase a que no pase.

Si son 5 de cada 10: $p = 0,5 \rightarrow \text{odds} = 0,5 / 0,5 = \mathbf{1}$. Igual de probable.

Las odds van de **0 a infinito**: mapean el intervalo $[0, 1]$ a los reales positivos.

Si además les tomamos logaritmo, llegamos a **todos** los reales. Eso es el **logit**.

Lo que en realidad es lineal

La regresión logística es lineal... pero en el logit

$$\log \left(\frac{p}{1-p} \right) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$$

las odds:
cuántas veces más probable
es que pase a que no pase

el logit
(log de las chances)

ESTO sí es una combinación lineal,
igual que en regresión lineal

Por eso se llama regresión LINEAL para clasificación: lo lineal está acá, no en la probabilidad.



La frontera es un hiperplano


Si $p = 0,5$, entonces $p = 1 - p$, las odds valen 1 y el logit vale 0.

Es decir: $\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p = 0$. Eso es la ecuación de un **hiperplano**.

Y para cualquier otro valor de p la separación también es un hiperplano, sólo que corrido: cambia el término independiente.

Su límite: si las clases no se separan con una recta, este modelo no va a poder.

La frontera de decisión





La función de decisión

La sigmoidea nos da una probabilidad. Para dar una respuesta hay que elegir un **umbral** (threshold).


No necesariamente 0,5. Ese es el valor por defecto, no una obligación.

En detección de fraude o diagnóstico médico conviene un umbral más bajo: es preferible una falsa alarma a dejar pasar un caso real.

Elegir el umbral no es una decisión estadística: depende de cuánto cuesta cada tipo de error.

Mover el umbral cambia todo

El umbral es una decisión tuya, no del modelo (borde negro = predicción equivocada)



Coeficientes de la Regresión Logística Binaria



Función de Costo

¿Qué sería lo equivalente a los RSS?



¿Qué reemplaza al RSS?

En regresión minimizábamos el RSS: la suma de los errores al cuadrado.

Acá no sirve. El modelo devuelve una probabilidad, y queremos premiar que le asigne **alta probabilidad a la clase correcta**.

La idea: buscar los β que hacen **más probables los datos que efectivamente observamos** (máxima verosimilitud, sobre una Bernoulli).

Tomando logaritmo y cambiando el signo, maximizar se convierte en minimizar. El resultado se llama **Binary Cross Entropy**.



Función de Costo

Densidad de probabilidad de Bernoulli

$$f(x|p) = \begin{cases} 1 - p, & x = 0 \\ p, & x = 1 \end{cases}.$$

Equivalentemente, $p^x(1-p)^{1-x}$

Se busca maximizar la productoria

$$\prod_{i=1}^n p^{y_i} (1-p)^{1-y_i}$$

$$\mathcal{L}(\beta) = \prod_{i=1}^n [\sigma(\beta^T \mathbf{x}^{(i)})]^{y^{(i)}} [1 - \sigma(\beta^T \mathbf{x}^{(i)})]^{1-y^{(i)}}$$



Función de Costo

Aplicando logaritmos

$$\log \mathcal{L}(\boldsymbol{\beta}) = \sum_{i=1}^n \left[y^{(i)} \log \sigma(\boldsymbol{\beta}^T \mathbf{x}^{(i)}) + (1 - y^{(i)}) \log(1 - \sigma(\boldsymbol{\beta}^T \mathbf{x}^{(i)})) \right]$$

Y cómo minimizar es más simple que maximizar, minimizamos la siguiente función

$$\min_w C \sum_{i=1}^n \left(-y_i \log(\hat{p}(X_i)) - (1 - y_i) \log(1 - \hat{p}(X_i)) \right)$$



Binary Cross Entropy

$$H_p(q) = -\frac{1}{N} \sum_{i=1}^N y_i \cdot \log(p(y_i)) + (1 - y_i) \cdot \log(1 - p(y_i))$$

Binary Cross Entropy: el reemplazo del RSS

$$L(\beta) = -\frac{1}{n} \sum_{i=1}^n \left[y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i) \right]$$

el menos convierte
'maximizar' en 'minimizar'

actúa sólo si
la clase real es 1


actúa sólo si
la clase real es 0

Como y vale 0 o 1, en cada dato uno de los dos términos se apaga solo.


Binary Cross Entropy

$$\text{cost}(h_{\theta}(\mathbf{x}), y) = \begin{cases} -\log(h_{\theta}(\mathbf{x})) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(\mathbf{x})) & \text{if } y = 0 \end{cases}$$

if $y = 1$




if $y = 0$




Binary Cross Entropy

No alcanza con acertar: el costo castiga estar seguro y equivocarse

Si la clase real es $y = 1$



Si la clase real es $y = 0$





Cómo se minimiza

A diferencia de la regresión lineal, acá **no existe una fórmula cerrada** para los β .

Hay que ir a **gradiente descendiente** (o alguna variante suya). Exactamente lo de la clase 4.

La buena noticia: la Binary Cross Entropy es convexa, así que hay un solo mínimo y el algoritmo siempre lo encuentra.

Esta es la respuesta a aquella pregunta: usamos gradiente descendiente porque acá **no hay otra opción**.



Función de Costo - Regularización

:

$$\min_w C \sum_{i=1}^n (-y_i \log(\hat{p}(X_i)) - (1 - y_i) \log(1 - \hat{p}(X_i))) + r(w).$$


We currently provide four choices for the regularization term $r(w)$ via the `penalty` argument:

penalty	$r(w)$
None	0
ℓ_1	$\ w\ _1$
ℓ_2	$\frac{1}{2} \ w\ _2^2 = \frac{1}{2} w^T w$
ElasticNet	$\frac{1-\rho}{2} w^T w + \rho \ w\ _1$


Problemas multiclase

Problemas multiclase


Binary classification:



Multi-class classification:



Softmax



**Un solo modelo con K rectas.
Las probabilidades suman 1 por construcción.**



Probabilidad de pertenecer a la clase k

$$\text{softmax}(z_i) = \frac{e^{z_i}}{\sum_{k=1}^K e^{z_k}}$$

$$\Pr(Y = k | X = x) = \frac{e^{\beta_{k0} + \beta_{k1}x_1 + \dots + \beta_{kp}x_p}}{1 + \sum_{l=1}^{K-1} e^{\beta_{l0} + \beta_{l1}x_1 + \dots + \beta_{lp}x_p}}$$