
Métricas

Midiendo el desempeño del modelo



Matriz de confusión

Definimos una clase como la “positiva”.

Predicted Values

Positive (1)

Negative (0)

Actual Values

Positive (1)

Negative (0)

TP

FP

FN

TN

TP	FP
FN	TN

Verdadero positivo

Interpretación: Predijiste positivo y es verdad.

Predijiste que llovía y llovió efectivamente.

Falso positivo (Error tipo 1)

Interpretación: Predijiste positivo y es falso.

Predijiste que llovía pero no llovió.

Falso Negativo (Error Tipo 2)

Interpretación: Predijiste algo negativo y es falso.

Predijiste que no llovía y sí llovió.

Verdadero Negativo

Interpretación: Predijiste algo negativo y es cierto.

Predijiste que no llovía y efectivamente no llovió

Accuracy

$$(VP+VN)/(VP+VN+FP+FN)$$

Verdadero positivo

Interpretación: Predijiste positivo y es verdad.

Predijiste que llovía y llovió efectivamente.

Falso positivo (Error tipo 1)

Interpretación: Predijiste positivo y es falso.

Predijiste que llovía pero no llovió.

Falso Negativo (Error Tipo 2)

Interpretación: Predijiste algo negativo y es falso.

Predijiste que no llovía y sí llovió.

Verdadero Negativo

Interpretación: Predijiste algo negativo y es cierto.

Predijiste que no llovía y efectivamente no llovió



Accuracy

Representa la cantidad de aciertos del modelo respecto del total de datos.

Es una buena métrica para problemas cuyos dataset están **balanceados**.

Recall

VP/(VP+FN) o VN/(FP+VN) según la clase

Verdadero positivo

Interpretación: Predijiste positivo y es verdad.

Predijiste que llovía y llovió efectivamente.

Falso positivo (Error tipo 1)

Interpretación: Predijiste positivo y es falso.

Predijiste que llovía pero no llovió.

Falso Negativo (Error Tipo 2)

Interpretación: Predijiste algo negativo y es falso.

Predijiste que no llovía y sí llovió.

Verdadero Negativo

Interpretación: Predijiste algo negativo y es cierto.

Predijiste que no llovía y efectivamente no llovió



Recall

Representa, dentro de la misma clase, cuántas fueron correctamente clasificadas.

En este caso, para un problema de clases desbalanceadas, se puede encontrar que una clase tenga un recall muy alto y la otra muy bajo, de esta forma se detecta un problema en el modelo, no así en el accuracy,

Precisión

VP/(VP+FP) o VN/(FN+VN) según la clase

Verdadero positivo

Interpretación: Predijiste positivo y es verdad.

Predijiste que llovía y llovió efectivamente.

Falso positivo (Error tipo 1)

Interpretación: Predijiste positivo y es falso.

Predijiste que llovía pero no llovió.

Falso Negativo (Error Tipo 2)

Interpretación: Predijiste algo negativo y es falso.

Predijiste que no llovía y sí llovió.

Verdadero Negativo

Interpretación: Predijiste algo negativo y es cierto.

Predijiste que no llovía y efectivamente no llovió



Precisión

De las clases que se han clasificado como positivas, indica cuántas realmente lo son.

A menores falsos positivos, mayor la precisión.



y	y pred	output for threshold 0.6	Recall	Precision	Accuracy
0	0.5	0	1/2	2/3	4/7
1	0.9	1			
0	0.7	1			
1	0.7	1			
1	0.3	0			
0	0.4	0			
1	0.5	0			



F1 Score (o F-Measure)

Podría ser bueno considerar una métrica que tenga en cuenta tanto la precisión como el recall.

Se utiliza una media armónica

$$F1 = 2 * ((\text{recall} * \text{precision}) / (\text{recall} + \text{precision}))$$

En problemas de alto recall y baja precisión o viceversa, un promedio no tiene un buen desempeño. La media armónica penaliza mejor si alguno de los dos es bajo (ya que están multiplicando)



Accuracy, Recall, Precision & F1

- Recall, Precision y F1 se calculan para una clase en específico. Es decir, a la hora de evaluarlos, para cada uno de ellos hay que realizar dos cálculos, uno para cada clase.
- Accuracy se calcula para todo el conjunto. Sólo hay una accuracy.



Accuracy, Recall, Precision & F1

La **exactitud** (accuracy) se utiliza cuando los Verdaderos Positivos (True Positives) y los Verdaderos Negativos (True Negatives) son más importantes. Es una métrica útil cuando el dataset está **balanceado**.

Si los Falsos Positivos (False Positives) son mucho más importantes que los FN, conviene utilizar la **precisión**.

Si los Falsos Negativos (False Negatives) son mucho más importantes que los FP, conviene utilizar el **recall**.

El **F1-Score** se utiliza cuando los Falsos Negativos (False Negatives) y los Falsos Positivos (False Positives) son importantes. Y es una muy buena métrica para datos **desbalanceados**.



Problemas multiclase: Matriz de confusión 3x3

	Apple	Banana	Mango
Apple	120	102	93
Banana	16	230	77
Mango	32	92	170

¿Cuánto es la accuracy?

Problemas multiclase: Matriz de confusión 3x3

	Apple	Banana	Mango
Apple	120	102	93
Banana	16	230	77
Mango	32	92	170

- $\text{Precision}(\text{Apple}) = 120 / (120 + 102 + 93) = 0.38$
- $\text{Precision}(\text{Banana}) = 230 / (16 + 230 + 77) = 0.71$
- $\text{Precision}(\text{Mango}) = 170 / (32 + 92 + 77) = 0.84$
- $\text{Recall}(\text{Apple}) = 120 / (120 + 16 + 32) = 0.71$
- $\text{Recall}(\text{Banana}) = 230 / (230 + 102 + 92) = 0.54$
- $\text{Recall}(\text{Mango}) = 170 / (170 + 93 + 77) = 0.50$



Implementación en sklearn

https://scikit-learn.org/stable/modules/model_evaluation.html#classification-metrics



Curva ROC (Receiver Operating Characteristics)

$$\text{TPR / Recall / Sensitivity} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

$$\text{Specificity} = \frac{\text{TN}}{\text{TN} + \text{FP}}$$

$$\text{FPR} = 1 - \text{Specificity}$$

$$= \frac{\text{FP}}{\text{TN} + \text{FP}}$$



Curva ROC

- Entrenar un modelo de clasificación.
- Obtener, para los datos de **validación**, las probabilidades de pertenencia a una de las clases.
- Para cada umbral entre 0 y 1, con una cierta granularidad:

Se calcula TPR y FPR.



Curva ROC


Para un umbral=0, el modelo siempre predice la clase positiva. Por lo que $FN=0$ y resulta $TPR=1$. Además $TN=0$ así que $FPR=1$ también.


Para un umbral=1, el modelo siempre predice la clase negativa. Por lo que $TP=0$ entonces $TPR=0$ y $FP=0$ por lo que $FPR=0$ también.

Los puntos (0,0) y (1,1) son parte entonces de la gráfica siempre.

A medida que varía el umbral, obtendremos puntos (FPR, TPR). Se espera que $TPR > FPR$ (que el modelo prediga más True Positives que False Positives), con lo cual la curva final debería quedar por encima de

El modelo perfecto sería aquel cuya curva ROC contenga el punto $(0,1)$. Dado que punto representa que no hay falsos positivos ni falsos negativos.







AUC - Area Under the Curve (Área bajo la curva)

Es el área debajo de la curva ROC. Su valor máximo es 1 (cuadrado de lado 1).

Puede ser entonces un indicador de desempeño.

Mientras más cercano esté a 1, implica que la curva ROC está más cerca de contener al punto (0,1).

Si es 0.5, el modelo es tan malo como predecir random.



ROC - AUC

Suma algo interesante que es la **variación del umbral**. Se puede intentar optimizar la elección de este umbral, por fuera de lo que tengan preestablecido los modelos de clasificación (usualmente seteado en 0.5).