

# GUÍA DE DEFENSA

Trabajo Práctico Final — Bases de Datos II

The Drinking Company · Data Warehouse

TUIA · FCEIA · UNR · 2026

**Federico Winter** | **Maximiliano Frank**



## Cómo usar esta guía

Esta guía sigue el flujo lógico de una defensa oral típica de este TP. Para cada bloque encontrás:

- Un SPEECH sugerido (cursiva, borde azul) — lo que podés decir en voz alta
- Tips técnicos clave para entender lo que estás explicando
- Advertencias sobre preguntas difíciles o errores comunes

### Orden recomendado de la presentación:

- 1. Presentación del caso de negocio (1-2 min)
- 2. Modelo dimensional: decisiones de diseño (3-4 min)
- 3. Fuentes de datos y ETL en SSIS (4-5 min)
- 4. Reportes en Power BI y respuesta a las gerencias (3-4 min)
- 5. Preguntas del jurado — respuestas preparadas

## 1. Caso de negocio — TDC

### Qué es TDC y por qué necesita un DW

Lo que tenés que transmitir: el problema que resuelve el DW, no solo describir la empresa.

💬 *The Drinking Company es una empresa que produce y vende bebidas — colas, cervezas, gaseosas, jugos y energizantes — en cuatro regiones de los Estados Unidos: Este, Oeste, Central y Sur. Opera tanto en el mercado minorista como mayorista y lleva cuatro años en el mercado. El problema concreto que teníamos era que todas las consultas analíticas de las gerencias impactaban directamente sobre la base de datos operacional, lo que generaba carga innecesaria y limitaba la capacidad de análisis histórico. La solución fue construir un Data Warehouse que centralice la información de todas las áreas y sirva de base exclusiva para los reportes.*

⚡ **TIP:** Si te preguntan '¿qué es un Data Warehouse?': es una base de datos diseñada para consultas analíticas, separada del sistema transaccional. Está optimizada para leer grandes volúmenes por dimensiones (tiempo, producto, geografía), no para insertar/actualizar registros individuales.

## 2. Modelo Dimensional — Esquema Estrella

### Decisiones de diseño generales

💡 Para el Data Warehouse elegimos un esquema estrella, que es el estándar para este tipo de soluciones. La ventaja principal es que las consultas son simples y performantes: siempre es una JOIN entre la tabla de hechos y una o varias dimensiones, sin necesidad de navegar relaciones complejas. El modelo tiene dos tablas de hechos y seis dimensiones.

⚡ **TIP:** Esquema estrella vs copo de nieve: en el estrella las dimensiones NO están normalizadas. En lugar de tener una tabla REGION separada, esa info está directamente en DIM\_GEO. Esto sacrifica algo de espacio pero simplifica enormemente las consultas en Power BI.

### Tabla de hechos: FACT\_VENTAS

Es la tabla central. Cada fila representa una línea de factura — un producto vendido en una venta.

💡 La tabla FACT\_VENTAS tiene grano de línea de factura: cada fila es un producto dentro de una venta. Elegimos este grano porque nos permite responder todas las preguntas de las gerencias con precisión, tanto a nivel de producto individual como agregando por cliente, por región o por período de tiempo. Las métricas que almacena son: cantidad, precio unitario, precio bruto, descuento aplicado, precio final y litros consumidos. También incluye atributos calculados que incorporamos durante el ETL: edad del cliente, edad del empleado, antigüedad del empleado y grupo etario del cliente.

⚡ **TIP:** Grano = el nivel de detalle más fino de una fila. Si te preguntan por qué no elegimos grano de factura (una fila por factura completa): porque perderíamos el detalle por producto, lo que haría imposible responder preguntas como 'ranking de productos más vendidos'.

⚠ **OJO:** Pregunta trampa frecuente: ¿por qué los atributos como 'edad del cliente' están en FACT y no en DIM\_CUSTOMER? Porque la edad cambia con el tiempo — no es un atributo fijo del cliente, sino calculado al momento de la venta.

### Tabla de hechos: FACT\_STOCK

💡 La segunda tabla de hechos es FACT\_STOCK, que registra los movimientos de stock por producto y fecha. Es un proceso de negocio diferente e independiente de las ventas, por eso tiene su propia tabla de hechos. Comparte las dimensiones DIM\_PROD y DIM\_TIME con FACT\_VENTAS, lo que permite cruzar análisis de ventas con niveles de stock.

### Las seis dimensiones

#### DIM\_TIME

💡 DIM\_TIME es la dimensión temporal. La clave primaria es la fecha completa en formato DATE. Además de la fecha, almacena atributos derivados como día de la semana, nombre del día, mes, nombre del mes, año, cuatrimestre, semestre, y dos indicadores booleanos: si es feriado y si es fin de semana. Los feriados los obtuvimos del archivo Holidays.xls provisto por el área de Recursos Humanos.

⚡ **TIP:** Por qué desnormalizar la fecha: en vez de tener solo una columna DATE en FACT\_VENTAS, tenemos DIM\_TIME con todos los atributos de tiempo precalculados. Esto hace que filtrar por 'todas las ventas de los sábados de Q3' sea trivial en Power BI sin necesidad de funciones de fecha.

#### DIM\_CUSTOMER

💡 DIM\_CUSTOMER unifica los dos tipos de clientes en una sola tabla: minoristas y mayoristas. Tomamos esta decisión de diseño deliberadamente — la alternativa era tener dos tablas separadas, DIM\_CUSTOMER\_R y DIM\_CUSTOMER\_W, pero eso complicaría todas las consultas de segmentación. Con una sola tabla y un atributo 'tipo', cualquier reporte puede filtrar por tipo de cliente o analizar ambos juntos sin cambiar la lógica. Los datos vienen de dos archivos XML: customer\_R.xml para retail y customer\_W.xml para wholesale.

⚠ **OJO:** Si el docente pregunta: '¿qué pasa si los clientes mayoristas no tienen email o teléfono?' — Los campos que no existen en la fuente mayorista quedan NULL en el DW. Es una decisión consciente, no un error de diseño.

#### DIM\_EMPLOYEE

💬 *DIM\_EMPLOYEE viene del archivo Employee.xls del área de Recursos Humanos. Almacena los atributos del empleado: género, categoría, nivel educativo, fecha de nacimiento y fecha de ingreso. La antigüedad en años la calculamos durante el ETL como un atributo derivado.*

## **DIM\_PROD**

💬 *DIM\_PROD tiene la información de los productos, combinando dos fuentes: el archivo Products.txt del área de Producción, que tiene nombre, categoría y presentación, y la tabla PRICES de MySQL que tiene los precios históricos. Agregamos dos indicadores booleanos que son clave para los reportes: es\_diet, para identificar las bebidas Diet cuya tendencia quiere analizar el gerente, y discontinuado, para el análisis de productos a discontinuar.*

## **DIM\_GEO**

💬 *DIM\_GEO almacena la jerarquía geográfica: región, estado y código postal. Los datos vienen del archivo Regions.txt. Esta dimensión es clave para el reporte de ranking de productos por zona geográfica y para análisis regionales de ventas.*

## **DIM\_DISCOUNT**

💬 *DIM\_DISCOUNT es una dimensión que modela los descuentos disponibles. Cada fila tiene el monto mínimo de factura requerido, el porcentaje de descuento y el rango de fechas de vigencia. Durante el ETL aplicamos la lógica de negocio: si una factura supera el monto mínimo de más de un descuento vigente, se aplica el de mayor porcentaje.*

⚡ **TIP:** Esta dimensión es técnicamente interesante. La lógica de descuentos viene de MySQL (tabla DISCOUNTS) y requirió una transformación no trivial en el ETL: para cada factura, buscar todos los descuentos aplicables y quedarse con el mejor.

### 3. Fuentes de datos — De dónde viene cada cosa

🗨 Una de las complejidades de este trabajo fue integrar fuentes de datos completamente heterogéneas. Trabajamos con seis tipos de fuente distintos simultáneamente.

|                   |                                                                                                                                                                               |
|-------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| SQL Server (nube) | Ventas históricas hasta 2008. Base TDChistorySales en server-tuia.database.windows.net. Una sola tabla con: billing_id, date, customer_id, employee_id, product_id, quantity. |
| MySQL (nube)      | Ventas actuales desde 2009. Base 'sales' en 132.226.43.0. Tiene 4 tablas: BILLING, BILLING_DETAIL, PRICES y DISCOUNTS.                                                        |
| customer_R.xml    | Clientes minoristas en formato XML. Campos: customer_id, full_name, birth_date, city, state, zipcode.                                                                         |
| customer_W.xml    | Clientes mayoristas en formato XML. Mismos campos básicos, sin email ni teléfono.                                                                                             |
| Employee.xls      | Empleados. Campos: employee_id, full_name, gender, category, employment_date, birth_date, education_level.                                                                    |
| Holidays.xls      | Feriados. Dos columnas: date, holiday. Se usa para poblar el indicador is_holiday en DIM_TIME.                                                                                |
| Products.txt      | Productos. Campos: product_id, detail, package. Texto plano delimitado.                                                                                                       |
| Stock.txt         | Movimientos de stock. Campos: product_id, date, variation. Texto plano.                                                                                                       |
| Regions.txt       | Geografía. Campos: region, state, city, zipcode. Texto plano.                                                                                                                 |

⚡ **TIP:** Si te preguntan cómo manejaron el cambio de SQL Server a MySQL en 2009: en el ETL unificamos ambas fuentes de ventas en FACT\_VENTAS. Las ventas históricas de SQL Server no tienen precio (solo quantity), entonces el precio se cruza con la tabla PRICES de MySQL usando product\_id y la fecha más cercana anterior a la venta.

## 4. Proceso ETL — SSIS

### Arquitectura general del ETL

💬 El proceso ETL fue implementado con SQL Server Integration Services, o SSIS, usando Visual Studio. Creamos un único paquete principal llamado `Package.dtsx` que orquesta toda la carga del Data Warehouse. El proceso sigue el orden natural del modelo: primero se cargan las dimensiones, y recién después la tabla de hechos, porque `FACT_VENTAS` necesita las claves foráneas de todas las dimensiones ya cargadas.

⚡ **TIP:** Orden de carga obligatorio en cualquier DW: 1) dimensiones → 2) tablas de hechos. Si cargás `FACT` primero, las foreign keys no existen todavía y falla la integridad referencial.

### Transformaciones clave que aplicamos

#### Encoding en los XML

💬 Los archivos XML de clientes venían con problemas de encoding — caracteres especiales que no se interpretaban correctamente en SSIS. Tuvimos que configurar el source de XML para usar el encoding correcto antes de procesar los datos.

#### Cálculo de litros consumidos

💬 Los litros consumidos no existen directamente en ninguna fuente. Los calculamos en el ETL multiplicando la cantidad vendida por la capacidad del producto en mililitros, y dividiendo por 1000. Eso se guarda como métrica en `FACT_VENTAS`.

⚡ **TIP:** Fórmula:  $\text{litros} = (\text{quantity} \times \text{capacity\_ml}) / 1000$ . La capacidad viene de `DIM_PROD`.

#### Lógica de descuentos

💬 La lógica de descuentos fue una de las partes más complejas del ETL. Para cada factura, buscamos todos los descuentos de la tabla `DISCOUNTS` de MySQL que: uno, estén vigentes en la fecha de la venta, y dos, cuyo monto mínimo de factura sea igual o menor al total de esa factura. Si hay más de uno aplicable, nos quedamos con el de mayor porcentaje.

#### Grupos etarios

💬 Calculamos la edad del cliente y del empleado en el momento de la venta como la diferencia entre la fecha de la venta y la fecha de nacimiento. Además, para los clientes asignamos un grupo etario: adolescentes para 13-19 años, adultos medios para 40-50, y calculamos también los de 66 años para el reporte específico que pide el gerente.

### Conexiones configuradas en SSIS

- SQL Server local (DW destino): conexión OLE DB a SQL Server donde vive el DW
- SQL Server en nube (ventas históricas): conexión OLE DB a `server-tuia.database.windows.net`
- MySQL (ventas actuales): conexión ODBC usando el driver MySQL Connector ODBC
- Excel: conexión Excel para `Employee.xls` y `Holidays.xls`
- XML flat file: para `customer_R.xml` y `customer_W.xml`
- Flat file (txt): para `Products.txt`, `Stock.txt` y `Regions.txt`

## 5. Reportes en Power BI

### Cómo se conecta Power BI al DW

💡 Power BI Desktop se conecta directamente al Data Warehouse en SQL Server. Una vez conectado, importa las tablas del esquema estrella y Power BI reconoce automáticamente las relaciones por las claves foráneas. Desde ahí construimos todos los reportes.

### Los 15 reportes — qué responde cada uno

|                                                      |                                                                                                                                                                     |
|------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Reporte 1-2: Litros y compra promedio por cliente    | Gráfico de líneas o barras con DIM_CUSTOMER en eje X, SUM(litros) y AVERAGE(litros) en eje Y, DIM_TIME como filtro de período.                                      |
| Reporte 3: Ranking productos por zona                | Matriz o tabla con DIM_GEO como filas, DIM_PROD como columnas, SUM(quantity) como valor. Con filtro de período temporal.                                            |
| Reporte 4: Proyección Q1 2011                        | Serie temporal de ventas históricas (2007-2010) con línea de tendencia o forecasting. Power BI tiene función de pronóstico nativa en gráficos de línea.             |
| Reporte 5: Estacionalidad energizantes en septiembre | Filtrar FACT_VENTAS por categoría = 'energy drinks', agrupar por mes. Mostrar si septiembre tiene pico o no. La hipótesis del gerente es a validar, no a confirmar. |
| Reporte 6: Edad vs tipo de bebida                    | Scatter plot o matriz con edad del cliente (grupos) vs categoría de bebida, valores en litros. Analiza si la edad determina preferencia.                            |
| Reporte 7: Ventas por segmentos etarios específicos  | Filtro por grupo_etario IN ('adolescentes 13-19', 'adultos medios 40-50', '66 años'). Tarjetas o barras con total de ventas por segmento.                           |
| Reporte 8 y 12: Empleado, edad, sexo y ventas        | Scatter o matriz con edad y género del empleado vs monto de ventas. Buscar correlación visual.                                                                      |
| Reporte 9: Top 5 vendedores prometedores 2011        | Proyección de ventas por empleado usando tendencia histórica. Ranking con los 5 de mayor proyección.                                                                |
| Reporte 10: Antigüedad vs cantidad vendida           | Correlación entre antigüedad_anios del empleado y SUM(quantity). Scatter plot.                                                                                      |
| Reporte 11: Pareto de clientes minoristas            | Gráfico de Pareto: ordenar clientes por ventas descendente, acumular hasta el 80% del total. Los que entran en ese 80% son los 'más valiosos'.                      |
| Reporte 13: Tendencia bebidas Diet                   | Filtrar por is_diet = TRUE, agrupar por año/mes, mostrar evolución temporal. Ver si sube o baja.                                                                    |
| Reporte 14: Consumo bebidas en lata                  | Filtrar por packaging = 'lata' o is_lata = TRUE, misma lógica temporal.                                                                                             |
| Reporte 15: Productos a discontinuar                 | Productos con ventas decrecientes en los últimos períodos o con ventas = 0 recientemente. Usar FACT_VENTAS agrupado por producto y período.                         |
| Reporte 16: Stock por producto/rubro                 | Usar FACT_STOCK. Evolución de stock_actual a lo largo del tiempo por DIM_PROD y categoría.                                                                          |
| Reporte 17: Clientes más valiosos en el tiempo       | Combinar Pareto con análisis temporal: clientes con mayor total histórico de compras, su evolución año a año.                                                       |

## 6. Preguntas frecuentes del jurado — con respuestas

### Sobre el modelo dimensional

|                                                         |                                                                                                                                                                                                                                                           |
|---------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| ¿Por qué eligieron esquema estrella y no copo de nieve? | El esquema estrella es más performante para consultas analíticas porque requiere menos JOINS. El copo de nieve normaliza las dimensiones pero complica las queries. Para un DW orientado a reportes en Power BI, el estrella es la opción estándar.       |
| ¿Qué es el grano de FACT_VENTAS?                        | Una fila por línea de factura — es decir, un producto dentro de una venta. Elegimos este grano porque es el nivel más detallado y permite responder todas las consultas, desde agregados totales hasta análisis por producto individual.                  |
| ¿Por qué unificaron DIM_CUSTOMER en una tabla?          | Para simplificar todas las consultas de segmentación. Con un atributo 'tipo' (retail/wholesale) podemos filtrar por tipo o analizar ambos juntos. Tener dos tablas separadas obligaría a hacer UNION ALL en cada consulta o tener dos FKs en FACT_VENTAS. |
| ¿Para qué sirve DIM_DISCOUNT?                           | Modela los descuentos disponibles con su lógica de aplicación. Permite analizar qué descuentos se aplicaron más, en qué períodos, y su impacto en el precio final.                                                                                        |
| ¿Por qué la edad está en FACT y no en DIM_CUSTOMER?     | Porque la edad es dependiente del tiempo: la misma persona tiene distinta edad en 2007 que en 2010. Al ponerla en FACT, la calculamos al momento de la venta, que es lo correcto analíticamente.                                                          |

### Sobre el ETL

|                                                                                                 |                                                                                                                                                                                                                                                                                                                          |
|-------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| ¿Cómo resolvieron la integración de dos bases de datos tan distintas (SQL Server 2000 y MySQL)? | Conectamos ambas como fuentes independientes en SSIS: la SQL Server via OLE DB y la MySQL via driver ODBC. El ETL extrae de ambas, aplica las transformaciones necesarias y carga todo en el DW. La diferencia principal es que las ventas históricas no tienen precio propio, entonces lo cruzamos con PRICES de MySQL. |
| ¿Cómo calcularon el descuento correcto?                                                         | Con una lógica en el ETL: para cada factura, filtramos los descuentos de la tabla DISCOUNTS que estén vigentes en la fecha de la venta y cuyo total_billing sea menor o igual al monto de la factura. Si hay varios, nos quedamos con el de mayor porcentaje.                                                            |
| ¿Qué estrategia de carga usaron: truncate-and-load o incremental?                               | Truncate-and-load: vaciamos las tablas del DW y recargamos todo. Para el volumen de datos de este TP es la estrategia más simple y confiable. La carga incremental sería necesaria en producción real con millones de registros.                                                                                         |
| ¿Por qué tuvieron que corregir el encoding de los XML?                                          | Los archivos XML de clientes venían con encoding no estándar que SSIS no interpretaba correctamente por defecto. Tuvimos que especificar el encoding correcto en la configuración del XML Source para que los caracteres especiales se procesaran bien.                                                                  |

### Sobre Power BI

|                                                      |                                                                                                                                                                                                                                                                                        |
|------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| ¿Cómo hicieron la proyección de ventas para Q1 2011? | Power BI tiene funcionalidad de pronóstico nativa en los gráficos de línea. Con la serie histórica de ventas mensuales, activamos el forecast para proyectar los meses siguientes con intervalo de confianza. También es válido mencionar regresión lineal sobre los datos históricos. |
| ¿Cómo implementaron el análisis de Pareto?           | Ordenamos los clientes minoristas por monto total de ventas en forma descendente y calculamos el porcentaje acumulado. El principio de Pareto dice que el 20% de los clientes genera el 80% de las ventas. En Power BI esto se implementa con una medida DAX de porcentaje acumulado.  |
| ¿Qué es una medida DAX?                              | DAX (Data Analysis Expressions) es el lenguaje de fórmulas de Power BI. Una medida es una fórmula que se calcula en contexto de filtro — por ejemplo, CALCULATE(SUM(ventas), FILTER(...)) para calcular ventas bajo ciertas condiciones.                                               |

## 7. Resumen para repasar en 5 minutos

### El modelo en una oración por tabla

- una fila = un producto vendido en una factura. Métricas: cantidad, precio, litros, descuento, ganancia. FACT\_VENTAS:
- una fila = movimiento de stock de un producto en una fecha. FACT\_STOCK:
- una fila = una fecha, con todos sus atributos (día, mes, año, feriado, etc.) DIM\_TIME:
- un cliente (retail o wholesale) con tipo como discriminador. DIM\_CUSTOMER:
- un empleado con sus atributos de RRHH. DIM\_EMPLOYEE:
- un producto con categoría, presentación, capacidad\_ml, is\_diet. DIM\_PROD:
- una combinación región-estado-zipcode. DIM\_GEO:
- un descuento disponible con su lógica de aplicación. DIM\_DISCOUNT:

### Las 3 decisiones de diseño más importantes

- DIM\_CUSTOMER unificada (no dos tablas) → simplifica todas las consultas de segmentación. 1.
- Edad y antigüedad en FACT\_VENTAS (no en DIM) → porque son dependientes del momento de la venta. 2.
- Grano de línea de factura (no de factura completa) → máximo detalle para análisis por producto. 3.

### El flujo del ETL en 30 segundos

🗨 *Primero levantamos todas las fuentes: SQL Server, MySQL via ODBC, dos XML, dos Excel y tres TXT. Transformamos: corregimos encoding, calculamos litros, edades, antigüedad y aplicamos la lógica de descuentos. Cargamos: primero las seis dimensiones, después las dos tablas de hechos. Todo en un único paquete SSIS llamado Package.dtsx.*

**¡Buena suerte en la defensa!**

Federico Winter · TUIA 2026