UNIDAD 1 – Introducción a DataWarehouse

Introducción a DataWarehouse El objetivo principal de esta unidad es entender cómo las organizaciones satisfacen sus necesidades de información, reconocer los problemas típicos al trabajar con datos, comprender los **conceptos básicos de Data Warehousing** y las metodologías para la construcción de una solución orientada a la toma de decisiones.

Conceptos, motivación y marco histórico

Para hablar de lo mismo…

- **Datos:** Son las **partículas de conocimiento** o el reflejo de instancias y realidades que ya sucedieron.
- **Información:** Es un conjunto de **datos que interesan a un observador** en particular para un fin y circunstancia determinados.
- **Conocimiento:** Es una mezcla de experiencia, valores e información que es **útil para la acción**. El conocimiento se deriva de la información a través de la comparación, predicción y conexiones.

Evolución de Plataformas de TI y de los Sistemas de Información Las plataformas tecnológicas evolucionaron de los grandes Mainframes (1959) a la actual Computación en la Nube y Móvil. A su vez, los Sistemas de Información (conjuntos orientados al tratamiento de datos para lograr objetivos de la empresa) pasaron del mero Procesamiento de Datos en 1950, hacia herramientas de Reportes Gerenciales, Soporte a Decisiones y finalmente hacia la Inteligencia de Negocios (BI) y **Ciencia de Datos** en la actualidad.

- **Previo a la IT y Con IT:** La recolección era manual y el procesamiento aislado.
- **Modelo Superador (Con DW):** Se logra el **almacenamiento automático, periódico y centralizado**, alimentando la emisión, distribución y publicación de información desde una fuente única.

Éxito y Fracaso de los Sistemas de Información Los sistemas suelen fracasar por la **falta de alineación con la estrategia empresarial**, el escaso apoyo de la alta administración, una mala identificación de las necesidades de información, el poco involucramiento del usuario final y la falta de formación del personal. Además, generar muchos datos no asegura tener información: **"Una organización puede ser rica en datos, pero será pobre en información"** si no sabe resumirlos e identificarlos.

Datos e Información - Problemas Frecuentes

- **Datos dispersos**, duplicados e inconsistentes en distintas plataformas.
- Discrepancias en las definiciones de los conceptos dentro de la misma organización.
- Plazos de entrega incompatibles y falta de disponibilidad de los datos.
- **Altos volúmenes de datos con baja capacidad analítica** o sin perspectivas históricas para medir tendencias.
- Esto genera quejas comunes en las empresas: "Tenemos montañas de datos pero no podemos accederlos" o "El área M no comparte la información".

Utilidad y funciones

Conceptos y Definiciones

- **Data Warehousing (DWH):** Describe los **procesos necesarios para la extracción, limpieza, transformación, control y carga (ETL)** de datos en un entorno histórico e integrado. **¡Importante: No es un producto comercial!**.
- **Data Warehouse (DW):** Es una **vista consolidada o repositorio de datos categorizados**, específicamente optimizado para la consulta, reportes y toma de decisiones. El DW representa **la única fuente de la verdad corporativa** y se caracteriza por estar orientado a temas, integrado, ser

variante en el tiempo, histórico y no volátil. El DW **se construye o se adapta**, no se compra enlatado. Es el centro absoluto de la toma de decisiones, interactuando con los sistemas internos y entregando a áreas de BI o Data Science.

¿Qué "promete" DWH?

- **Única fuente (modelo) de la información** y visión compartida para toda la empresa (across-the-company) superando discrepancias y redundancias.
- Tiempos mínimos de entrega y alta performance para el análisis.
- Posibilidad de definir **métricas e indicadores clave de performance (KPI)** separando el mundo operativo de la gestión del negocio.

Principios a Considerar al Diseñar un DataWarehouse

- Tener el **foco puesto en los objetivos del negocio** y empezar el diseño con "el fin en mente".
- **Pensar y diseñar un todo, pero construir de a poco** mediante entregas incrementales.
- Construir basándose en datos atómicos y **sumarizar solo al final**.
- Construir la **Metadata** (datos que explican los datos) al mismo tiempo que se analiza y construye.

Ventajas y Desventajas de Implementar un DW

- **Ventajas:** Acceso **rápido y centralizado**, información coherente, menor tiempo para reportes y gran facilidad para **análisis de tendencias (histórico)**.
- **Desventajas:** Alta complejidad, no maneja bien datos "no estructurados", es difícil adaptar o cambiar el esquema posteriormente y **requiere una alta inversión inicial de tiempo y dinero**.

Generación y construcción de DW: ETL

La construcción se divide en tres grandes etapas:

1. **Diseño:** Considerar requerimientos, definir el tipo de solución (EDW, DM, ODS), elegir la arquitectura metodológica (Top-Down o Bottom-Up) e identificar orígenes (extracción, limpieza e integración).
2. **Construcción:** Definir tecnologías, detectar cambios (Log/CDC/Timestamp) y crear los procesos de **ETL o ELT** (carga inicial y periódica).
3. **Explotación:** Construir reportes y Tableros/KPI, monitorear la performance y **validar la calidad de los datos**.

Arquitecturas de DW Existen dos enfoques primordiales y elementos genéricos:

- **Bill Inmon (Top-Down):** Enfoque basado en un **Modelo Relacional Normalizado y atómico**. Postula la "Corporate Information Factory" (CIF) donde los datos fluyen primero a un DW centralizado e integrado, y luego derivan en Datamarts departamentales o usos analíticos.
- **Ralph Kimball (Bottom-up):** Enfoque basado en el **Modelo Dimensional**. Su "DataWarehouse Dimensional" se nutre desde los Datamarts que se unen en una arquitectura central lógica llamada **"DW Bus" con dimensiones conformadas compartidas**.
- **Componentes en común:** Ambas utilizan procesos ETL, un repositorio de información integrado, un área de staging (transitoria para la limpieza de los datos) y herramientas de acceso o explotación de datos (BI).

Tipos de DataWarehouse

1. **Enterprise DataWarehouse (EDW):** Es el almacén **global**. Orientado a las decisiones estratégicas a nivel **de toda la organización**. Integra información histórica y estructurada de todas las áreas (y fuentes externas).

2. **DataMart (DM):** Es un almacén **departamental**. Se centra en un área temática específica (Ventas, Finanzas, RRHH). **Mitos frecuentes:** No siempre son pequeños, ni son más rápidos o fáciles de hacer que un EDW. A menudo implican datos redundantes y arquitecturas fragmentadas si no se controlan.
3. **Operational Data Store (ODS):** Es un almacenamiento enfocado en la toma de decisiones **tácticas y operativas a muy corto plazo**. Refleja información reciente (casi en tiempo real) y se sobrescribe frecuentemente. Suele ser el paso intermedio entre las fuentes y el DW principal.
4. **Base de Datos Híbrida o DW Virtual:** Uso de motores (como almacenamiento In-Memory o Columnar) para consultar de forma analítica directo en la base de transacciones (OLTP) sin perjudicar el sistema. Sin embargo, su limitación es clara: **"Si no hay ETL ni repositorio de destino, no hay un verdadero DW"**.

Comparativa con Bases de Datos Relacionales

El DW y las Bases de Datos Relacionales (OLTP) son sistemas distintos:

- **Propósito:** El DW es para **Análisis de Datos (Data Out / OLAP)** mientras que las DB Relacionales son para **Registro (Data In / OLTP)**.
- **Datos:** El DW guarda datos **históricos y sumarizados**; las DB guardan el estado actual y volátil.
- **Transacciones y Usuarios:** El DW utiliza **cargas masivas periódicas** (ETL) y es usado por gerencia para reportes complejos. Las DB Relacionales operan con **transacciones atómicas continuas (alta disponibilidad 24x7)** y las utiliza el público general.
- **Diseño (Modelos DW vs Relacional):**
    - **Modelo Star (Estrella):** Orientado al DW. Está **no normalizado**, tiene alta redundancia pero **la complejidad de las consultas es baja y su performance muy alta**. Requiere más espacio.
    - **Modelo Snowflake (Copo de Nieve):** Más **normalizado**, con **baja redundancia**. Ahorra espacio de almacenamiento, pero la complejidad de las consultas es media-alta, disminuyendo la facilidad de diseño

UNIDAD 2 – OLAP

1. Introducción

Los sistemas **OLAP (Procesamiento Analítico en Línea)** son bases de datos **optimizadas para Data Warehouse** que facilitan **consultas de inteligencia empresarial** útiles para el negocio. Generalmente se crean a partir de bases de datos relacionales y tienen la capacidad de **procesar y generar respuestas rápidamente** a través de **estructuras multidimensionales (cubos de datos)**.

Sus principios fundamentales son:

- **Lenguaje y visión de Negocio:** El modelo debe responder preguntas y facilitar el análisis de la manera en que el usuario reconoce su estructura.
- **Jerarquías:** Las aristas de análisis suelen estar asociadas jerárquicamente.
- **Escasez (Sparcity):** Es frecuente encontrar combinaciones vacías dentro de estos modelos.

Mediciones y Dimensiones: Para OLAP, "lo que no se define, no se puede medir", y lo que no se mide no se puede mejorar. Las mediciones identifican valores para **evaluar, medir o comparar** (ventas, costos), y están **determinadas por las Dimensiones** (contexto). El conjunto de dimensiones y medidas en una matriz multidimensional representa un **Modelo de Negocio**.

- **Medidas Aditivas:** Se pueden **sumar (agregar) de manera uniforme** en todas las dimensiones (Ej: unidades vendidas, monto facturado).

- **Medidas Semi-aditivas:** Se suman, pero **no para todas las dimensiones** (generalmente no se suman en la dimensión temporal). (Ej: stock, saldos).
- **Medidas No Aditivas: No se suman** en los distintos niveles (Ej: índices, tasas, porcentajes, precios).

El **Tiempo es una dimensión más** y maneja la periodicidad (desde/hasta, YTD, MTD). Las **Dimensiones** son elementos del negocio usados como **filtros o atributos para agrupar totales**. Poseen jerarquías:

- **Nivel Simple:** Varios miembros a un solo elemento superior.
- **Nivel Alterno:** Un elemento va a más de un elemento de dos dimensiones distintas.
- **Nivel Múltiple:** Un elemento se relaciona con más de un concepto simultáneamente de abajo hacia arriba.
- **Nivel Irregular (Ragged):** Estructuras no balanceadas.

2. Bases de Datos Multidimensionales. Cubos e Hipercubos.

Ventajas y Desventajas: Tienen **gran rendimiento**, acceso a **grandes cantidades de información**, establecen relaciones complejas e involucran **datos agregados y cálculos complejos**. Sus desventajas son la **imposibilidad de realizar cambios, baja flexibilidad, baja escalabilidad y limitado alcance del diseño**.

Operaciones OLAP:

- **Consolidación:** Comprende conjuntos de datos con acumulaciones/agrupaciones.
- **Drill-Down:** Permite seleccionar un valor acumulado y **desglosarlo a un nivel mayor de detalle**.
- **Slicing and Dicing:** Capacidad de visualizar datos desde distintos puntos de vista, **rotando o cambiando niveles de agrupación rápidamente**.

Modelo Dimensional - Conceptos y Metodología: Consiste en diseñar un modelo a partir de BD transaccionales. Sus componentes son:

- **Hechos:** Colección de **medidas o métricas** representadas por llaves de dimensión. Representan transacciones o eventos del negocio (ej. una venta).
- **Dimensiones:** Elementos cualitativos usados para **categorizar o restringir los hechos**. Existen aunque no haya hechos (ej. Clientes, Sucursales).

Consideraciones metodológicas: Se debe **centrar en el negocio**, entregar incrementos significativos y ofrecer una solución integral. Los pasos para diseñarlo son:

1. **Elegir el proceso de negocio.**
2. **Establecer la granularidad** (nivel de detalle).
3. **Determinar las Dimensiones.**
4. **Determinar los Hechos y Medidas**.

Modelos de Datos:

- **Esquema Estrella (Star):** Una tabla de hechos central rodeada de dimensiones desnormalizadas.
- **Esquema Copo de Nieve (Snowflake):** Similar a la estrella, pero las dimensiones están normalizadas (ej. Ciudad se separa de Zona).
- **Esquema Constelación:** Múltiples tablas de hechos unidas por dimensiones compartidas.
- **Tabla "Factless":** Tabla de hechos particular sin métricas explícitas, usada solo con contadores.

Dimensiones Conformadas y Matriz Bus: Para que los modelos sean integrables, es crucial utilizar **dimensiones conformadas** (una única tabla de dimensión que sirve a varias tablas de hechos de manera

coherente). Para priorizar proyectos y visualizar esto, se usa la **Matriz en Bus (Kimball)**, cruzando procesos de negocio (filas) con dimensiones (columnas).

A nivel físico, requiere documentación exhaustiva y consideraciones de **escalabilidad**. Agregar atributos y medidas nuevas es manejable, pero **cambiar la granularidad de una dimensión implica eliminar y reconstruir la tabla de hechos por completo**.

3. Análisis Multidimensional. MOLAP, ROLAP, HOLAP.

- **ROLAP (Relacional):** Los datos están normalizados en una base de datos relacional.
    - *Ventajas:* Escalable para **grandes volúmenes**, aprovecha la seguridad de la BD y permite datos/estructuras dinámicas.
    - *Desventajas:* **Consultas más lentas** (usa SQL y debe procesar combinaciones agrupando datos con GROUP BY), construcción cara y cálculos limitados a funciones de la base de datos.
- **MOLAP (Multidimensional):** Los datos se almacenan físicamente en una estructura multidimensional.
    - *Ventajas:* **Mayor desempeño** en procesamiento, permite realizar **cálculos mucho más complicados** y pre-calcula/mantiene actualizadas las combinaciones automáticamente.
    - *Desventajas:* **Tamaño limitado** por la arquitectura del cubo, no se pueden usar datos fuera de él y no explota el paralelismo de las BD relacionales.
- **HOLAP (Híbrido):** Es la suma de ROLAP + MOLAP. **Mantiene los registros detallados en BD relacionales** y los datos resumidos o agregados en BD multidimensionales.

4. Ejemplos prácticos.

En ROLAP, las consultas se ejecutan con sentencias relacionales estándar (SELECT, SUM(), JOIN, GROUP BY) que se vuelven más complejas a medida que se suman más dimensiones. Por otro lado, en MOLAP se pueden hacer consultas nativas a un **cubo multidimensional** usando lenguajes como MDX (SELECT ... on columns ... on rows FROM [Cubo]) a través de herramientas especializadas (ej. Analysis Services de SQL Server).

5. Diferencias OLAP y Data Warehouse.

El enfoque de OLAP está **basado 100% en las necesidades de análisis** y en el proceso de toma de decisiones del usuario, dándole **prioridad absoluta a la visualización de métricas, indicadores y ratios**.

OLTP vs Data Warehouse / OLAP:

- **OLTP (Operacional):** Ejecuta transacciones del día a día, sirve a **muchos usuarios**, BD normalizada de **menor tamaño (Gigabytes)**, de actualización actual y continua, con consultas predecibles.
- **Data Warehouse / OLAP:** Organizado en conceptos (temático), **bajo número de usuarios**, **consultas Ad Hoc que pueden demorar minutos** (analíticas), BD desnormalizada de **mayor tamaño (Gigabytes a Terabytes)**, con actualización histórica o en batch y que sufre constantes cambios evolutivos

UNIDAD 3 – Explotación de datos

1. Introducción a Data Lakes - DW

- **Datawarehouse (DW):** Es una gran colección de datos procedentes de **diversas fuentes** reunidos en un **único almacén homogéneo**. Extraen datos de sistemas transaccionales (OLTP), los limpian e importan, y están diseñados específicamente para el **análisis de grandes cantidades de datos estructurados**.

- **Data Lake:** Almacena datos a escala en su **formato nativo (sin procesar, estructurados o desestructurados)**. Los datos se añaden **"como están"**, sin formatearse, siendo fundamentales para que la información esté disponible para **sistemas de IA, Machine Learning (ML) y análisis de Big Data**.
- **Data Lake House:** Es una arquitectura nueva que combina la **flexibilidad y escalabilidad de un lago de datos** con las **estructuras y gestión de un datawarehouse**. Esto brinda agilidad a los equipos de data science y garantiza que dispongan de los datos **más completos y actualizados** sin acceder a varios sistemas a la vez.

2. Técnicas de DM y descubrimiento de conocimiento

- **Data Mining (DM):** Herramientas que **predicen tendencias y comportamientos** para descubrir información relevante mediante técnicas que **buscan patrones ocultos**.
- **Proceso de DM (6 pasos):** 1. Definición del problema, 2. Preparación de datos, 3. Explorar los datos, 4. Creación de modelos, 5. Exploración y validación de modelos, 6. Implementar y actualizar los modelos.
- **Técnicas principales:**
    - **Redes neuronales artificiales:** Radica en el aprendizaje secuencial, el uso de transformaciones para la predicción y la **no linealidad del modelo**.
    - **Árboles de decisión:** Permiten obtener **de forma visual las reglas de decisión** bajo las que operan los consumidores a partir de datos históricos.
    - **Agrupamiento (Clustering):** Agrupa observaciones en clusters o grupos, basándose estrictamente en la idea de **similitud de los grupos**.
    - **Algoritmo Jerárquico:** Calcula la distancia entre pares de clusters, **junta los dos más cercanos** y repite el proceso hasta que no queden pares.
    - **Regla de Inducción:** Deriva un conjunto de **reglas independientes para clasificar casos**, contrastando patrones a partir de los datos de entrada.

3. Business Intelligence (BI)

Conceptos y Definiciones

- Se define como la **transformación de los datos de la compañía en conocimiento para obtener una ventaja competitiva**.
- Consiste en analizar datos para conocer las actividades y oportunidades de la empresa, y en el conjunto de tecnologías que soportan este análisis para **tomar mejores decisiones de negocio**.
- Evoluciona a partir de los DSS y permite minería de datos, reporting, modelo de escenarios, tableros y visualización de datos.

Necesidades según Rol

- **Ejecutiva/Director:** Foco en **todas las áreas** pero con **poco detalle** (solo por excepción). Necesita indicadores, semáforos y alertas.
- **Departamental/Gerente:** Foco en **su área**. Requiere reportes de evolución, historia completa de libre acceso, iteración fácil y análisis multidimensional.
- **Operativa/Supervisor:** Visión **minuto a minuto** con **poca historia** (casi on-line). Utiliza consultas pre-armadas y reportes pre-calculados.

Tipos de Uso

Existen diferentes niveles de complejidad en su uso: 1. Minería de datos y análisis estadísticos, 2. Consultas a la medida, 3. Análisis de cubos, 4. Reportes empresariales, y 5. Alertas y reportes.

Diferencias entre BI y BA (Business Analytics)

- **BI (Inteligencia de negocios):** Se centra en el **pasado** (datos históricos), la eficiencia operativa y **responde al ¿Qué? y ¿Cómo?**.
- **BA (Analítica de negocio):** Se enfoca en el **futuro**, la innovación, la planeación mediante algoritmos y **responde al ¿Por qué?**.

Ecosistema de BI

- **Sistemas Empresariales:** Sistemas con los datos de la operación diaria de donde se extrae la información. Realizan **transacciones** y usan SQL.
- **Extracción y Filtrado (ETL):** Procesos para integrar, **formatear y limpiar** datos de distintas fuentes.
- **Explotación:** Repositorio central donde se ejecutan las **reglas de negocio**. Organizan datos de forma granular en tablas de hechos y dimensiones.
- **Aristas de Explotación (OLAP/Data Mart):** Permiten ver **diferentes vistas** de los datos por área de negocio o arista.
- **Visualización:** Representación de los datos en **tableros de control** para dar visibilidad y ayudar a la toma de decisiones.

Beneficios Esperados y Modelo de Madurez

- Los beneficios impactan en lo **Organizacional** (Dashboards focalizados), en **Procesos** (KPIs), en **Personas** (Optimización de RRHH) y en **Tecnología** (Gobernabilidad de datos).
- El **Modelo de Madurez** avanza en etapas: 1. Informes, 2. Data Warehouse, 3. Explotación de datos, 4. Cuadros de mando integral, 5. Minería de datos.
- **Conclusión:** Una plataforma de BI no es solo tecnología, requiere que **datos, procesos y personas se interrelacionen** como capacidades focalizadas en el negocio.

4. Motivación y aplicabilidad de BI

- Nace para solucionar problemas como el manejo de información interna con **poca fluidez**, documentos **no integrados**, existencia de **silos de información** aislados, y la falta de visibilidad integral de la información clave para la toma de decisiones.

5. Curado de Datos

- **Valor y Riesgo:** El curado busca **aumentar el valor de los datos** y reducir los riesgos y **costos innecesarios** asociados a la mala calidad de información.
- **Eficiencia, Productividad y Reputación:** Tomar decisiones sobre datos "verdaderos" mejora la eficiencia, mientras que usar datos malos afecta severamente la **imagen de la organización**.
- **Prevención y Causa Raíz:** El enfoque correcto es **prevenir errores desde la causa raíz**, no simplemente corregir síntomas o registros erróneos.

Conceptos Esenciales

- **Data Quality (Calidad de datos):** Un dato de alta calidad **satisface las expectativas y necesidades** de quien lo consume. Los desafíos principales son que las expectativas a veces no se conocen y los requisitos cambian con el tiempo.
- **Datos Críticos:** No todos los datos importan igual; los esfuerzos deben centrarse en aquellos con un **impacto directo y medible en el negocio** (como los Master Data).
- **Objetividad:** La calidad debe medirse de forma **objetiva y coherente** compartiendo la metodología con los interesados.
- La calidad de datos abarca factores inherentes (exactitud, completitud, consistencia, credibilidad) y dependientes del sistema (accesibilidad, trazabilidad, disponibilidad, etc.).

6. Tableros de Control

- Son soluciones de gestión de información diseñadas para analizar y **visualizar información de comportamiento y transacciones de forma fácilmente comprensible**. Reúnen gran cantidad de números en indicadores gráficos **altamente condensados**.

Balanced Scorecard (Cuadro de Mando Integral)

- Es una metodología (presentada por Kaplan & Norton) que hace hincapié en una **visión más balanceada de la organización**, sin poner el foco únicamente en la parte financiera.
- Define el alcance de **todo lo que una organización debe MEDIR** para asegurar su éxito. Propone analizar la empresa desde **cuatro perspectivas**:
    1. **Perspectiva Financiera:** Indicadores de gestión financiera como **inversiones y rentabilidad**.
    2. **Perspectiva del Cliente:** Datos relevantes para **identificar, generar, atraer y fidelizar** a los clientes frente al mercado.
    3. **Perspectiva Interna:** Identifica los **procesos y actores internos** que generan iniciativas vitales para la salud de la empresa.
    4. **Perspectiva de Aprendizaje y Crecimiento:** Es la más importante a futuro; refleja la proyección de la organización a través del **clima organizacional y su infraestructura humana/sistemática**