

GUÍA DE ESTUDIO: FUNDAMENTOS DE CIENCIA DE DATOS

INTRODUCCIÓN

El objetivo general de los temas cubiertos en estas diapositivas es brindarte las herramientas fundamentales para que puedas tomar un conjunto de datos crudos y transformarlo en información valiosa. Esto implica aprender a explorar y resumir los datos (Análisis Exploratorio), representarlos gráficamente para encontrar patrones (Visualizaciones), prepararlos para que los algoritmos los entiendan mejor (Transformación y Escalado), y finalmente, construir representaciones matemáticas simplificadas de la realidad para hacer inferencias y predicciones (Ajustes y Modelos de Regresión Lineal).

DESARROLLO DE LOS TEMAS

TEMA 1: ANÁLISIS EXPLORATORIO Y MEDIDAS DE RESUMEN

Definición: El análisis exploratorio permite describir la información contenida en un dataset. Los datos provienen de "variables", que son características observables. Pueden ser cualitativas (no medibles numéricamente) o cuantitativas (continuas o discretas). Para resumir estos datos usamos medidas de posición (media, mediana, cuartiles, moda) que indican dónde se localizan los datos, y medidas de dispersión (rango, variancia, desvío estándar, rango intercuartil, MAD) que describen su variabilidad. Para evaluar cómo varían conjuntamente dos variables, usamos métricas de correlación como la covariancia y los coeficientes de Pearson y Spearman.

Importancia: Es el primer paso crítico en Ciencia de Datos. Sin un buen resumen estadístico, no podemos entender nuestros datos, detectar errores o identificar valores atípicos (outliers) que arruinarían modelos futuros.

Conceptos relacionados: Se conecta directamente con la Transformación de Datos y la Regresión Lineal. Por ejemplo, detectar falta de linealidad mediante la correlación nos dirá si es apropiado ajustar un modelo lineal.

Ejemplos prácticos: Si mides la altura de tus amigos, la Media Aritmética es sumar todas las alturas y dividir por la cantidad de amigos. Si uno mide 2.40 metros (un outlier), la media se verá muy afectada. En ese caso, conviene usar la Mediana, que es simplemente el valor que queda en el medio si los ordenas de menor a mayor.

Aplicaciones reales: Calcular el ingreso total promedio de los hogares (media) o el ingreso típico (mediana) para evaluar políticas públicas.

Errores o confusiones comunes:

- Asumir que "correlación implica causalidad". Que dos variables se muevan juntas no significa que una cause la otra.
- Calcular el coeficiente de Pearson para relaciones no lineales. Pearson solo mide asociación lineal.
- Eliminar outliers automáticamente. Un outlier puede ser un error de carga, pero también puede ser un fenómeno real y valioso.

Cómo puede aparecer en un examen: Se te puede pedir que analices qué medida de tendencia central es mejor si los datos son asimétricos (respuesta: la mediana), o que elijas entre Pearson y Spearman (Spearman es mejor si hay outliers o la relación es monótona pero no lineal).

TEMA 2: VISUALIZACIÓN DE DATOS Y GEODESIA

Definición: La visualización es la representación gráfica de información para detectar tendencias y patrones. Para una variable, usamos gráficos de bastones, histogramas o gráficos de densidad. Para dos cuantitativas, diagramas de dispersión (scatterplots). Para categóricas, gráficos de barras o sectores (pie charts). Además, se incluyen los datos georreferenciados, que requieren entender la Geodesia (la ciencia que estudia la forma de la Tierra). La Tierra se modela matemáticamente como un elipsoide o físicamente como un geoide.

Importancia: Las estadísticas no cuentan toda la historia (como lo demuestra el "Datasaurus Dozen"); necesitamos ver los datos. En los datos espaciales, usar el sistema de coordenadas de referencia (CRS) y proyecciones cartográficas correctas es vital para no distorsionar mapas.

Conceptos relacionados: Se relaciona fuertemente con la detección de "Red Flags" en regresión lineal, ya que los gráficos de dispersión y de residuos son visualizaciones esenciales.

Ejemplos prácticos: Hacer un "boxplot" (diagrama de caja) de los salarios de una empresa. La caja representa el 50% central de los datos (Rango Inter cuartil) y los "bigotes" se extienden hasta los valores típicos. Los puntos que quedan sueltos afuera son potenciales outliers.

Aplicaciones reales: Crear un mapa "Choropleth" coloreando las provincias de Argentina según su superficie cultivada usando bibliotecas como GeoPandas o Folium.

Errores o confusiones comunes:

- Confundir un histograma con un gráfico de barras. El histograma agrupa datos cuantitativos continuos en subintervalos (bins), mientras que el de barras representa categorías de variables cualitativas.
- La trampa de los gráficos de densidad: tienden a "dibujar" datos donde no existen, especialmente en las colas (ejemplo: mostrar edades negativas). Se soluciona cortando los límites del eje.

Cómo puede aparecer en un examen: Se te pedirá que generes un gráfico que verifique la distribución o simetría de una variable (como el Índice de Masa Corporal) o que compares distribuciones en función de otra categoría usando boxplots paralelos o ridge plots.

TEMA 3: TRANSFORMACIÓN Y ESCALADO DE DATOS

Definición: Es el proceso de modificar los datos para mejorar el rendimiento de los algoritmos.

Incluye:

- Dicotomización: Convertir variable continua en binaria (ej: menor de edad / mayor de edad).
- Binning: Agrupar en múltiples categorías (ej: rangos etarios).
- Encoding (Codificación): Convertir variables cualitativas en numéricas (One-Hot Encoding con 0 y 1, o Ordinal Encoding).
- Escalado (Scaling): Ajustar las escalas de las variables para que varíen en rangos comparables. Ejemplos: Z-score (escalado estándar), Min-Max.
- Transformación Logarítmica: Comprime la cola superior de distribuciones asimétricas para hacerlas más simétricas.

Importancia: Los algoritmos de Machine Learning no entienden palabras, solo números. Además, si una variable varía entre 0 y 1, y otra entre 0 y 1.000.000, el modelo le dará erróneamente más importancia a la segunda. El escalado lo soluciona.

Conceptos relacionados: One-Hot Encoding tiene una relación directa con la regresión múltiple, ya que genera la necesidad de variables "Dummy".

Ejemplos prácticos: Tienes una variable categórica "Ciudad" con niveles: Rosario, Funes, Roldán. Con One-Hot Encoding, creas tres columnas nuevas con unos y ceros indicando la presencia de la ciudad.

Aplicaciones reales: Predecir la popularidad de un artículo. Si el número de palabras está sesgado (la mayoría son cortos, pocos son larguísimos), aplicar logaritmo hace la distribución más normal y mejora el modelo predictivo.

Errores o confusiones comunes:

- La trampa de la variable Dummy (Dummy Variable Trap): si hay N categorías, debes usar N-1 variables en el modelo para evitar multicolinealidad perfecta.
- Usar Ordinal Encoding para variables sin un orden real (como nombres de ciudades). Solo debe usarse cuando hay jerarquía (ej: Pequeño, Mediano, Grande).
- Usar Min-Max o Z-score cuando hay outliers muy extremos; en ese caso se debe preferir el Escalado Robusto, que usa la mediana y el rango intercuartil.

Cómo puede aparecer en un examen: Te pueden pedir directamente que "dicotomices" una variable a partir de un valor de corte (ej: fumar 0 cigarrillos vs fumar 1 o más) para luego usarla en gráficos y modelos.

TEMA 4: MODELOS DE REGRESIÓN LINEAL (SIMPLE Y MÚLTIPLE)

Definición: El análisis de regresión permite modelar matemáticamente el comportamiento de una variable respuesta (Y) a partir de variables predictoras (X). Si es una sola X, es Regresión Lineal Simple; si son varias, es Múltiple. El modelo asume que existe una relación de tipo $Y = b_0 + b_1 \cdot X + \text{error}$.

Importancia: Sirve para dos cosas fundamentales: Inferencia (entender cómo y cuánto afecta X a Y) y Predicción (adivinar Y para nuevos datos de X).

Conceptos relacionados:

- Mínimos Cuadrados (OLS): Método matemático para encontrar los coeficientes b_0 y b_1 que minimizan la suma de los residuos al cuadrado (SCError).
- Residuos: La diferencia entre el valor real observado y el valor predicho por el modelo.
- P-value (Valor p): En inferencia, se usa un ensayo de hipótesis para saber si una variable X realmente aporta al modelo. Si $p\text{-value} < 0.05$, rechazamos la Hipótesis Nula (H_0) y concluimos que el predictor SÍ está asociado a Y.
- R^2 y R^2 Ajustado: Miden qué proporción de la variabilidad de Y es explicada por el modelo (de 0 a 1). En regresión múltiple siempre se debe usar el R^2 Ajustado, porque penaliza la inclusión de variables basura.

Ejemplos prácticos: Predecir la masa corporal de un pingüino (Y) a partir del largo de su aleta (X_1) y su sexo (X_2). El coeficiente b_1 indicará cuánto aumenta en promedio la masa por cada milímetro extra de aleta.

Aplicaciones reales: Modelar el precio de una propiedad en función de su superficie, tasa de criminalidad y distancia al río.

Errores o confusiones comunes:

- Creer que el P-value es la probabilidad de que la hipótesis nula sea verdadera. ¡Falso! Es la probabilidad de observar nuestros datos ASUMIENDO que la hipótesis nula es verdadera.
- Ignorar las "Red Flags" (alertas rojas) del modelo lineal: asumir linealidad cuando hay una curva, ignorar la falta de normalidad de los residuos (verificable con Q-Q plots), pasar por alto la Heterocedasticidad (variancia no constante, forma de embudo), no analizar outliers o ignorar la multicolinealidad.

Cómo puede aparecer en un examen: Suele ser el núcleo del examen. Te darán un dataset y te pedirán que ajustes un modelo múltiple, analices los p-values para quitar variables no significativas (reducción del modelo), escribas la ecuación final, interpretes un coeficiente b_1 , hagas una predicción para un caso concreto y grafiques los residuos.

RELACIÓN CON EL EXAMEN DE MUESTRA

Analizando el documento de examen (MODELOEXAMEN_FDCCD.pdf), el parcial integrador evalúa tu capacidad para conectar todos los temas de la materia de forma práctica.

1. Qué temas aparecen:
2. Limpieza y transformación de datos (crear la variable IMC, Dicotomizar la variable fumadora).
3. Análisis Exploratorio y Visualización (Evaluar simetría mediante un gráfico, graficar Y vs. categoría, evaluar asociación lineal o correlación).
4. Ajuste de Modelos (Regresión lineal múltiple, selección de variables por p-value, escritura de la ecuación matemática, interpretación de coeficientes, predicción y análisis de residuos).
5. Qué conceptos son más importantes:
6. Las transformaciones básicas (Matemáticas directas como fórmula del IMC y Dicotomización).
7. El coeficiente de correlación (Pearson) visualizado con un heatmap o scatterplots.
8. Test de hipótesis en Regresión Lineal ($p\text{-value} < 0.01$ según pide el examen) para determinar qué variables se quedan en el modelo.
9. Reducción de modelos y escritura de la Ecuación Lineal.
10. Conocimientos indispensables para aprobar:
11. Saber escribir la ecuación del modelo: Predicción = Intercepto(b_0) + b_1X_1 + b_2X_2 ...
12. Saber interpretar " b_1 ": "Por cada unidad extra de X, Y aumenta en promedio b_1 unidades, manteniendo el resto constante".
13. Saber interpretar los residuos (si tienen patrón lineal, forma de embudo, o si se distribuyen de forma normal alrededor del cero).
14. Qué errores podrían hacer perder puntos:
15. No filtrar o no eliminar variables predictoras que tienen un p-value mayor al nivel de significación requerido (en el examen pide al 1%, es decir, $p > 0.01$ se descarta).

16. Interpretar mal las fórmulas en transformaciones de datos.
 17. Olvidar evaluar los residuos del modelo final.
-

PREGUNTAS TEÓRICAS POSIBLES

Pregunta 1: Has ajustado un modelo de regresión lineal y el parámetro de la variable "Semanas de gestación" tiene un p-value de 0.003. Si tu nivel de significación exigido es del 1% (0.01), ¿qué concluyes? Respuesta: Dado que el p-value (0.003) es menor al nivel de significación (0.01), existe evidencia estadística suficiente para rechazar la Hipótesis Nula (que postula que no hay relación). Por lo tanto, concluyo que la variable "Semanas de gestación" aporta significativamente al modelo y tiene relación lineal con la variable de respuesta.

Pregunta 2: Estás comparando dos modelos de regresión lineal múltiple para el mismo conjunto de datos. El Modelo A tiene 2 predictores y un R2 de 0.80. El Modelo B tiene 15 predictores y un R2 de 0.82. ¿Por qué el estadístico R2 no es confiable en este caso y qué métrica deberías utilizar?

Respuesta: El R2 nunca disminuye al agregar variables, aunque estas sean "basura" y no aporten información real, por lo que favorece falsamente a los modelos más complejos. Para comparar modelos con distinto número de predictores, se debe utilizar el "R2 Ajustado", el cual penaliza la inclusión de variables que no mejoran el ajuste genuinamente.

Pregunta 3: Un colega te muestra un gráfico de dispersión de los Residuos vs. Valores Predichos (Fitted Values). Notas que los residuos se esparcen formando un "embudo" (comienzan juntos y se abren cada vez más a medida que avanzamos en el eje horizontal). ¿Qué supuesto de la regresión lineal se está violando? Respuesta: Se está violando el supuesto de homocedasticidad. Ese patrón de embudo indica "Heterocedasticidad", es decir, los errores no tienen una varianza constante a lo largo de las observaciones. Una posible solución es transformar la variable respuesta usando una función logarítmica.

Pregunta 4: Deseas cuantificar la asociación entre dos variables cuantitativas, pero observas mediante un diagrama de dispersión que hay varios Outliers extremos. ¿Qué métrica de correlación eliges y por qué? Respuesta: Elegiría el coeficiente de correlación de Spearman en lugar del de Pearson. Spearman utiliza los "rangos" de los datos en lugar de los valores crudos, lo que lo hace mucho menos sensible a la distorsión que causan los valores atípicos (outliers).

CONCEPTOS CLAVE PARA MEMORIZAR

- Regresión Lineal: $f(X) = b_0 + b_1X_1 + b_2X_2... + \text{error}$.
 - Interpretación de b_1 : Es el cambio promedio en la variable Y ante el aumento de una unidad en X.
 - Hipótesis Nula (H_0) en regresión: Asume que $b_1 = 0$ (el predictor no tiene relación lineal con la respuesta).
 - P-value: Probabilidad de observar los datos actuales asumiendo que H_0 es verdadera.
 - Residuos: La distancia vertical entre un dato real (y_i) y la recta de predicción del modelo.
 - Outlier vs Punto Influyente: Un outlier es un valor extremo. Solo se convierte en punto "influyente" si además tiene alto "leverage" (está en una posición extrema de los predictores X) y arrastra la recta de regresión consigo.
 - Dummy Variable: Variable creada artificialmente con valores numéricos discretos (ej: 0 y 1) para poder ingresar datos cualitativos a un modelo matemático.
 - R2 ajustado: Métrica ideal para comparar modelos de regresión múltiple; penaliza la complejidad innecesaria.
 - Dicotomización: Dividir datos continuos en dos categorías mutuamente excluyentes (Ej: Fuma / No fuma).
-

CHECKLIST DE EXAMEN

Utiliza esta lista de verificación para saber si ya tienes dominio para el examen:

[] Sé importar un dataset y realizar filtros o limpieza básica de datos ausentes o nulos. [] Sé calcular operaciones matemáticas creando columnas nuevas en el dataset (ej: calcular IMC). [] Puedo aplicar "dicotomización" sobre una variable cuantitativa continua mediante reglas lógicas (ej: mayor/menor a X). [] Sé hacer gráficos de caja (boxplots) y diagramas de densidad, y puedo interpretar si una distribución es simétrica o sesgada. [] Conozco las funciones para hacer gráficos de dispersión (scatterplots) y heatmaps de correlación, identificando asociaciones fuertes. [] Sé interpretar una salida de Regresión Lineal Múltiple: leer intercepto, coeficientes, y R² ajustado. [] Sé filtrar predictores evaluando sus valores "P-value" según un nivel de significancia dado (ej: 1% o 5%). [] Puedo redactar textualmente la ecuación predictiva que surge de un modelo ajustado. [] Sé realizar una predicción matemática a mano sustituyendo las "X" por los valores que me da el problema. [] Sé realizar el gráfico de Residuos vs Valores Predichos (Fitted Values) para diagnosticar visualmente linealidad y homocedasticidad.

RESUMEN FINAL DE REPASO

La Ciencia de Datos, según los fundamentos de la materia, trata sobre hacer "hablar" a los datos. Inicias el proceso explorándolos con medidas resumen (media, mediana, desvío, variancia) y los visualizas con la herramienta gráfica que corresponda al tipo de dato (barras para categóricas, boxplots/densidad para distribuciones continuas, dispersión para analizar relaciones, mapas/geopandas para datos espaciales). Si los datos no están preparados, debes transformarlos mediante dicotomización, escalado o codificación (One-Hot). El fin último abordado es predecir comportamientos (Y) mediante Regresiones Lineales, un modelo que se basa en minimizar los errores (residuos). Para que el modelo sea válido, sus variables deben ser estadísticamente significativas (P-value bajo), su ajuste robusto (evaluado por R² Ajustado) y no se deben romper supuestos vitales como la linealidad y la homocedasticidad.

Tipo de Variable(s)	Objetivo / Contexto	Gráfico Recomendado
1 Variable Cualitativa (Categórica)	Visualizar las frecuencias o proporciones de cada categoría.	Gráfico de barras, Gráfico de sectores (Pie chart).
2 Variables Cualitativas	Evaluar la distribución conjunta o condicional entre categorías.	Gráficos de barras agrupadas/paralelas, Gráficos de barras apiladas.
1 Variable Cuantitativa Discreta (pocos valores distintos)	Visualizar cómo se distribuyen las observaciones.	Gráfico de bastones.
1 Variable Cuantitativa Continua (o discreta con muchos valores)	Visualizar la distribución, centralidad, simetría y detectar valores atípicos.	Histograma, Gráfico de densidad, Boxplot (Diagrama de caja), Violin plot.

1 Variable Cuantitativa + 1 Variable Cualitativa	Comparar cómo se distribuye una variable numérica segmentada según distintos grupos.	Boxplot múltiple, Gráficos de densidad múltiples, Strip plot (Jitter plot), Violin plot múltiple, Ridgeline plot.
2 Variables Cuantitativas	Evaluar el grado de asociación, relación o correlación entre ambas.	Gráfico de dispersión (Scatterplot).
3 Variables Cuantitativas	Visualizar la asociación de tres variables numéricas simultáneamente.	Gráfico de burbujas (Bubble chart).
Múltiples Variables Cuantitativas	Analizar patrones globales, tendencias o todas las correlaciones posibles a la vez.	Matriz de dispersión (Pairplot), Correlograma, Heatmap.
Serie de tiempo (Variable ordenada temporalmente)	Visualizar la evolución, comportamiento y tendencias a lo largo del tiempo.	Gráfico de líneas.
Datos Georreferenciados (Espaciales)	Analizar variaciones de un atributo específico en regiones geográficas exactas.	Mapas (utilizando puntos, líneas o polígonos), Mapa Choropleth.