


TRANSFORMACIÓN DE DATOS: Técnicas de escalado

UNIDAD 5 - Parte 1

Fundamentos de Ciencia de Datos 2026



EL PROBLEMA DE LAS ESCALAS

Imaginemos que estamos analizando un perfil de clientes para un estudio de mercado. Queremos encontrar **qué consumidores se “parecen” más entre sí** a partir de la información de dos variables cuantitativas:

Cliente	Edad	Salario
Cliente A	30 años	\$1500000
Cliente B	31 años	\$1530000
Cliente C	50 años	\$1500000

¿El cliente A se “parece” más al B o al C?

EL PROBLEMA DE LAS ESCALAS

Si calculamos la distancia euclídea que ya conocemos para medir similitud entre datos numéricos:

$$d_E(A, B) = \sqrt{(31 - 30)^2 + (1530000 - 1500000)^2} = \mathbf{30000}$$

$$d_E(A, C) = \sqrt{(50 - 30)^2 + (1500000 - 1500000)^2} = \mathbf{20}$$

Matemáticamente, el Cliente A es “mucho más cercano” al C, ¡a pesar de llevarse 20 años de diferencia!

TÉCNICAS DE ESCALADO

El **escalado** (también llamado **normalización**) es un paso de preprocesamiento esencial en el trabajo con modelos de *machine learning* que se realiza con el objetivo de ajustar las escalas de los atributos (variables) de tal manera que varíen todas en el mismo rango.

TÉCNICAS DE ESCALADO

Los algoritmos de *machine learning* que se basan en el cálculo de distancias tienden a darle más importancia a aquellos atributos que varían en un rango más amplio, aunque no sean los más informativos o decisivos a la hora de poner en marcha su capacidad predictiva.

Escalar los datos previo al entrenamiento del modelo puede ayudarnos a evitar este problema, conduciendo así a **mejoras significativas en la precisión de sus predicciones** en relación a utilizar datos no escalados.

ESCALADO DE DATOS


Las técnicas más comunes de escalado incluyen **dos componentes**: un **término traslacional (T)** y un **factor de escalado (S)**:

$$x'_i = \frac{x_i - T}{S}$$

El término traslacional opera moviendo los datos a lo largo del eje X , mientras que el factor de escalado hace que los datos estén más concentrados o más dispersos horizontalmente.

ESCALADO DE DATOS

Vamos a analizar el efecto de las técnicas de escalado más comunes sobre tres conjuntos de datos de dos variables cuantitativas continuas X_1 y X_2 :



Los mismos reflejan diferentes distribuciones para las variables (normal, uniforme), así como presencia/ausencia de *outliers*.

ESCALADO DE DATOS

Podemos simular estos conjuntos¹ en Python utilizando el siguiente código, basado en el uso de las librerías **numpy** y **pandas**:







```
np.random.seed(2023)

datos = pd.DataFrame({'x1_ej1' : np.random.normal(10, 4, 1000), 'x2_ej1' :
np.random.normal(-10, 4, 1000), 'x1_ej2' : np.random.normal(10, 4, 1000), 'x2_ej2'
: np.concatenate([np.random.normal(50, 4, 975), np.random.normal(100, 4, 25)]),
'x1_ej3' : np.random.normal(10, 4, 1000), 'x2_ej3' : np.random.uniform(-3, 5,
1000)}))
```


ESCALADO ESTÁNDAR (Z-SCORE)

A cada valor de la variable se le resta la media ($\bar{x}$) y se divide el resultado por la desviación estándar (s_x), resultando en una distribución con media cero y variancia unitaria:

$$x'_i = \frac{x_i - \bar{x}}{s_x}$$



ESCALADO ESTÁNDAR (Z-SCORE)

Una ventaja de esta técnica es que transforma tanto valores positivos como negativos a distribuciones similares.

Sin embargo, en presencia de *outliers*, la distribución de los valores no atípicos resulta demasiado concentrada en relación a la de una variable sin outliers. En este caso, los resultados del escalado pueden no ser apropiados.

ESCALADO ESTÁNDAR (Z-SCORE)

El **Escalado Pareto** y el ***Variable Stability (Vast) scaling*** son variaciones a esta técnica que alteran el factor de escalado, haciendo que la distribución resultante sea más dispersa. De esta manera, reducen la importancia de los *outliers*, pero no son completamente “inmunes” a ellos.







Escalado Pareto: $x'_i = \frac{x_i - \bar{x}}{\sqrt{n}}$

Variable Stability (Vast) scaling: $x'_i = \frac{x_i - \bar{x}}{s_x} \frac{\bar{x}}{s_x}$

ESCALADO MIN-MAX

Este enfoque altera la escala de la variable y desplaza sus valores a lo largo del eje X , con el resultado de que el atributo transformado se encuentra dentro del rango $[0,1]$.

$$x'_i = \frac{x_i - x_{min}}{x_{max} - x_{min}}$$



ESCALADO MIN-MAX

En esta técnica, el factor de escalado es el **rango**, y el término traslacional es el **valor mínimo de la variable**. De esta forma, los datos transformados pasan a ubicarse en el rango **[0,1]**.

Para aquellos atributos que no presentan *outliers* la técnica tiene un efecto similar al del **Z-Score**, aunque en este último caso la distribución resultante se encuentra en un rango menos acotado.

Sin embargo, cuando los datos presentan *outliers*, la técnica falla en ecualizar tanto las medias como las variancias de las distribuciones, lo que la hace inadecuada en una *pipeline* de *machine learning*.

GENERALIZACIÓN DEL ESCALADO MIN-MAX







El escalador min-max puede ser definido a través de una expresión matemática más general, de manera de permitir la definición del rango resultante como $[a,b]$, en lugar de $[0,1]$:

$$x'_i = a + \frac{(x_i - x_{min})(b - a)}{x_{max} - x_{min}}$$

ESCALADO MÁXIMO ABSOLUTO

Esta técnica modifica la escala de un atributo dividiendo cada observación por el **máximo en valor absoluto**:

$$x'_i = \frac{x_i}{\max(|x|)}$$



ESCALADO MÁXIMO ABSOLUTO

Como se observa, esta técnica es sensible a los *outliers*, dando como resultado distribuciones mucho más compactas que en ausencia de valores atípicos.

Por otra parte, dado que no incluye un término traslacional, no es capaz de ecualizar las medias de los atributos.

¿Y LOS OUTLIERS?







Las tres técnicas de escalado que mencionamos hasta el momento son muy sensibles a la presencia de outliers porque todas dependen de medidas resumen que suelen estar muy afectadas por la existencia de valores atípicos en los datos con los que trabajamos.

¿Y si hacemos algunas modificaciones sobre alguna de ellas para lograr un escalado más robusto en estas situaciones?

ESCALADO ROBUSTO

Esta técnica busca mitigar los efectos indeseados de los *outliers* utilizando como término traslacional a la **mediana** (Q_2) y escalando los datos de acuerdo al **rango intercuartil (RI)**:

$$x'_i = \frac{x_i - Q_2(x)}{Q_3(x) - Q_1(x)}$$



ESCALADO ROBUSTO

Esta técnica es efectiva para ecualizar las variancias entre los conjuntos de datos para diferentes atributos o variables, aún cuando haya uno que presenta *outliers*.

REALIZAR OPERACIONES DE SCALING

En la práctica, podemos implementar estas técnicas de escalado de diversas maneras:

- “A mano”, es decir, creando una función que aplique la operación matemática correspondiente a cada una de las columnas del DataFrame empleando métodos de **Pandas**.
- O utilizando elementos de la biblioteca **Scikit-learn**.



REALIZAR OPERACIONES DE SCALING

El flujo de trabajo utilizando el enfoque de **Scikit-learn** implica:

- Importar el *scaler* desde el módulo **sklearn.preprocessing**, según el caso: **StandardScaler**, **MinMaxScaler**, **MaxAbsScaler** o **RobustScaler**.
- Crear el objeto correspondiente (por ejemplo, **StandardScaler()**), el cual almacena las instrucciones para escalar los datos según el método elegido.
- Aplicar el escalado a los datos utilizando **fit_transform()**.

SELECCIONAR EL ESCALADO ÓPTIMO


Como vimos, hay varias alternativas de escalado que pueden ser aplicadas a un dataset, y la selección de la estrategia a utilizar es una decisión metodológica importante en el curso de un análisis de datos.

Hay estudios que muestran que elegir una técnica no muy adecuada para los datos con los que contamos puede ser más perjudicial sobre la *performance* predictiva del modelo que no haber escalado los datos.

TRANSFORMACIÓN LOGARÍTMICA

La transformación logarítmica es una herramienta poderosa para el trabajo con variables cuantitativas con valores mayores a cero que tienen **distribuciones sesgadas (*heavy-tailed*)**.

Comprime la cola superior de la distribución, haciéndola más corta, y expande la región en la que se encuentra el resto de los datos.




TRANSFORMACIÓN LOGARÍTMICA

La transformación logarítmica puede aplicarse en diversas situaciones, por ejemplo:

- **Mejorar visualizaciones:** al comprimir el rango en el que se encuentran los datos, ayuda a mejorar visualizaciones de variables cuyas observaciones se encuentran distribuidas en un rango de varios órdenes de magnitud.
- **Disminuir el sesgo:** en ciertos casos, la transformación logarítmica ayuda a lograr una distribución más simétrica de los datos (importante en el análisis estadístico/modelado).
- **Linealizar relaciones entre variables.**

TRANSFORMACIÓN LOGARÍTMICA - Ejemplo 1



A continuación se muestra un histograma en el que se representan 250 observaciones de una variable X .



¿Cómo podríamos describir a la distribución de los datos en relación a sus características de simetría?

TRANSFORMACIÓN LOGARÍTMICA - Ejemplo 1

¿Qué ocurre con la forma de la distribución cuando aplicamos una transformación logarítmica sobre estos datos?




TRANSF. LOGARÍTMICA - Otro ejemplo

Se cuenta con información acerca de alrededor de 40000 artículos y se quiere generar un modelo para predecir popularidad en términos del **número de veces que se comparte en redes sociales.**

Se propone utilizar como variable predictora el **número de palabras en el artículo.**

TRANSF. LOGARÍTMICA - Otro ejemplo¹

La distribución luce mucho más **simétrica** luego de la transformación logarítmica (dejando de lado el grupo de artículos “sin palabras” 🤔, observaciones que no se transformaron).



1. Zheng, A. y Casari, A. (2018). **Feature Engineering for Machine Learning**. 1a Edición. O'Reilly Media.