


AJUSTES Y MODELOS: Regresión Lineal

UNIDAD 6 - Parte 1

Fundamentos de Ciencia de Datos 2026



LETS LEARN



REGRESSION

memegenerator.net

ANÁLISIS DE REGRESIÓN

Bajo el nombre de **análisis de regresión** se engloba al conjunto de herramientas que permiten explicar (modelar matemáticamente) el comportamiento de una variable (**variable respuesta Y**) a partir de la información proporcionada por una o más variables (**variables predictoras $X_1, X_2, \dots, X_p$**).

TRABAJEMOS SOBRE UN EJEMPLO

Contamos con información sobre la **superficie** y el **precio de venta** de 10 propiedades de una zona de una ciudad.

```
import pandas as pd

datos = pd.DataFrame({ 'id'
' sup_m2' : [45, 60, 75, 90,
' precio_usd' : [82000, 97500
```

ID	Superficie (m²)	Precio (USD)
1	45	82000
2	60	97500
3	75	128000
4	90	155000
5	110	190000
6	130	225000
7	55	97000
8	80	124000
9	100	185000
10	120	210000

TRABAJEMOS SOBRE UN EJEMPLO


El propósito es construir un **modelo** que permita predecir el precio de una propiedad a partir de su superficie.

En este ejemplo, ¿cuál es la variable respuesta y cuál es la variable predictora?

- Y = precio de venta (USD) - **variable respuesta**
- X = superficie (m²) - **variable predictora**

EXPLORACIÓN GRÁFICA

Antes de proponer un modelo, conviene **visualizar** los datos para explorar la relación entre las dos variables.



EL MODELO DE REGRESIÓN

La relación entre Y y las p variables predictoras puede escribirse de la siguiente manera:

$$Y = f(X_1, X_2, \dots, X_p) + \varepsilon$$

- $f(\cdot)$ es una función **fija pero desconocida** que captura la relación sistemática entre las variables.
- ε es un **término de error aleatorio**: recoge todo lo que no está incluido en el modelo (variables omitidas, variaciones no medibles, etc.).

EL MODELO DE REGRESIÓN LINEAL SIMPLE

Cuando es razonable suponer que f es una recta, el modelo toma la forma:

$$Y = \underbrace{\beta_0 + \beta_1 X}_{f(X)} + \varepsilon$$

EL MODELO DE REGRESIÓN LINEAL SIMPLE

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

β_0 es la **ordenada al origen** y β_1 la **pendiente** de la recta que representa la relación entre Y y X . Son los llamados **parámetros o coeficientes del modelo**.

A raíz de la inclusión de ε (**error aleatorio**), dado un valor de la variable predictora, x_i , no se puede especificar de forma exacta el valor de la variable respuesta, ya que existe la influencia de distintos componentes aleatorios/no modelados.

LA FUNCIÓN DE REGRESIÓN

$\beta_0 + \beta_1 X$ representa a la llamada **función de regresión**, que en nuestro caso corresponde a la ecuación de una **recta**:

$$f(X) = \beta_0 + \beta_1 X$$

Desde un punto de vista estadístico, se especifica de la siguiente manera (ya veremos el sentido de esta notación más adelante):

$$E[Y/X] = \mu_{Y/X} = \beta_0 + \beta_1 X$$

LA FUNCIÓN DE REGRESIÓN

La función de regresión es una **función desconocida**, porque no conocemos los valores exactos que toman β_0 y β_1 .

- β_0 (**ordenada al origen**): valor promedio de la variable respuesta cuando la explicativa es igual a 0.
- β_1 (**pendiente**): cambio promedio en la variable respuesta cuando la explicativa aumenta en una unidad.

El objetivo del **aprendizaje estadístico** es estimar esa f desconocida a partir de la información contenida en los datos.

ESTIMACIÓN DEL MODELO

Función de regresión: $f(X) = \mu_{Y/X} = \beta_0 + \beta_1 X$

A partir de una muestra de n pares (x_i, y_i) , estimamos la función (recta) de regresión:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$


donde $\hat{\beta}_0$ y $\hat{\beta}_1$ son **estimaciones puntuales** de los parámetros poblacionales β_0 y β_1 .

ESTIMACIÓN DEL MODELO


$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

Las fórmulas para calcular estos valores son el resultado de aplicar el **Método de Mínimos Cuadrados (OLS)**, el cual provee las estimaciones que corresponden a la recta que *mejor ajusta* a los datos experimentales.

MÉTODO DE MÍNIMOS CUADRADOS




MÉTODO DE MÍNIMOS CUADRADOS




MÉTODO DE MÍNIMOS CUADRADOS

Este no parece ser el mejor ajuste para los datos con los que contamos... 🙄



MÉTODO DE MÍNIMOS CUADRADOS

Estas **distancias verticales** de los puntos observados a la recta son “grandes”, por lo que la recta no proporciona un buen ajuste para los datos.



RESIDUOS

Estas ***distancias verticales*** que miramos de forma intuitiva se denominan **residuos del modelo**:

$$e_i = y_i - \hat{y}_i$$

En nuestro caso, en el que se incorpora un único predictor:

$$e_i = y_i - \hat{y}_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)$$

MÉTODO DE MÍNIMOS CUADRADOS

Si los residuos representan errores en el ajuste, lo deseable es encontrar los valores de $\hat{\beta}_0$ y $\hat{\beta}_1$ que arrojen **residuos lo más pequeños posibles**. En particular, se buscan los valores $\hat{\beta}_0$ y $\hat{\beta}_1$ que minimicen la suma de los residuos al cuadrado:

$$\sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 = \min$$

La suma de los residuos al cuadrado se conoce como **suma de cuadrados de error (SC_{error} o RSS, por las siglas en inglés)**.

MÉTODO DE MÍNIMOS CUADRADOS

Para encontrar los valores de $\hat{\beta}_0$ y $\hat{\beta}_1$ que minimizan la sumatoria anterior, se deriva con respecto a $\hat{\beta}_0$ y $\hat{\beta}_1$, se igualan ambas derivadas parciales a cero y se resuelve el sistema de ecuaciones resultante (**ecuaciones normales**). De ello resulta:


$$\hat{\beta}_1 = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{(n - 1) s_x^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

MÉTODO DE MÍNIMOS CUADRADOS


En esta primera propuesta de ajuste, los **residuos** son “grandes”, por lo que la recta no proporciona un buen ajuste para los datos.

$$SC_{Error} = \sum_{i=1}^{10} e_i^2 \approx 6.43 \cdot 10^{10}$$



MÉTODO DE MÍNIMOS CUADRADOS


Intuitivamente, esta recta proporcionaría un mejor ajuste para los datos que la anterior (aunque no parece ser la que **mejor ajusta**).



MÉTODO DE MÍNIMOS CUADRADOS

Intuitivamente, esta recta proporcionaría un mejor ajuste para los datos que la anterior (aunque no parece ser la que **mejor ajusta**).


$$SC_{Error} = \sum_{i=1}^{10} e_i^2 \approx 2.26 \cdot 10^9$$




MÉTODO DE MÍNIMOS CUADRADOS

El Método de Mínimos Cuadrados nos provee los valores de $\hat{\beta}_0$ y $\hat{\beta}_1$ que corresponden a la recta que **mejor ajusta** a los datos experimentales (que minimiza la SC_{Error}).

$$SC_{Error} = \sum_{i=1}^{10} e_i^2 \approx 4.09 \cdot 10^8$$



AJUSTE Y ANÁLISIS DE SALIDAS



Para realizar el ajuste, vamos a usar **statsmodels**, un módulo de Python que proporciona funcionalidades para la estimación de diferentes modelos, así como para realizar análisis exploratorios y conducir tests estadísticos.

EVALUANDO EL MODELO: R^2

¿Cómo **explicamos** que haya **variabilidad** en las observaciones de la variable respuesta? Es decir, ¿por qué los precios de las propiedades son diferentes?

- Porque las propiedades relevadas tienen distintas superficies (variable predictora incorporada en el modelo) <-> **explicada por el modelo**
- Por la influencia de causas aleatorias y de otras variables no incluidas en el modelo como predictoras <-> **no explicada por el modelo**

EVALUANDO EL MODELO: R^2

COEFICIENTE DE DETERMINACIÓN (R^2): mide la proporción de la variabilidad total en las observaciones de la variable respuesta Y que es *explicada* por el modelo.

EVALUANDO EL MODELO: R^2

El rango de variación de este coeficiente es:

$$0 \leq R^2 \leq 1$$

- Si el ajuste es perfecto, $R^2 = 1$: el modelo captura el **100%** de la variabilidad en la respuesta.
- Si el modelo no logra explicar nada de la variabilidad existente en la respuesta, $R^2 = 0$.

Cuanto más cercano a 1 sea el valor de R^2 , mayor será la capacidad explicativa del modelo.



IMPORTANTE

Un R^2 alto no garantiza que el modelo sea adecuado.

Puede ser elevado incluso cuando la relación entre las variables no es lineal, cuando hay valores atípicos influyentes, o cuando el modelo sobreajusta los datos. Siempre acompañarlo de exploración gráfica y análisis de residuos (próxima clase).

REGRESIÓN LINEAL MÚLTIPLE

La regresión lineal simple es útil para predecir una variable respuesta sobre la base de una **única variable predictiva**.


Sin embargo, en la práctica a menudo tenemos más de un predictor, con lo que podemos extender el modelo de regresión lineal simple para incorporar **múltiples variables explicativas**:

$$Y = \beta_0 + \underbrace{\beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \dots + \beta_p X_p}_{f(X_1, X_2, X_3, \dots, X_p)} + \varepsilon$$


En este escenario, hablamos de **regresión lineal múltiple**.

INCORPORAR UNA VARIABLE CUALITATIVA

Para estudiar este caso, vamos a volver a nuestro querido dataset de **penguins**, con el que trabajamos algunas clases atrás.



En ese momento, vimos que existía un grado de asociación lineal interesante ($r = 0.87$) entre la masa corporal (**body_mass_g**) y la longitud de la aleta (**flipper_length_mm**) de los pingüinos del archipiélago Palmer.



En este escenario, nos podría interesar ajustar un modelo que permita predecir la masa corporal del pingüino en función de la longitud de su aleta (**¿Por qué?**).

UN PRIMER MODELO

¡MANOS A LA OBRA!

🐧 Ajustar un modelo de regresión lineal simple que permita predecir la masa corporal de un pingüino de esta región en función de la longitud de su aleta.

🐧 Utilizar el modelo ajustado para predecir la masa corporal de un pingüino con una **longitud de aleta de 207 mm**.


🐧 Utilizar el modelo ajustado para predecir la masa corporal de un **pingüino hembra** con una **longitud de aleta de 207 mm**.

UN PRIMER MODELO

La ecuación de nuestro modelo ajustado es:

$$\hat{y} = -5780.8 + 49.7 x$$

Coef. de determinación (R^2) = 0.759.




En base al modelo ajustado, la masa corporal predicha para un pingüino con una aleta de 207 mm es: $\hat{y} = 4504.1$ g.

UN PRIMER MODELO

La ecuación de nuestro modelo ajustado es:

$$\hat{y} = -5780.8 + 49.7 x$$


Coef. de determinación (R^2) = 0.759.



En base al modelo ajustado, la masa corporal predicha para un pingüino con una aleta de 207 mm es: $\hat{y} = 4504.1$ g, **¡tanto para un pingüino macho como para una hembra!**

COMPLEJICEMOS EL MODELO 🦾

Como existen diferencias visibles entre pingüinos macho y hembra, podríamos incorporar la variable **sex** como predictora en nuestro modelo (además de **flipper_length_mm**, *of course!*).



¿Qué tipo de variable es **sex**?

GENERACIÓN DE VARIABLES *DUMMY*

Para incorporar un predictor cualitativo que sólo tiene **dos niveles**, como la variable **sex**, creamos una **variable *dummy*** que puede tomar dos valores numéricos posibles:

$$X_2 = \begin{cases} 1, & \text{si es un pingüino macho.} \\ 0, & \text{si es un pingüino hembra.} \end{cases}$$

Y usamos esta variable como un predictor en la ecuación de regresión. Esto resulta en el siguiente **modelo**:


$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$$

AJUSTEMOS EL NUEVO MODELO

Ajustar este nuevo modelo por Mínimos Cuadrados implicará utilizar la información muestral para encontrar los valores de $\hat{\beta}_0$, $\hat{\beta}_1$ y $\hat{\beta}_2$ que minimizan la SC_{Error} .

La ecuación de nuestro modelo ajustado es:

$$\hat{y} = -5410.3 + 46.98 x_1 + 347.85 x_2$$



🧐 Utilizar el modelo ajustado para predecir la masa corporal de un pingüino hembra con una longitud de aleta de 207 mm.

SOBRE EL MODELO

Este nuevo modelo de regresión lineal estándar provee resultados interpretables y funciona aceptablemente bien.

Sin embargo, en el planteo que hicimos estamos suponiendo que la forma en la que **flipper_length_mm** influye sobre la respuesta es **la misma independientemente del sexo del animal**. Esto se refleja en el hecho de que las rectas de regresión ajustadas para los dos sexos son **paralelas**.

La diferencia en la masa corporal predicha para un pingüino macho en relación a uno hembra es un término aditivo representado por β_2 .

SOBRE EL MODELO

$$\hat{y} = -5410.3 + 46.98x_1 + 347.85x_2$$

Recta ajustada para pingüinos machos ($x_2 = 1$)

$$\hat{y} = -5062.45 + 46.98 x_1$$

Recta ajustada para pingüinos hembra ($x_2 = 0$)

$$\hat{y} = -5410.3 + 46.98 x_1$$

R^2 ajustado

Dado que agregar más predictores al modelo siempre reduce (o en el peor caso mantiene igual) el error de ajuste, **el R^2 nunca disminuye al incorporar nuevas variables — aunque éstas no aporten información real.**

Esto lo convierte en una **métrica poco útil para comparar modelos con distinto número de predictores.**

R^2 ajustado

El R^2 ajustado corrige ese problema penalizando la complejidad del modelo:

$$R^2_{adj} = 1 - \frac{SC_{Error} / (n - p - 1)}{S_Y^2}$$

A diferencia del R^2 , el R^2_{adj} puede disminuir si se agrega una variable que no mejora el ajuste de forma genuina. Es por eso una métrica más adecuada para comparar modelos.

R² ajustado

En nuestro caso, los valores de R^2_{adj} obtenidos fueron los siguientes:

Modelo 1: $\hat{y} = -5780.8 + 49.7 x$
 $R^2_{adj} = 0.758$

Modelo 2: $\hat{y} = -5410.3 + 46.98 x_1 + 347.85 x_2$
 $R^2_{adj} = 0.805$

OTRAS MÉTRICAS PARA EVALUAR EL MODELO

ERROR CUADRÁTICO MEDIO (*Mean-Squared Error*, MSE):

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \frac{SC_{Error}}{n}$$

Es una medida de la *performance* del modelo que evalúa qué tan próximos se encuentran los valores predichos de los reales u observados.

Al elevar al cuadrado la distancia entre la respuesta observada y la predicha (residuos), esta métrica **penaliza fuertemente a los valores atípicos**.

OTRAS MÉTRICAS PARA EVALUAR EL MODELO

RAÍZ DEL ERROR CUADRÁTICO MEDIO (*Root Mean Squared Error*, RMSE):

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Resuelve el problema de interpretación del MSE: al tomar la raíz cuadrada, el RMSE queda expresado en las **mismas unidades que Y** . Es la métrica más utilizada en la práctica para reportar el error de predicción de un modelo.

OTRAS MÉTRICAS PARA EVALUAR EL MODELO

ERROR ABSOLUTO MEDIO (*Mean Absolute Error, MAE*):

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

En este caso, en lugar de sumar los residuos elevados al cuadrado, **se toman sus valores absolutos**, lo que hace que el MAE sea inherentemente robusto a las posibles distorsiones causadas por la presencia de valores atípicos.

Es por eso que el MAE suele preferirse cuando el contexto no justifica penalizar más a los errores grandes.