


AJUSTES Y MODELOS: Regresión Lineal: Inferencia y Predicción

UNIDAD 6 - Parte 2

Fundamentos de Ciencia de Datos 2025



REPASO

La relación que existe entre Y y la/s variable/s predictora/s $X_1, X_2, \dots, X_p$ puede escribirse de la siguiente forma:

$$Y = f(X_1, X_2, \dots, X_p) + \varepsilon$$

f es una función fija pero desconocida de $X_1, X_2, \dots, X_p$, y ε es un término de **error aleatorio** que contiene otras variables no incluidas explícitamente en el modelo como predictoras, así como variaciones aleatorias no medibles.

Utilizamos el aprendizaje estadístico para estimar o **modelar** $f(X_1, X_2, \dots, X_p)$.

¿POR QUÉ NOS INTERESA ESTIMAR f ?

PARA HACER PREDICCIONES: en muchas situaciones, no puede obtenerse fácilmente el valor de Y (**respuesta**), pero sí se tiene disponible la información sobre un conjunto de variables (**predictores**) $X_1, X_2, \dots, X_p$. Podemos predecir Y usando:

$$\hat{y} = \hat{f}(X_1, X_2, \dots, X_p)$$

Bajo esta concepción, $\hat{f}$ se suele tratar como una **caja negra**, en el sentido de que no estamos particularmente interesados en la forma matemática exacta de $\hat{f}$, sino en las predicciones que podemos realizar de Y a partir de ella.

¿POR QUÉ NOS INTERESA ESTIMAR f ?

PARA HACER INFERENCIAS: en este caso, estamos más interesados en conocer la forma matemática en la que los predictores $X_1, X_2, \dots, X_p$ influyen sobre Y , y nos hacemos preguntas como:

- ¿Qué predictores están asociados con la respuesta? ¿Cuáles son los más ***importantes***?
- ¿Cuál es la relación entre la respuesta y cada predictor?
- La relación entre Y y cada predictor... ¿puede ser resumida utilizando una ecuación lineal o necesitamos formas más complicadas?

¿PREDICCIÓN, INFERENCIA O AMBAS?



Por ejemplo, podríamos querer modelar el precio de una propiedad en función de distintos predictores como: superficie, tasa de criminalidad, barrio de la ciudad, distancia al río, calidad del aire, etc.

Podríamos querer responder: ***¿cuánto más cuesta una casa si tiene vista al río?*** O tal vez simplemente nos interese **predecir el valor de una casa en función de las características que tiene.**

O quizás nos interesen ambas... ¿por qué no?

¿CÓMO ESTIMAMOS f ?

Primero le damos una forma matemática (bastante simple) a esa f :

$$f(X_1, X_2, \dots, X_p) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \dots + \beta_p X_p$$

¿CÓMO ESTIMAMOS f ?

Primero le dimos una forma matemática (bastante simple) a esa f :

$$f(X_1, X_2, \dots, X_p) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \dots + \beta_p X_p$$

Luego, a partir de un **conjunto de datos** utilizamos un método de aprendizaje estadístico para **ajustar** el modelo, es decir, para **estimar los parámetros** $\beta_0, \beta_1, \beta_2$, etc.

Este *approach* es **paramétrico**, porque reduce el problema de estimar f al de estimar un conjunto de parámetros.

INFERENCIA

Ante múltiples predictores, ¿cómo evaluamos cuáles son los que ***realmente*** están asociados con la respuesta? Este procedimiento se conoce como **selección de variables**.

ENSAYAR HIPÓTESIS SOBRE LOS PARÁMETROS

Una vez ajustado un modelo, podemos realizar **TESTS DE HIPÓTESIS** acerca de los **coeficientes o parámetros** asociados con cada uno de los predictores para evaluar si están realmente relacionados con la respuesta.

Los **tests de hipótesis** son procedimientos estadísticos empleados para **tomar una decisión** acerca del valor de uno o más parámetros poblacionales, en base a la información de una muestra.

ENSAYAR HIPÓTESIS SOBRE LOS PARÁMETROS

Por ejemplo, supongamos que pensamos en ajustar un modelo con la siguiente forma para la función f :

$$f(X_1, X_2) = \beta_0 + \beta_1 X_1 + \beta_2 X_2$$

Nos puede interesar evaluar si existe o no relación entre X_1 e Y , es decir, **si este predictor es útil para modelar Y o podemos prescindir de él.**

ENSAYAR HIPÓTESIS SOBRE LOS PARÁMETROS

En este escenario, nos interesa testear la **hipótesis nula (H_0)** de que:

H_0 : No hay relación entre X_1 e Y

versus la **hipótesis alternativa (H_1):**

H_1 : Hay relación lineal entre X_1 e Y

ENSAYAR HIPÓTESIS SOBRE LOS PARÁMETROS

Matemáticamente, esto equivale a plantear el siguiente **test de hipótesis**:

$$H_0: \beta_1 = 0$$

versus

$$H_1: \beta_1 \neq 0$$

En el caso de que H_0 se cumpla, el modelo sería igual a $Y = \beta_0 + \beta_2 X_2 + \varepsilon$ y X_1 no estaría asociada linealmente con Y .

ENSAYAR HIPÓTESIS SOBRE LOS PARÁMETROS

Para resolver el ensayo de hipótesis, necesitamos determinar si $\hat{\beta}_1$, nuestro estimador de β_1 , está lo suficientemente alejado de cero como para que podamos afirmar “con confianza” que $\beta_1 \neq 0$.

¿Y cómo sabemos cuánto es **suficiente**?

ENSAYAR HIPÓTESIS SOBRE LOS PARÁMETROS

Podemos usar el enfoque de la **probabilidad asociada (p-value o valor-p)**

La probabilidad asociada es una medida de **cuánta evidencia** tenemos, en el marco del modelo propuesto y con los datos con los que contamos, de que sea **cierta la hipótesis nula**. Por lo tanto, **valores pequeños de p-value** nos llevarán a pensar que el predictor en cuestión está relacionado con la respuesta.

En la práctica, se suele considerar que valores de **p-value < 0.05** son suficientes para considerar falsa a la hipótesis nula.

OTROS ENFOQUES

Si lo queremos ver de otra manera, extender lo anterior a ambos predictores implicaría decidir qué modelo es el mejor entre los siguientes (para la función f):

Modelo 1: $f(X_1, X_2) = \beta_0 + \beta_1 X_1 + \beta_2 X_2$

Modelo 2: $f(X_1) = \beta_0 + \beta_1 X_1$

Modelo 3: $f(X_2) = \beta_0 + \beta_2 X_2$

Modelo 4: $f = \beta_0$

O sea, decidir **cuál es el mejor conjunto de predictores**.

OTROS ENFOQUES

Para esto, puede calcularse el **R^2 ajustado** para cada modelo, ya que penaliza la inclusión innecesaria de variables que sólo generan ruido en el modelo:

$$R^2_{adj} = 1 - \frac{SC_{Error} / (n - p - 1)}{SC_{Total} / (n - 1)}$$

Entre modelos con distinta cantidad de predictores, se elige el que presenta el **mayor** R^2_{adj} .

MÁS SOBRE LA CALIDAD DEL AJUSTE

Una métrica muy utilizada para evaluar la calidad del ajuste es el **ERROR CUADRÁTICO MEDIO** (*Mean-Squared Error, MSE*):

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \frac{SC_{Error}}{n}$$

Es una medida de qué tan “próximos” se encuentran los valores predichos de los reales u observados.

Al elevar al cuadrado la distancia entre lo que predijimos y lo que es correcto (residuos), esta métrica **penaliza fuertemente a los valores atípicos**.

MÁS SOBRE LA CALIDAD DEL AJUSTE

El MSE se calcula utilizando los **datos de entrenamiento** que se emplearon para ajustar el modelo (es un ***training* MSE**).

Sin embargo, en general estamos más interesados en la calidad de las predicciones que el modelo pueda hacer a partir de datos que nunca vio (**datos de testeo**). O sea, requerimos un ***test* MSE**.



Más que seleccionar el modelo que presente un menor *training* MSE, nos quisiéramos quedar con aquel que nos proporcione el menor *test* MSE. **¿Cómo hacemos esto?**

MÁS SOBRE LA CALIDAD DEL AJUSTE


En algunos casos, tenemos disponible un conjunto de observaciones que no fueron usadas para entrenar los modelos de aprendizaje estadístico y podemos utilizarlos como **datos de testeo** para quedarnos con el que minimice el MSE.

¿Y si no tenemos datos de testeo? ¿Por qué no pensar en elegir el modelo que minimiza directamente el *training* MSE que podemos calcular sobre los datos de entrenamiento?

MÁS SOBRE LA CALIDAD DEL AJUSTE





MÁS SOBRE LA CALIDAD DEL AJUSTE



El **training MSE** (línea gris) disminuye de forma continua, ya que el modelo se ajusta cada vez más a las particularidades de los datos de entrenamiento a medida que aumenta su complejidad.

Por otro lado, el **test MSE** (línea roja) disminuye inicialmente conforme el modelo se ajusta mejor a los datos de entrenamiento, ya que también lo hace sobre los datos de testeo. Sin embargo, **alcanza un valor mínimo** en una situación intermedia para luego volver a aumentar conforme el modelo se vuelve más y más complejo, perdiendo así capacidad de generalización.

MÁS SOBRE LA CALIDAD DEL AJUSTE



MÁS SOBRE LA CALIDAD DEL AJUSTE

Cuando un modelo ajustado nos proporciona un ***training* MSE** pequeño junto con un gran ***test* MSE**, se dice que estamos **sobreajustando** los datos (fenómeno del *overfitting*).

Esto ocurre porque nuestro modelo de aprendizaje estadístico está muy enfocado en encontrar patrones en los datos de entrenamiento que en realidad son provocados por fluctuaciones aleatorias.

Cuando sobreajustamos los datos de entrenamiento, el ***test* MSE** se hace muy grande porque esos supuestos patrones simplemente no existen en los datos de testeo (ni en la realidad).

REDFLAGS EN UNA REGRESIÓN LINEAL

En esta sección exploraremos algunas otras cuestiones que no debemos pasar por alto al evaluar un modelo de regresión lineal.



REDFLAGS EN UNA REGRESIÓN LINEAL


NO LINEALIDAD DE LA RELACIÓN RESPUESTA-PREDICTOR.

El modelo de regresión lineal asume que hay una relación lineal entre los predictores y la respuesta.

Si la relación verdadera está lejos de ser lineal, virtualmente todas las conclusiones que saquemos a partir del ajuste son dudosas.

REDFLAGS EN UNA REGRESIÓN LINEAL

NO LINEALIDAD DE LA RELACIÓN RESPUESTA-PREDICTOR.



Los gráficos de **residuos** (e_i) vs. los **valores predichos** (*fitted values*, $\hat{y}_i$) son muy útiles para identificar falta de linealidad.


Si el gráfico sugiere que existen asociaciones no lineales en los datos, un enfoque simple es utilizar **transformaciones no lineales de los predictores** en el modelo de regresión, como $\log(X)$, $\sqrt{X}$ y X^2 .

REDFLAGS EN UNA REGRESIÓN LINEAL

FALTA DE NORMALIDAD. Un importante supuesto del modelo de regresión lineal es que los errores ε tienen **distribución normal**. Posibles incumplimientos de esta asunción pueden observarse gráficamente al representar la distribución de los **residuos del modelo** (histograma, gráfico de densidad) o, aún mejor, realizando un **Normal Q-Q Plot**.

REDFLAGS EN UNA REGRESIÓN LINEAL

HETEROCEDASTICIDAD. Otro importante supuesto del modelo de regresión lineal es que los errores ε tienen **variancia o variabilidad constante**.



La observación de patrones tipo **embudo** en el gráfico de residuos vs. *fitted values* es un indicador de heterocedasticidad.


REDFLAGS EN UNA REGRESIÓN LINEAL

HETEROCEDASTICIDAD.

Cuando nos encontramos con este problema, una posible solución es realizar alguna transformación sobre la respuesta Y usando una función cóncava, como $\log(Y)$ o $\sqrt{Y}$.

REDFLAGS EN UNA REGRESIÓN LINEAL

PRESENCIA DE OUTLIERS. En el marco del ajuste de modelos, un *outlier* es un punto para el que el valor observado y_i está “lejos” del valor predicho por el modelo.



REDFLAGS EN UNA REGRESIÓN LINEAL

PRESENCIA DE OUTLIERS.

Muchas veces no causan grandes problemas en el ajuste por mínimos cuadrados (estimaciones de parámetros), pero sí pueden influir sobre ciertas medidas utilizadas para hacer inferencia a partir del modelo ajustado (**¡pesan mucho en la SC_{error} !**).

REDFLAGS EN UNA REGRESIÓN LINEAL

COLINEARIDAD/MULTICOLINEARIDAD.

La colinealidad se presenta cuando dos o más variables predictoras están íntimamente asociadas (*correlacionadas*) y resulta difícil separar y evaluar los efectos individuales de cada una sobre la respuesta.

Una forma de detectarla es analizando la matriz de correlación de los predictores (aunque no siempre es sencillo hacerlo de este modo, porque puede existir **multicolinealidad**).

GRÁFICOS DE RESIDUOS

A continuación presentaremos herramientas para la construcción de los gráficos de residuos mencionados anteriormente, tomando como referencia los correspondientes al modelo para la masa de los pingüinos del Archipiélago Palmer que considera al sexo y a la long. aleta como predictoras:


$$\hat{y} = -5410.3 + 46.98 x_1 + 347.85 x_2$$

Donde x_1 = long. aleta y x_2 = variable dummy que toma el valor 1 si el pingüino es macho y 0 en caso contrario.

GRÁFICOS DE RESIDUOS

Gráfico de residuos vs. fitted values:


```
sns.regplot(x = modelo.fittedvalues, y = modelo.resid, lowess = True, line_color = 'red',  
plt.axhline(y = 0, color = 'black', linestyle = '--');
```



GRÁFICOS DE RESIDUOS

Normal Q-Q Plot de residuos

```
import statsmodels.api as sm  
  
sm.qqplot(modelo.resid, line = 's')
```



GRÁFICOS DE RESIDUOS

En el código utilizado para construir el primer gráfico, **lowess = True** agrega la línea suavizada que sigue la forma general de los puntos.

En el Normal Q-Q Plot, la recta roja (**line = 's'**) representa el comportamiento esperado para una distribución normal de los residuos.

BONUS TRACK

Como vimos, ajustar un **modelo de regresión** consiste en hallar una ecuación matemática que describa, de la mejor manera posible, la forma en la cual una variable respuesta Y se relaciona con uno o más predictores.

Esto implica encontrar el conjunto de coeficientes que **minimizan** alguna de las métricas definidas en función de los **residuos** del modelo: SC_{error} (Suma de cuadrados de error, SSR), MSE (Error cuadrático medio), MAE (Error absoluto Medio), etc.

BONUS TRACK

SOLUCIÓN CERRADA. Una forma para obtener estos coeficientes es a través de una **SOLUCIÓN CERRADA**. Como consecuencia de la aplicación del Método de Mínimos Cuadrados, en el marco de un ajuste de un modelo de regresión lineal simple, hallamos expresiones matemáticas (fórmulas) para el cálculo de las estimaciones de los parámetros del modelo:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{(n - 1) s_x^2}$$


$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

BONUS TRACK

ALGORITMO DE OPTIMIZACIÓN ITERATIVO. También es posible emplear un **ENFOQUE ITERATIVO** basado en algún otro algoritmo de optimización, como el **descenso de gradiente**, ampliamente utilizado en el entrenamiento de modelos de *machine learning* y redes neuronales. Este método permite encontrar un conjunto de coeficientes que minimice una función convexa conocida como **función de pérdida o de costo** (como el MSE en regresión), guiando al modelo hacia una solución óptima mediante ajustes sucesivos en la dirección de máximo descenso de dicha función.

BONUS TRACK

ALGORITMO DE OPTIMIZACIÓN ITERATIVO.



RECURSO INTERESANTE

<https://mlu-explain.github.io/linear-regression/>. Esta página ofrece una explicación detallada acompañada de visualizaciones interactivas sobre el análisis de regresión lineal, cubriendo desde los conceptos básicos y la interpretación de los parámetros hasta temas más avanzados como el ajuste del modelo y las métricas de evaluación.

Si bien aborda temas que escapan a los alcances de este curso, es un buen recurso para entender los fundamentos y desafíos en la aplicación de estas herramientas.