Probabilidad y Estadística

TUIA - FCEIA

Unidad 1

Gottig, Nicolás
Avila, Aylen
L'heureux, Julián

Naturaleza de los estudios estadísticos

"…la ciencia de recolección, presentación, análisis e interpretación de datos numéricos para el análisis lógico". (Varalakshmi et al, 2004)

- Fenómenos deterministas vs. Fenómenos estocásticos.

- **Fenómenos estocásticos:** poseen variabilidad natural o asignable. Con ayuda de herramientas estadísticas podemos reducir la incertidumbre asociada.

Naturaleza de los estudios estadísticos

La estadística tiene como origen la aplicación de métodos para resumir información característica de una población y recursos (de hecho, estadística deriva de la palabra latina estado).

*El **arte** y la **ciencia** que se dedica al diseño de estudios y al análisis de los datos que dichos estudios producen, con el objetivo de traducir los datos en conocimiento y entender el mundo que nos rodea (Agresti y Franklin, 2013).*

La estadística es el arte y la ciencia de aprender por medio de los datos. Aporta métodos para obtener, organizar y analizar datos, así como herramientas para la toma de decisiones en presencia de la variabilidad e incertidumbre.

Naturaleza de los estudios estadísticos

Los procesos están sujetos a cierta variabilidad. Nuestro objetivo es reducir esa incertidumbre. Algunas actividades que incluyen el uso de la estadística en varias etapas:

- Explicación de la devolución de pedidos por parte de los clientes para mejorar la calidad del producto.
- Elaboración de un proyecto para la construcción de un puente.
- Conocer las cantidades producidas de un producto que maximiza las ganancias en una empresa.
- Comprender los factores que inciden en que un cliente acepte o no una llamada, para optimizar una campaña de marketing.

¿Qué otras?

Algunas nociones

- **Debemos realizar las preguntas correctas y definir objetivos:**

  ¿Cuál es el ingreso promedio de los habitantes del aglomerado Gran Rosario? ¿Cuál es la proporción de ciudadanos que está de acuerdo con una política ambiental? ¿Cuál es el porcentaje de productos que no cumple con una norma de calidad? ¿Qué grupos de instrumentos financiero es menos riesgoso (variable)?

- ¿Qué tienen en común las preguntas?
- Definir objetivos para las preguntas anteriores

La operacionalización del estudio se realiza a través de la **medición de variables**.

Algunas nociones

Las preguntas anteriores involucran **parámetros**. Es decir, medidas que resumen un **atributo** de la población. Algunos parámetros podrían ser: el promedio, una proporción, o una medida de variabilidad. ¿Qué otros?

Las **variables** son los atributos de las unidades de estudio que son capaces de tomar distintos valores para cada una.

La **población estadística** se compone por todos los valores (y sus respectivas frecuencias) que toma la variable en mi población bajo estudio.

Las variables pueden ser: Categóricas o numéricas discretas o continuas. **También debe evaluarse la escala de medición, pudiendo ser nominales, ordinales, de intervalo o de razón.**

Actividad

Variable	Posibles valores	Cualitativa	Cuantitativa		Escala de medición			
			Discreta	Continua	Nominal	Ordinal	De intervalo	De razón
Tiempo de reparación de cierto tipo de equipo en un taller (en minutos)	$(0\,;\infty)$			X				X
Nivel de resistencia de piezas metálicas	Alto, Medio o Bajo							
Intención de voto en una elección	Candidato A, B, ...							
Tipo de defecto observado en piezas	Rayadura, poro, ...							
Temperatura del proceso de producción (en grados C)	$[0\,;\infty)$							
Cumplimiento de las especificaciones en relación al peso de componentes plásticos (en gramos)	Cumple, no cumple							
Número de unidades vendidas diariamente de cierto producto	0, 1, 2,...							
Calidad de conexiones eléctricas	Mala, Regular, Buena, Muy Buena							
Resistencia de tramas probada con un nuevo tipo de fibra (en deniers)	$(0\,;\infty)$							
Espesor del asfalto en una ruta (en cm)	$(0\,;\infty)$							
Nº de piezas defectuosas en cajas de 20 unidades	0, 1, ..., 20							

Para cada una de las variables de la tabla:

a) Indique de qué tipo es y en qué escala está medida (señale con una "x" según corresponda).

b) Defina:

1) Una población para la cual pueda ser de interés registrarla.
2) Un parámetro de interés.

Algunas nociones

¿Cuál es el ingreso promedio de los habitantes del aglomerado Gran Rosario? ¿Cuál es la proporción de ciudadanos que está de acuerdo con una política ambiental? ¿Cuál es el **porcentaje** de **productos** que no cumple con una norma de calidad?

¿Qué grupos de instrumentos financiero es menos **riesgoso** (variable)?

¿Cuál es la población en cada caso? ¿Podemos acceder a ella?

Algunas nociones

La población es el conjunto de todas las unidades elementales. Puede ser finita o infinita.

Una muestra es un subconjunto de la población. Profundizaremos en esto más adelante.

La unidad elemental es cada uno de los elementos que componen la población, y que tienen algún atributo que los hace pertenecer a esa población.

Criterios de inclusión / exclusión: *Los criterios de inclusión son las características que deben cumplir las unidades elementales (incluyendo el tiempo y espacio). Los de exclusión son aquellos que deben no cumplir las unidades elementales para ser consideradas parte de la población*

Algunas nociones

Tomar decisiones analizando muestras implica un trabajo adicional.

Análisis descriptivo: Abarca métodos para resumir la información recolectada (sea de una muestra o del total del conjunto de las unidades de análisis. El análisis descriptivo incluye registros tabulares y gráficos, además de medidas resumen como promedios y porcentajes.

Inferencia: *Abarca métodos para tomar decisiones o para realizar pruebas de hipótesis o realizar predicciones sobre una población (proceso inductivo). Es decir, la utilizaremos cuando queramos sacar conclusiones de una población a partir de una muestra.*

Muestra: Estadístico $\longrightarrow$ Población: Parámetro

Algunas nociones

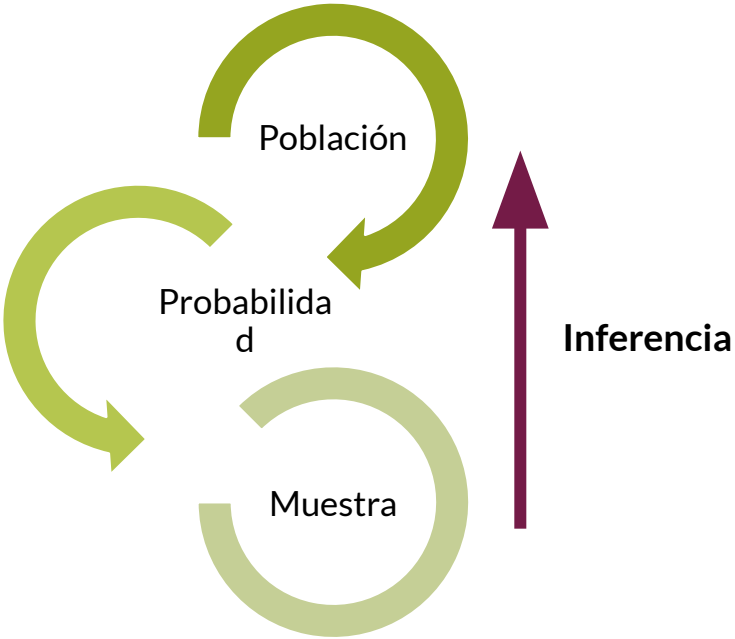

La **probabilidad** permite entender mejor cómo se desarrollan y utilizan los métodos de inferencia. Es un “puente” entre la muestra y la población.

En un problema de estadística, el observador dispone de **una muestra** y, a partir de ella, puede realizar conclusiones sobre toda una población.

La **probabilidad** aporta información de la población a la muestra (proceso deductivo) mientras que la inferencia aporta información sobre la población a partir de una muestra (proceso inductivo).

Nos aporta herramientas para **entender y cuantificar** la incertidumbre.

Algunas nociones

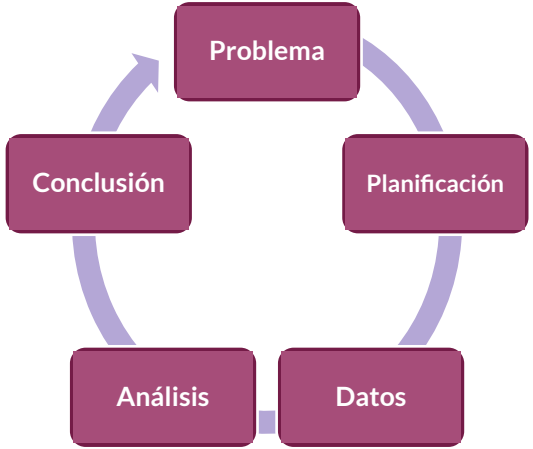

Wild y Pfannkuch (1999)

Planteo del problema

Plantear correctamente el interrogante y los objetivos del estudio, así como los parámetros de interés y las variables a observar o medir.

Dentro de los objetivos podemos querer reconocer el comportamiento de una característica de la población (modelo o distribución) o el conocimiento de alguna medida que resuma información sobre la población estadística de estudio. Es decir, un parámetro.

¿Cuál fue la ocurrencia de fallas mensuales en un sistema de distribución eléctrica de la Provincia de Santa Fe, entre el 1ro de diciembre y el 31 de marzo? Es distinto a … ¿Cuál es la ocurrencia de fallas mensuales en los sistemas de distribución eléctrica de Argentina?

Planteo del problema

*Suponga una producción de barras de acero para un cliente del rubro automotriz. Se desea saber la proporción (p) de barras producidas que cumplen con la siguiente especificación: la longitud debe ser entre **249,4 y 250,6** mm.*

Escriba y discuta un objetivo válido en términos estadísticos, así como la pregunta a responder.

Además describa la población, la unidad elemental, las variables y características, la población estadística y la o las medidas de interés.

Planificación del estudio

Para responder a cualquiera de las preguntas de índole estadística se necesitan datos. En esta etapa se decide:

- Cómo se llevará a cabo el estudio estadístico para obtener los datos (observacional, experimental, transversal, longitudinal, etc…)
- Cómo se analizarán los datos posteriormente para obtener las conclusiones (análisis descriptivo y/o inferencial).
- En caso de trabajar con muestras, se debe decidir qué nivel de confianza se utilizará, así como el margen de error dispuesto a cometer.
- Se deben evaluar estudios previos que aporten información a la planificación del estudio

Planificación del estudio

Estudios transversales vs. Estudios longitudinales:

Los estudios **transversales** son aquellos donde las variables se observan en un determinado momento, o en el que se supone que el tiempo transcurrido no constituye un factor de variación entre las unidades.

Los estudios **longitudinales** son estudios donde las variables observadas son sobre las mismas unidades a lo largo del tiempo.

Planificación del estudio

Estudios observacionales vs. Estudios experimentales:

Los estudios **observacionales** son aquellos en donde se observan las unidades elementales y se registra el valor de alguna característica de interés sin realizar modificaciones. Cada unidad se denomina unidad observacional.

Los estudios **experimentales** son aquellos donde se realizan cambios deliberados en los niveles de algunas variables (factores), y se registra si estos se asocian con cambios en algunas características de interés (variables respuesta). En este caso las unidades se denominan unidad experimental.

Planificación del estudio

Estudios exhaustivos vs. Estudios por muestreo:

Los estudios exhaustivos son aquellos donde se estudian todas las unidades elementales. También se denominan censo.

Los estudios donde se analiza un subconjunto del universo de tamaño n, se denominan estudios por muestreo.

¿Qué ejemplos conoces de censos y estudios por muestreo?

Planificación del estudio

Sobre las muestras

Existen diferentes maneras de seleccionar una muestra. No obstante, para extender los resultados de una muestra a toda una población, las muestras deben ser aleatorias o probabilísticas.

Esto significa que cada unidad tenga la misma chance conocida de ser seleccionada. Dentro de las muestras aleatorias existen distintos métodos (simple al azar, sistemático, por conglomerados, estratificado, multietápico) etc.

Además del método, también es importante elegir adecuadamente el tamaño de la muestra.

En este curso: Muestreo Aleatorio Simple

Planificación del estudio

Preguntas a responder en esta etapa:

- ¿Será un estudio observacional o experimental?
- ¿Se trabajará con toda la población o con una muestra?
- Si se toma una muestra, ¿de qué tipo y tamaño será?
- Si se lleva a cabo un experimento… ¿Cómo se diseñará? ¿Con cuantas unidades?
- ¿Cómo se medirán las variables de interés? ¿Con qué métodos o instrumentos?
- ¿Qué tipo de análisis se llevará a cabo? ¿Se requieren herramientas de inferencia estadística?
- ¿Qué riesgos máximos se admiten en el caso de tener que inferir las conclusiones de la muestra a la población?

Recolección de los datos

- En esta etapa se registran los datos y se vuelcan los mismos en una **planilla de registro**. Es fundamental que los datos de calidad, evitando medirlos incorrectamente, ingresandolos de forma completa, completa, y desde fuentes de información confiable.

- Si bien pueden realizarse procesos de **validación** una vez recolectados, es importante establecer **controles** que eviten posibles errores (desde aclaraciones en las preguntas en una encuesta, hasta sistemas que emitan señales si se ingresan errores).

- Es importante garantizar la **trazabilidad** de los datos, principalmente por si aparecen valores dudosos o imposibles.

Recolección de los datos

Una estructura recomendada para el volcado de datos

1	x_1	y_1	$\cdots$	$\cdots$	$\cdots$	z_1
2	x_2	y_2	$\cdots$	$\cdots$	$\cdots$	z_2
$\cdots$	$\cdots$	$\cdots$	$\cdots$	$\cdots$	$\cdots$	$\cdots$
$\cdots$	$\cdots$	$\cdots$	$\cdots$	$\cdots$	$\cdots$	$\cdots$
$\cdots$	$\cdots$	$\cdots$	$\cdots$	$\cdots$	$\cdots$	$\cdots$
$\cdots$	$\cdots$	$\cdots$	$\cdots$	$\cdots$	$\cdots$	$\cdots$
$\boldsymbol{n}$ **(o** $\boldsymbol{N}$**)**	x_n	y_n	$\cdots$	$\cdots$	$\cdots$	z_n

Recolección de los datos

Tareas que se realizan en esta etapa:

- Elaborar instructivos y entrenar a las personas que realicen las mediciones o recaben los datos.
- Hacer una prueba piloto de los métodos de recolección.
- Chequear los métodos de medición
- Diseñar una planilla de registro apropiada.
- Supervisar la tarea de recolección y carga de datos.
- Garantizar, siempre que sea posible, la trazabilidad de los datos.
- Volcar la información obtenida a las planilla de registro.

Análisis de los datos

En esta etapa se realiza:

- Un tratamiento primario (validación, recodificación, revisión, transformación..)
- Se observa si hay datos faltantes, absurdos, códigos mal ingresados, atípicos, etc…
- Un análisis descriptivo, donde se resume la información en tablas, gráficos o medidas.
- Un análisis inferencial con riesgos asociados (si corresponde).
- Si corresponde, se aplican herramientas de inferencia estadística para generalizar las conclusiones a la población.

Análisis de los datos

Importancia del análisis descriptivo, numérico y visual

Interesa el **valor nominal (en $)** del ingreso por hora trabajada en Gran Rosario en personas empleadas que tengan entre 18 y 65 años, el 1er trimestre de 2023. Se seleccionan al azar 518 ciudadanos del Gran Rosario y se les consultó su ingreso mensual y las horas trabajadas al mes. Luego del análisis, se informan los siguientes indicadores:

Indicador	Valor
Promedio	$1036.30
Desvío	$1088.05

- Realizar el planteo del problema y la planificación del estudio.

Análisis de los datos

Importancia del análisis descriptivo, numérico y visual

Interesa el valor nominal (en $) del ingreso por hora trabajada en Gran Rosarios, el 1er trimestre de 2023. Se seleccionan al azar 518 ciudadanos del Gran Rosario y se les consultó su ingreso mensual y las horas trabajadas al mes.

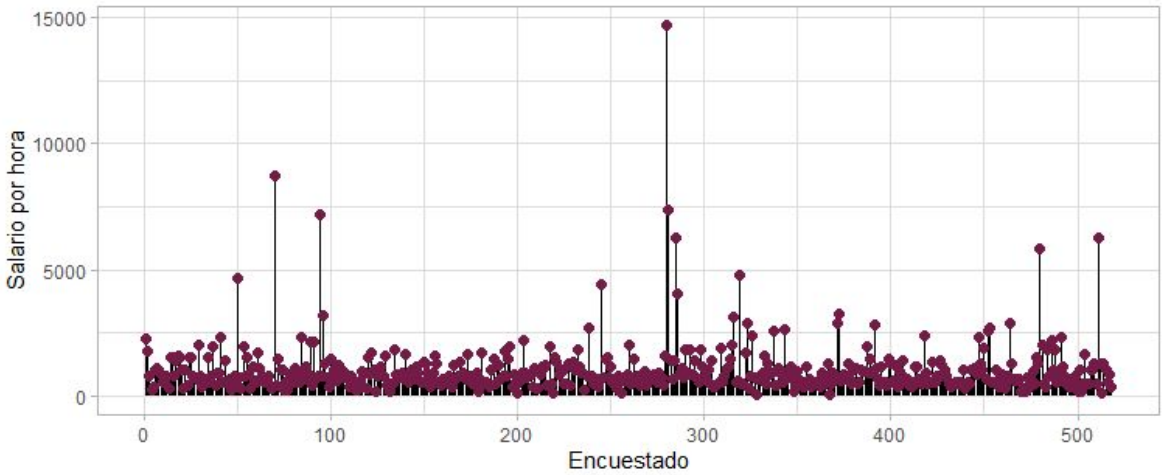

¿Es el promedio el mejor indicador para describir los datos? ¿Qué medidas resultan adecuadas para describir el conjunto de datos?

Conclusiones

En esta etapa se da **respuesta al problema planteado** a partir de los resultados obtenidos en la etapa anterior. Es posible que estas conclusiones estén sujetas a error. La **conclusión estadística** es la interpretación de los resultados de las herramientas estadísticas aplicadas, mientras que la **conclusión en contexto** es la vinculación de la conclusión estadística en la situación.

En el estudio de la producción de barras de acero, en donde se deseaba conocer la proporción de barras producidas válidas (entre 249,4 y 250,6 mm) se toma una muestra de tamaño n = 50, se registran las unidades, se mide su longitud y se evalúa si está en el intervalo definido. Al observar el registro, se contabiliza que 47 de 50 barras se encuentran en el intervalo correspondiente. Defina el problema, la planificación del problema y concluya.

Conclusiones

La **validez externa** de un estudio se refiere a la posibilidad de generalizar las conclusiones del mismo a la población definida en el planteo del problema, y también a otras poblaciones que se consideren similares. La **validez interna** está asociada al diseño del estudio.

Es importante tener claramente definida la población de referencia al momento de elaborar las conclusiones y la posibilidad de considerar estas características en otras poblaciones generales… ¿A qué otras poblaciones se puede generalizar?

Conclusiones

Tareas a realizar en esta etapa:

- Interpretar los resultados en términos estadísticos, comprendiendo el alcance y las limitaciones de las mismas.
- Interpretar dichos resultados en el contexto del problema, dando respuesta al objetivo planteado.
- Considerar la validez externa de las conclusiones.

Actividad

3. Para los siguientes enunciados:
   - De los registros de la Sección Alumnado de la FCEIA se obtuvo que los alumnos de carreras de Ingeniería que completaron el formulario SUR en 2021, aprobaron, en promedio, 4 materias en ese año.
   - Se analizaron las 250 piezas que componen un lote de exportación y se obtuvo que el 2% de las mismas no cumple las especificaciones del cliente.

   Defina un objetivo para el cual el grupo mencionado corresponda a una muestra y uno para el cual constituya la población en estudio.