Probabilidad y Estadística

TUIA - FCEIA

Unidad 2

Gottig, Nicolás
Avila, Aylen
L'heureux, Julián

4. Para cada una de las situaciones enunciadas:
   a) Identifique la/s variable/s en estudio y clasifíquela/s.
   b) 1) Plantee o identifique (según corresponda), algún objetivo para el cual resulte relevante estudiar el comportamiento de dicha/s característica/s en una población.
      2) ¿El objetivo planteado involucra parámetros? ¿Cuál/es?
   c) 1) Identifique la unidad de observación y la población. ¿Es finita o infinita?
      2) Identifique la/s población/es estadística/s en estudio.
   d) Respecto al tipo de estudio:
      1) ¿El estudio es observacional o experimental?
      2) Si el estudio es observacional, ¿considera posible/conveniente llevar adelante un estudio poblacional?
      3) ¿En el estudio, interesa conocer el comportamiento de las variables a través del tiempo?

5. Indique si en las siguientes expresiones relacionadas con las situaciones de la Actividad 4 se involucran parámetros o estadísticos.

   Situación 1: En el último control se observó que el 98 % de las piezas resultaron buenas.

   Situación 3: En el estudio se observó que en los paneles estudiados, el número promedio de poros por metro cuadrado con el aditivo resultó un 5 % menor que el valor correspondiente a paneles pintados sin aditivo.

   Situación 4: Se obtuvo que más del 60 % de las quejas analizadas han sido por daños en el embalaje.

   Situación 5: De los registros se obtuvo que la venta promedio mensual (para los meses registrados) de acero fue de 11000 kg.

Descripción de un conjunto de datos

Recordemos que:

- Muchos procesos y fenómenos de la naturaleza están sujetos a variabilidad.
- Para resolver problemas en presencia de variabilidad… se necesitan datos
- Una vez recolectados los datos, es importante realizar un análisis descriptivo de los mismos.
- Si se tomó una muestra de la población de interés, luego del análisis descriptivo se deben aplicar **herramientas de inferencia** estadística, que permiten la generalización de las conclusiones de una muestra a toda una población, bajo ciertos supuestos.
- El análisis descriptivo provee herramientas para **resumir los datos** y es fundamental antes de cualquier análisis de inferencia.
- El ciclo **PPDAC** sistematiza el proceso de análisis estadístico en 5 etapas.

Descripción de un conjunto de datos

En el análisis descriptivo se resume la información en **tablas**, **gráficos** y **medidas** de posición o dispersión.

Cuando se realiza sobre una variable, se denomina análisis descriptivo **univariado.** Pero también puede ser **bivariado** o multivariado.

En las **tablas de frecuencia** se construyen clases, cuyos elementos tienen características comunes. En ciertos casos, estas clases pueden estar formadas por un único elemento (en las variables categóricas se da con frecuencia).

Como regla general, tratándose de variables cuantitativas, cuando el rango de la variable es muy amplio o la variable es continua las **clases** son grupos por intervalos.

Descripción de un conjunto de datos

Problema 4: *En una empresa dedicada a la comercialización de productos por Internet, están preocupados por el incremento en las devoluciones, lo cual aumenta sus costos operativos y hace que su reputación como vendedores disminuya notoriamente. La Gerencia propone determinar el motivo principal de cada una de estas devoluciones, para detectar las causas más frecuentes e implementar luego acciones para mejorar el servicio y no seguir perdiendo clientes. En la Gerencia sospechan que una de las posibles causas podría ser el retraso en la entrega por problemas en el transporte y consideran que si esta causa representa más del 30% de las devoluciones, se justifica la contratación de una nueva empresa prestadora. Respecto de las causas restantes, las mejoras se implementarán de acuerdo a lo que se encuentre en el estudio.*

Descripción de un conjunto de datos

Problema 4 (pág. 7): *En este problema se analizan las 350 devoluciones de productos vendidos por Internet por la empresa durante el último semestre del corriente año, las cuales se pueden considerar una muestra de la totalidad de las devoluciones de la empresa. La variable es el motivo principal de cada devolución, variable cualitativa medida en escala nominal.*

Tabla 2.3. *Tabla de distribución de frecuencias para los motivos principales de 350 devoluciones.*

Motivo principal	*N° de devoluciones (n_i)*	*Proporción de devoluciones (f_i)*
Error en la facturación (c_1)	*40 (n_1)*	*0,1143 (f_1)*
Pedido equivocado (c_2)	*58 (n_2)*	*0,1657 (f_2)*
Precio final no coincidente (c_3)	*25 (n_3)*	*0,0714 (f_3)*
Producto dañado (c_4)	*76 (n_4)*	*0,2171 (f_4)*
Producto mal embalado (c_5)	*15 (n_5)*	*0,0429 (f_5)*
Producto vencido o en mal estado (c_6)	*21 (n_6)*	*0,0600 (f_6)*
Retraso en la entrega (c_7)	*115 (n_7)*	*0,3286 (f_7)*
Total	*350 (n)*	*1*

Actividad: Realizar la interpretación en términos del problema de la fila 2 y 4.

Descripción de un conjunto de datos

Problema 4 (pág. 7): *En este problema se analizan las 350 devoluciones de productos vendidos por Internet por la empresa durante el último semestre del corriente año, las cuales se pueden considerar una muestra de la totalidad de las devoluciones de la empresa. La variable es el motivo principal de cada devolución, variable cualitativa medida en escala nominal.*

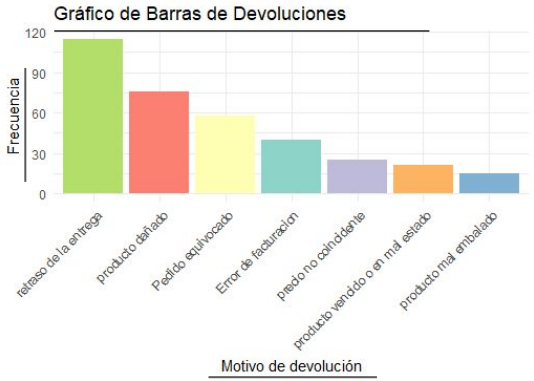

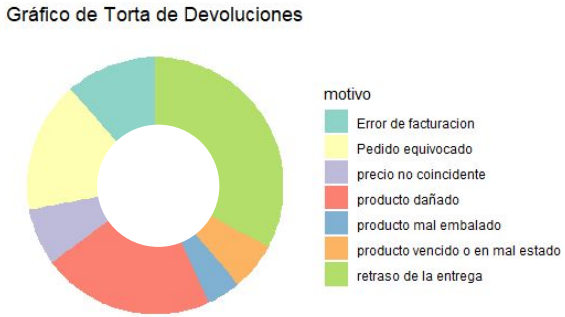

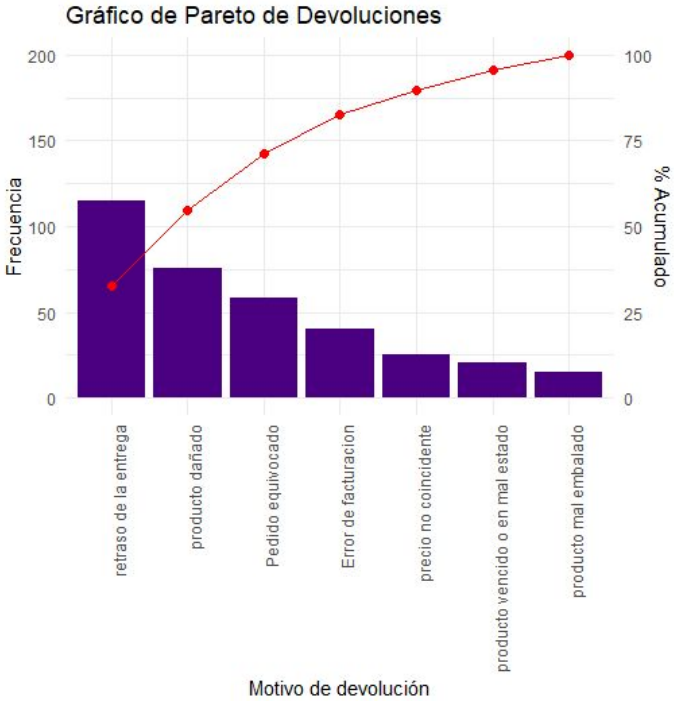

Descripción de un conjunto de datos

Problema 5: *Una empresa distribuidora de la energía de Santa Fe desea evaluar la ocurrencia mensual de fallas en una de las subestaciones, ubicada en el sur de la provincia. Interesan solo las fallas debidas propiamente al proceso de distribución que generen interrupciones en el servicio eléctrico mayores a 1 minuto.*

Problema 5 (pág. 7): *En cada uno de los últimos 50 meses, se registró la cantidad de fallas propias del sistema de distribución, siempre que generaron interrupciones del servicio eléctrico superiores a 1 minuto (en adelante, fallas), y_i. Una parte de la planilla de registro se presenta en la Figura 2.5.*

Tabla 2.4. *Tabla de distribución de frecuencias correspondiente al número de fallas por mes.*

N° de fallas por mes (y_j)	Cantidad de meses (n_j)	Proporción de meses (f_j)	Cantidad acumulada de meses (N_j)	Proporción acumulada de meses (F_j)
0 (c_1)	23 (n_1)	0,46 (f_1)	23 (N_1)	0,46 (F_1)
1 (c_2)	17 (n_2)	0,34 (f_2)	40 (N_2)	0,80 (F_2)
2 (c_3)	7 (n_3)	0,14 (f_3)	47 (N_3)	0,94 (F_3)
3 (c_4)	1 (n_4)	0,02 (f_4)	48 (N_4)	0,96 (F_4)
4 (c_5)	2 (n_5)	0,04 (f_5)	50 (N_5)	1,00 (F_5)
Total	50 (n)	1	–	–

Actividad: Realizar el planteo del problema. Identificar cómo se accede a los datos (planificación del estudio).

Interprete la fila 1 y 3

Descripción de un conjunto de datos

1. Una empresa produce piezas especiales para maquinaria agrícola. En el proceso de producción, las piezas pasan por siete etapas diferentes. Con el objeto de mejorar la calidad de las piezas se inspeccionaron todas las producidas en el último mes y se detectaron 318 defectos. Especialistas determinaron luego en qué etapa del proceso se produjeron dichos defectos. Con los datos obtenidos se construyeron la tabla de distribución de frecuencias y el gráfico de barras que a continuación se presentan:

Etapa en la que se produjo el defecto	Nro. de defectos	Proporción de defectos
Etapa 1	74	0,2327
Etapa 2	81	0,2547
Etapa 3	111	0,3491
Etapa 4	26	0,0818
Etapa 5	16	0,0503
Etapa 6	3	0,0094
Etapa 7	7	0,022
Total	**318**	**1**

Descripción de un conjunto de datos

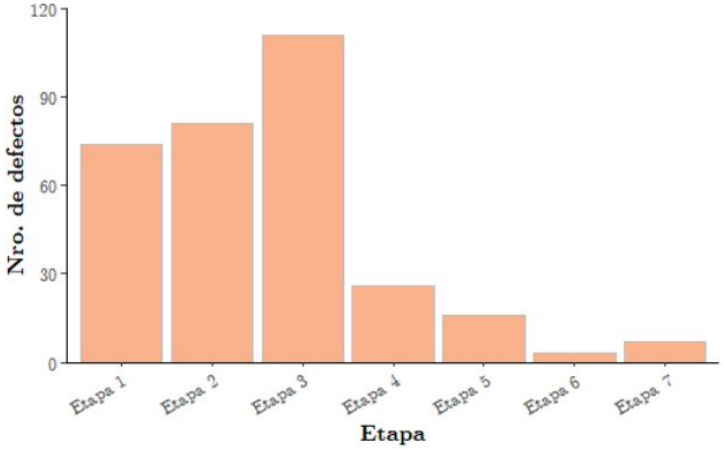

a) Mencione algún objetivo para el cual los defectos analizados constituyan una muestra. Especifique unidad elemental, población y variable en estudio.

b) ¿Qué puede decir de la etapa del proceso en la que se produjeron los defectos? Interprete los resultados obtenidos.

c) Construya otro gráfico con la misma información.

Descripción de un conjunto de datos

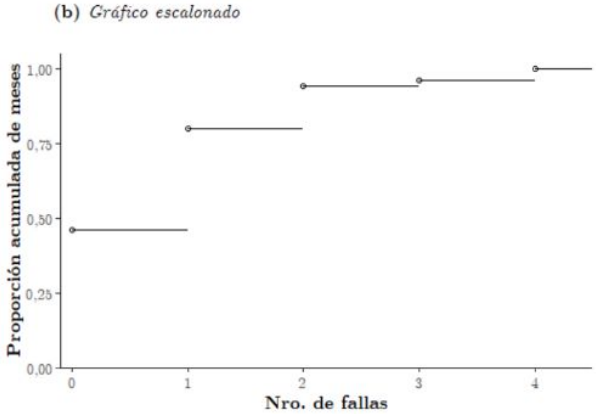

Descripción de un conjunto de datos

Problema 1: *Una empresa metalúrgica de la provincia de Santa Fe fabrica diferentes tipos de barras de acero que luego se utilizan en la construcción y en otras industrias.*
Una empresa automotriz de la zona requiere uno de los tipos de barras y está dispuesta a comprarlas siempre y cuando sus longitudes se encuentren dentro del intervalo 250 +/- 0,6 mm.
En la gerencia de la empresa metalúrgica están interesados en convertirse en proveedores de esta empresa para lo cual necesitan estudiar si la producción cumple los requerimientos impuestos en relación a las longitudes.

En la gerencia de la empresa metalúrgica están interesados en convertirse en proveedores de esta empresa para lo cual necesitan estudiar si la producción cumple los requerimientos impuestos en relación a las longitudes.

Suponga que para cumplir ese objetivo se selecciona una muestra aleatoria de n = 120 barras, tomadas del proceso estabilizado y en cada una de ellas se evalúa su longitud, en mm. Una parte de la planilla de registro se presenta en la Figura 2.8.

Actividad: Comentar cuestiones del planteo del problema y la planificación del estudio.

Descripción de un conjunto de datos

Suponga que para cumplir ese objetivo se selecciona una muestra aleatoria de n = 120 barras, tomadas del proceso estabilizado y en cada una de ellas se evalúa su longitud, en mm. Una parte de la planilla de registro se presenta en la Figura 2.8.

Tabla 2.7. *Tabla de distribución de frecuencias para las longitudes de las barras analizadas.*

Longitud (mm) (y_j)	Nro. de barras (n_j)	Proporción de barras (f_j)	Nro. acumulado de barras (N_j)	Proporción acumulada de barras (F_j)
(249,2 ; 249,4] (c_1)	3 (n_1)	0,0250 (f_1)	3 (N_1)	0,0250 (F_1)
(249,4 ; 249,6] (c_2)	8 (n_2)	0,0667 (f_2)	11 (N_2)	0,0917 (F_2)
(249,6 ; 249,8] (c_3)	26 (n_3)	0,2166 (f_3)	37 (N_3)	0,3083 (F_3)
(249,8 ; 250,0] (c_4)	23 (n_4)	0,1917 (f_4)	60 (N_4)	0,5000 (F_4)
(250,0 ; 250,2] (c_5)	30 (n_5)	0,2500 (f_5)	90 (N_5)	0,7500 (F_5)
(250,2 ; 250,4] (c_6)	21 (n_6)	0,1750 (f_6)	111 (N_6)	0,9250 (F_6)
(250,4 ; 250,6] (c_7)	6 (n_7)	0,0500 (f_7)	117 (N_7)	0,9750 (F_7)
(250,6 ; 250,8] (c_8)	3 (n_8)	0,0250 (f_8)	120 (N_8)	1 (F_8)
Total	120 (n)	1	–	–

Interprete la primera y la 7ma clase.

¿Cuántas clases?

- Depende del problema
- Raíz de n
- Regla de Sturges $k = 1 + \log_2(n)$

Descripción de un conjunto de datos

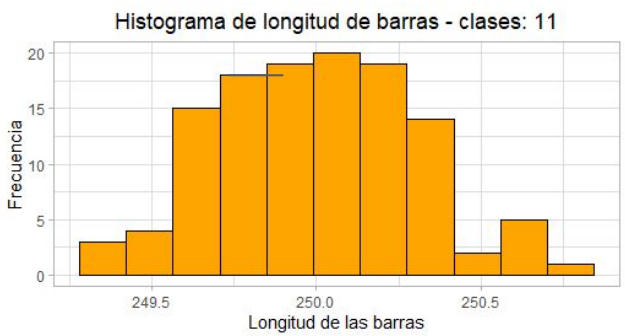

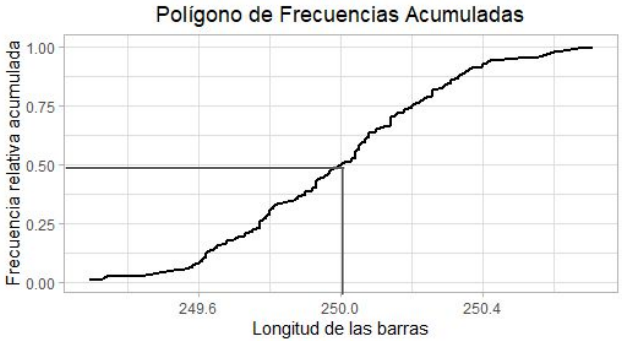

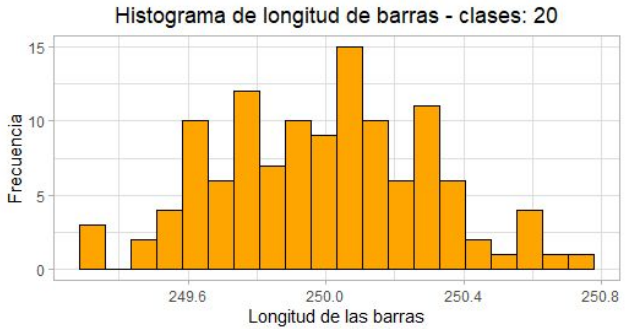

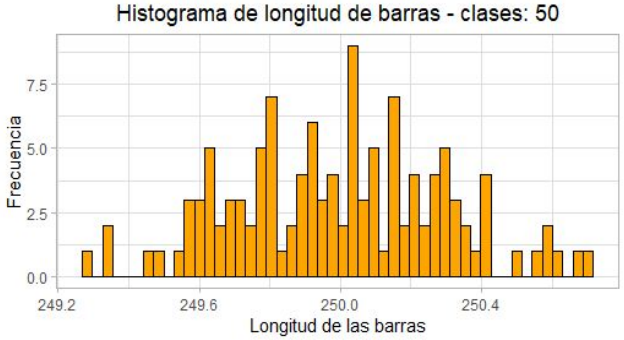

Descripción de un conjunto de datos

6. En la fabricación de chips para circuitos integrados hay una variable, denominada amplitud de ventana, que está relacionada con los procedimientos de interconexión entre los circuitos. Se desea estudiar el comportamiento de esta variable y para ello se mide la amplitud de ventana (en milimicras, Mm) en una muestra aleatoria de 40 lugares (puntos de interconexión de los circuitos), obteniéndose el gráfico que se presenta a continuación.

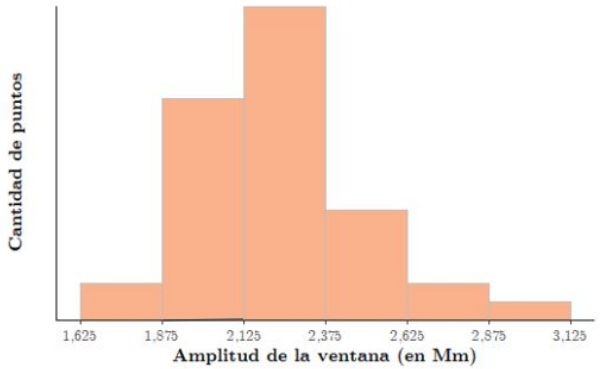

a) Especifique unidad elemental, población y variable en estudio.

b) Indique cuál es la amplitud de los intervalos y trace el polígono de frecuencias. Complete el gráfico con lo que corresponda.

c) ¿En qué intervalos se observan las mayores frecuencias?

unidad: cada punto de interconexión

Pob.: Todos los puntos de interconexión de los circuitos integrados producidos

Var.: Amplitud de ventana (en Mm)

n = 40

Descripción de un conjunto de datos

3. En una industria textil interesa evaluar la calidad del estampado de cierto tipo de tela de algodón. Con ese objetivo, de la producción de un día en particular se toma una muestra de 80 trozos de tela (todos de 1 m^2 de superficie) y en cada uno se observa la cantidad de defectos. Con los datos obtenidos se construyeron la tabla de distribución de frecuencias y el gráfico de bastones que a continuación se presentan:

Nro. de defectos por trozo	Nro. de trozos	Proporción de trozos	Nro. de trozos acumulados	Proporción de trozos acumulada
0	17	0,2125	17	0,2125
1	30	0,3750	47	0,5875
2	20	0,2500	67	0,8375
3	10	0,1250	77	0,9625
4	2	0,0250	79	0,9875
5	1	0,0125	80	1,0000
Total	**80**	**1**		

Descripción de un conjunto de datos

a) Especifique unidad elemental, población y variable en estudio.

b) Interprete una fila de la tabla de distribución de frecuencias.

c) Complete las siguientes oraciones y señale las frecuencias mencionadas en el gráfico de bastones cuando corresponda:

1) El ..... % de los trozos tiene como máximo 1 defecto.
2) El ..... % de los trozos tiene exactamente 2 defectos.
3) ..... trozos tienen al menos 4 defectos.
4) El 98,7 % de los trozos tiene como máximo ..... defectos.

Sobre simetría y curtosis

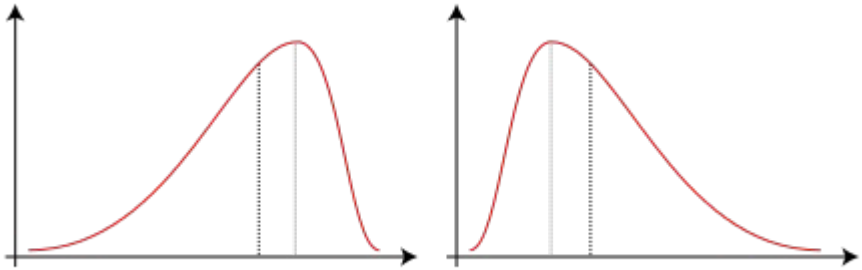

Asimetría

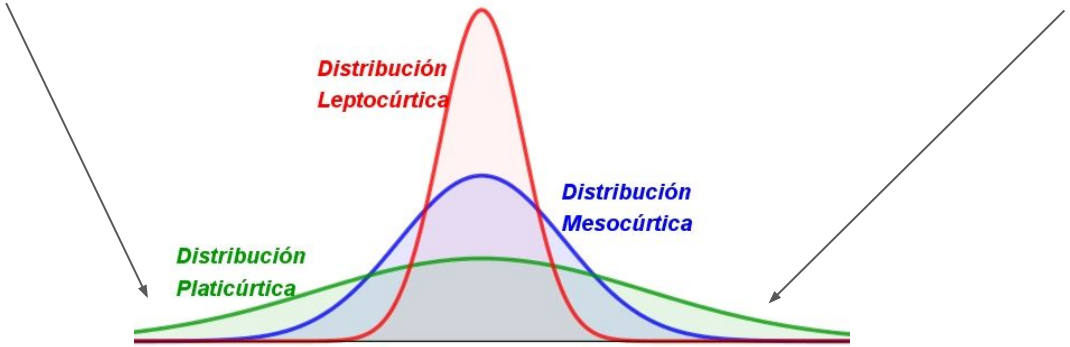

Curtosis

Series de tiempo

Cuando los datos son registrados en el tiempo la descripción debe hacerse sobre la serie, ya que no siempre las medidas pueden ser representativas.

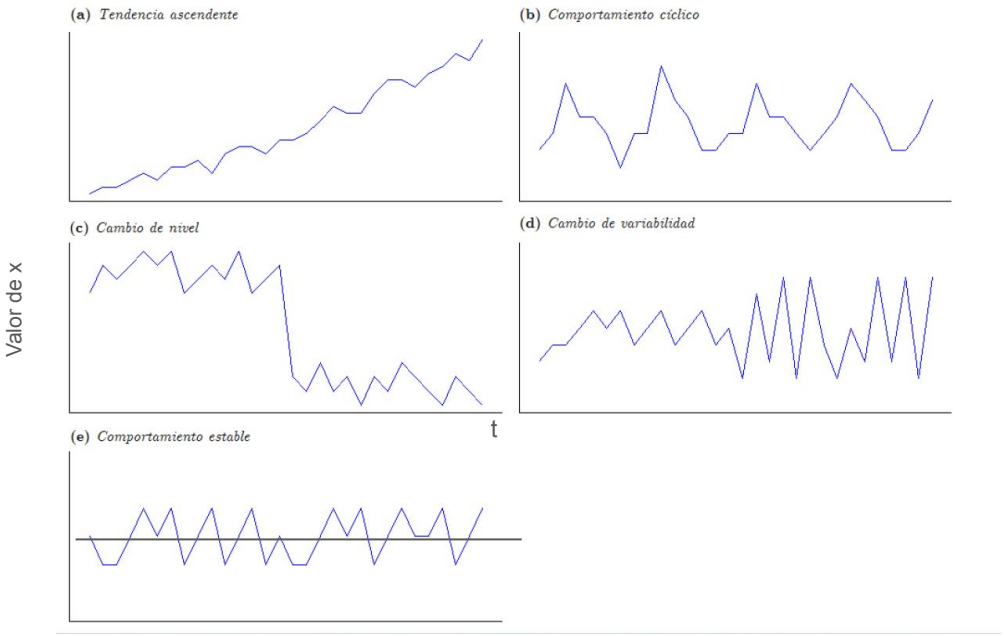

Series de tiempo

Cuando los datos son registrados en el tiempo la descripción debe hacerse sobre la serie, ya que no siempre las medidas pueden ser representativas.

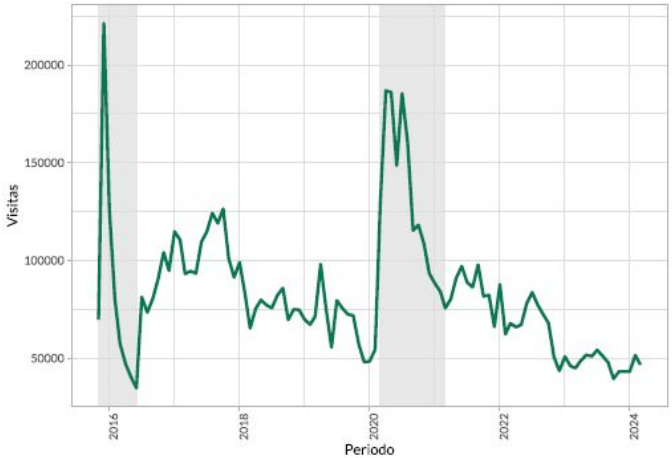

Figura 1: Evolución de las visitas mensuales (2015-2024)

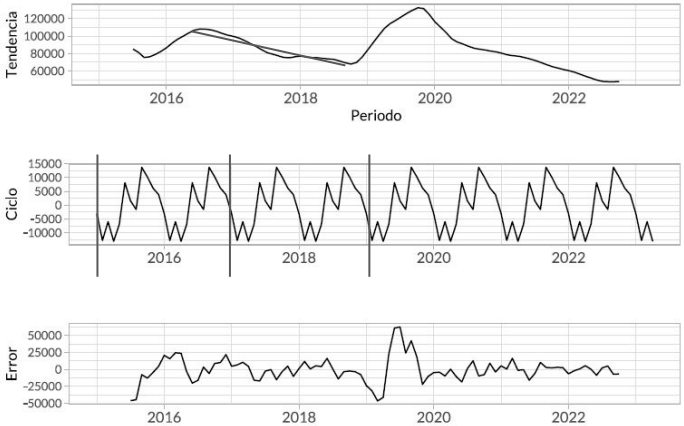

Figura 3: Descomposición de la serie

acceso a plataforma Cine.Ar play

Algunas preguntas

¿En qué casos tiene sentido obtener e interpretar frecuencias acumuladas?

¿Cómo se representan gráficamente las frecuencias no acumuladas (absolutas o relativas) en el caso de variables discretas y en el caso de variables continuas?

Si los datos se han registrado a través del tiempo….. ¿en qué casos tiene sentido construir con ellos una distribución de frecuencias?

¿Qué elementos debe contener, necesariamente, un gráfico?

Consideraciones

- El título debe ser completo de manera de brindar toda la información necesaria, sin resultar reiterativo.
- No es necesario indicar qué tipo de gráfico o tabla es presentada. El título debe dar información en relación a la variable que se está graficando. Deben estar numeradas para poder referenciarlas en el texto.
- La información no debe duplicarse: No es correcto presentar la misma información más de una vez. El criterio del analista determina la mejor manera de resumir los datos.
- Se debe mantener la misma cantidad de decimales en todo el análisis.
- Las frecuencias acumuladas sólo tienen sentido si se trata de variables capaces de ser ordenadas. Si no es ordinal, es una buena práctica ordenar las categorías según su frecuencia.

Medidas

Las medidas de resumen informan sobre la localización y la variabilidad de un conjunto de datos.

Recordemos que cuando la medida de resumen se obtiene a partir de información de toda la población, se denomina parámetro, mientras que si se obtiene sobre una muestra de tamaño n se denomina estadístico y se utiliza una notación distinta.

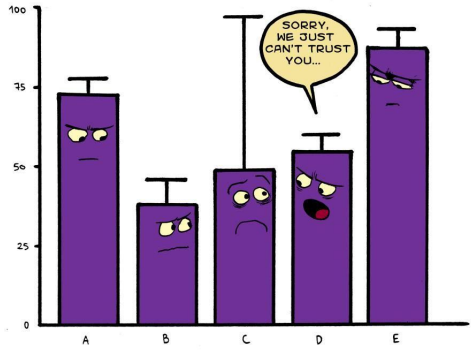

Medidas

TIPOS DE INDICADORES

Medidas de posición

De tendencia central (media, mediana, moda) de tendencia no central (mínimo, máximo, percentiles)

Medidas de dispersión

Desvíos, variancia, desviación estándar, rango intercuartílico, etc…

Medidas

- **MEDIDAS DE POSICIÓN DE TENDENCIA CENTRAL Y NO CENTRAL**
- **Valor mínimo** es el menor valor observado en el conjunto de datos.
- **Valor máximo** es el mayor valor observado en el conjunto de datos.

- **Percentiles** Si p_α indica el valor de la variable que acumula el $\alpha\%$ de las observaciones ordenadas.

**Existen algunos percentiles de uso frecuente como los deciles, los cuartiles o la mediana.*

Medidas

GRUPOS DE PERCENTILES USADOS FRECUENTEMENTE:

Deciles: dividen en 10 intervalos de 10 % cada uno el total del conjunto de datos.

1er decil, 2do decil…10mo decil.

Cuartiles: dividen en 4 partes de 25 % cada uno el total del conjunto de datos.

1er cuartil, 2do cuartil, 3er cuartil y 4to cuartil.

Medidas

- **CONSIDERACIONES SOBRE LOS PERCENTILES:**
- Los datos deben estar ordenados. Se haya la posición del valor en el conjunto de datos:

$$(p_a)^o = \frac{a.n}{100}$$

- **Si los datos están sin agrupar:**
- Ese número tiene una parte entera y una decimal. Si la parte decimal es no nula, entonces: $p_\alpha = y_{[E+1]}$ en cambio, si la parte decimal es nula, entonces $p_\alpha = \frac{1}{2}(y_{[E]} + y_{[E+1]})$ siendo E el valor entero del orden del percentil.

Medidas

- **Si los datos están agrupados:**
- Si las clases tienen un único valor, entonces p_α es el valor de la variable correspondiente a la primera clase que acumula, como mínimo, el $\alpha\%$ *del los datos*.
- Si las clases tienen intervalos y $F(y_h).100\% = \alpha\%$ se considera como valor aprox. Del percentil el extremo superior del intervalo. De otra forma, si $F(y_h).100\% > \alpha\%$ se puede considerar al punto medio del intervalo.

Medidas

Tiempo de espera (minutos)	Frecuencia	Fr	Fr acum.
1	3	0.03	0.03
2	5	0.06	0.09
3	8	0.09	0.18
4	12	0.13	0.31
5	15	0.17	0.48
6	18	0.20	0.68
7	14	0.16	0.84
8	9	0.10	0.94
9	5	0.05	0.99
10	1	0.01	1

Tiempos de espera en la atención de pacientes en un centro de cardiología, observados el último mes.

Defina población, variable y unidad de medida.

¿Cuál es el percentil 25 y el percentil 50? interprete en términos del problema

Medidas

1, 2, 2, 2, 3, 3, 4, 4, 5, 6, 6, 7, 7, 8, 9, 10, 11, 11, 10, 10

Tiempo de espera (en minutos). Ejemplo de datos no agrupados

PERCENTIL 25

$$(p_{25})^o = \frac{25.20}{100} = 5$$

$$p_{25} = (y_{[E]} + y_{[E+1]})\frac{1}{2} = \frac{3+3}{2} = 3$$

PERCENTIL 33

$$(p_{33})^o = \frac{33 * 20}{100} = 6{,}6$$

$$p_{33} = y_{[E+1]} = 7$$

Medidas

Los percentiles también pueden obtenerse aproximadamente a partir del polígono acumulativo, como se observa en la Figura 2.18.

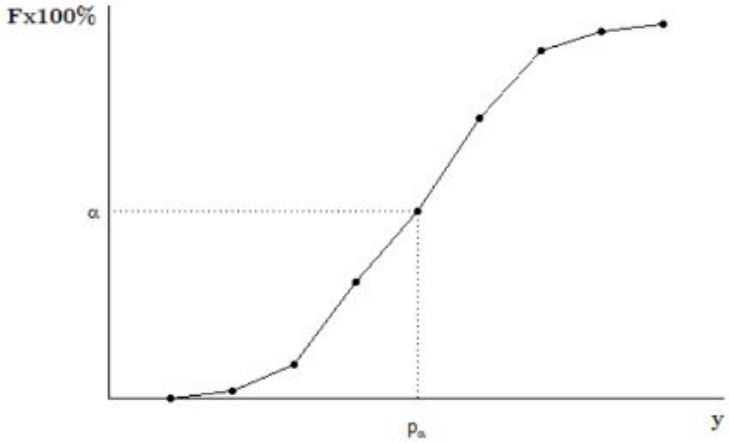

Figura 2.18. *Determinación aproximada del valor de un percentil a partir del polígono acumulativo.*

Medidas

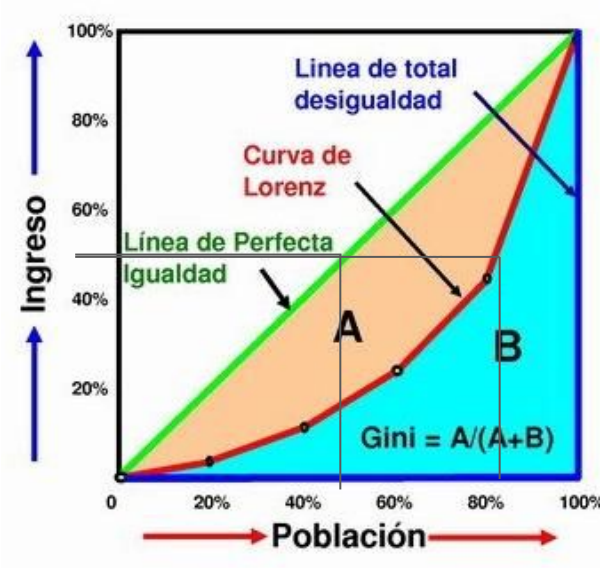

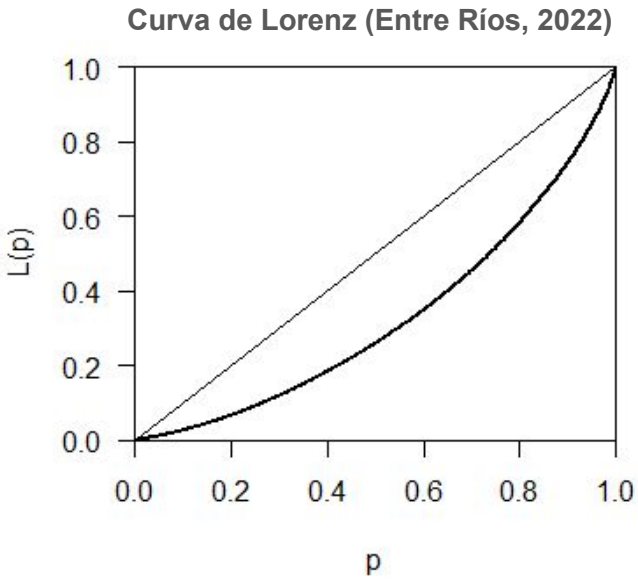

Aplicación: El coeficiente de Gini es una medida de desigualdad en la distribución de la riqueza, calculada en función del acceso al ingreso de la población acumulada.

Medidas

MEDIDAS DE TENDENCIA CENTRAL

Media: “Centro de gravedad” del conjunto de datos. Existen distintos cálculos tales como la media aritmética (promedio), geométrica, truncada, ponderada, armónica, etc..

Mediana: Es el valor que se encuentra en la posición media del conjunto de datos ordenados. Es equivalente al 2do cuartil, o al 5to decil, etc…

Moda: Es el valor con mayor frecuencia. Útil para datos agrupados o variables cualitativas.

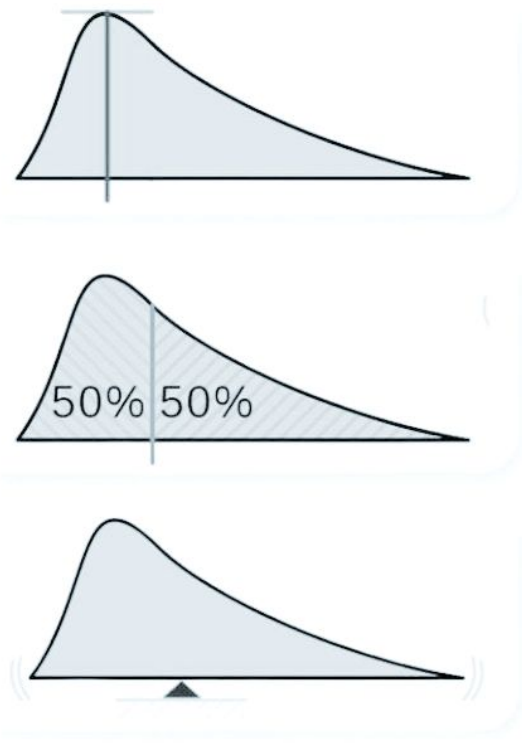

Medidas

$$\bar{y} = \frac{1}{n}\sum_{i=1}^{n} y_i.$$

Datos no agrupados

$$\bar{y} = \frac{1}{n}\sum_{j=1}^{k} y_j n_j = \sum_{j=1}^{k} y_j f_j,$$

Datos agrupados

MEDIA ARITMÉTICA

Al tener en cuenta toda la información es sensible a los valores atípicos. Si dos distribuciones tienen formas semejantes, es un indicador útil para compararlas.

MEDIA TRUNCADA

Su cálculo incluye ordenar los datos, extraer del conjunto un p% de valores en cada extremo y luego calcular la media aritmética. Hecho esto la medida se denomina media truncada de orden p. Cuando la cantidad de valores a eliminar no coincide con un número entero, se pueden calcular dos medias truncadas e interpolar.

Existen otros tipos de medidas de tendencia central, con aplicaciones en campos específicos: media armónica, media geométrica, etc.

Medidas

Tiempo de espera (en minutos)

1, 2, 2, 2, 3,

4, 4, 4, 5, 5,

6, 6, 6, 7, 8,

8, 8, 8, 9, 10

MEDIA TRUNCADA AL 10%

Quitamos el 10 % de cada lado en el conjunto ordenado. En este caso al ser 20 datos, truncamos dos por la izquierda y 2 por la derecha, luego calculamos la media.

$$\overline{y_{10\%}} = (2 + 2 + 3 + \cdots + 8 + 8 + 8 + 8) * \frac{1}{16} = 5.37$$

Si la cantidad de elementos a quitar no es entera (En este caso un ejemplo es la media truncada al 15 %) se interpola las medias al 10 % y al 20 %.

Medidas

Se cuenta con los siguientes datos: 10, 12, 8, 15 y 13. Se desea obtener el promedio.

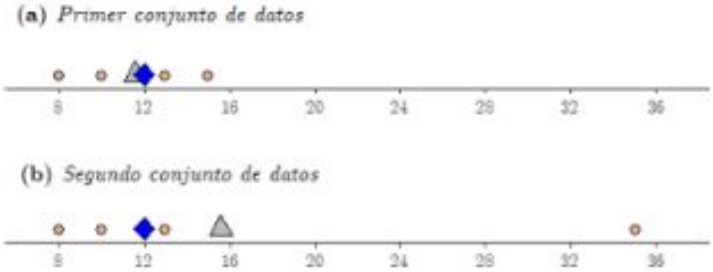

Suponga que el 15 se reemplaza por 35. ¿Qué sucede con el promedio?

¿Qué sucede con la mediana en los casos anteriores?

Medidas

Es el valor de la variable que presenta el máximo relativo más alto. Si no existe uno más alto, entonces la distribución de ese conjunto es bimodal o multimodal o uniforme.

Aunque se puede obtener con variables cuantitativas, es más útil si la variable es cualitativa o si los datos están agrupados en intervalos (intervalo modal).

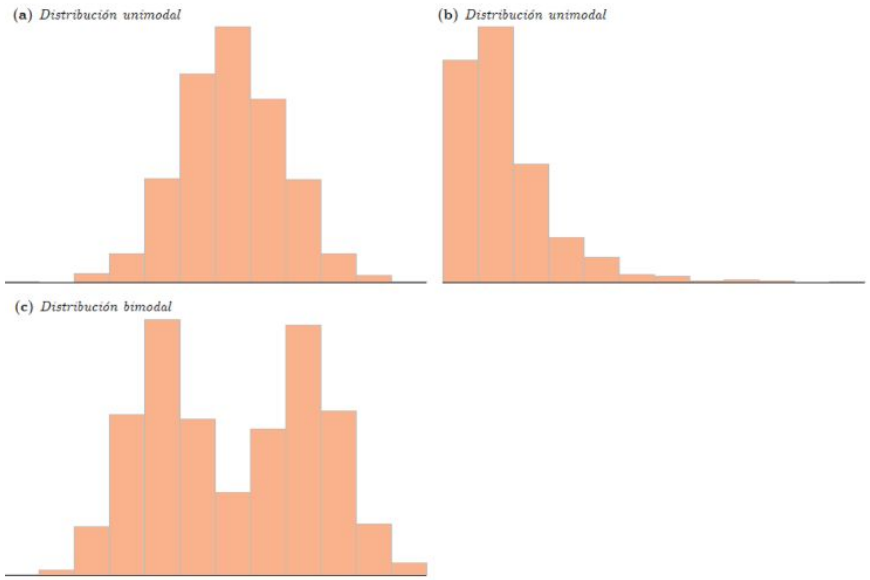

Medidas

La **varianza** identifica y resume cuanto se aleja el resto de los datos del promedio.

$$s^2 = \frac{\sum_{i=1}^{n}(y_i - \bar{y})^2}{n-1},$$

Datos no agrupados

$$s^2 = \frac{\sum_{j=1}^{k}(y_j - \bar{y})^2 \cdot n_j}{n-1},$$

Datos agrupados

varianza muestral

Medidas

DESVÍO ESTÁNDAR

Está expresado en la misma unidad de medida que la variable.

$$s = \sqrt{s^2} \qquad s = \sqrt{7.93} = 2.81$$

RANGO

Es la distancia entre el valor máximo y el valor mínimo de la distribución de datos. Si se calcula la distancia entre el tercer y el primer cuartil, se denomina ***rango intercuartílico*** y representa la variabilidad de los valores del 50% de los datos centrales, siendo más robusto frente a la presencia de atípicos.

$$r = y_{max} - y_{min} \qquad ric = q_3 - q_1$$

Medidas

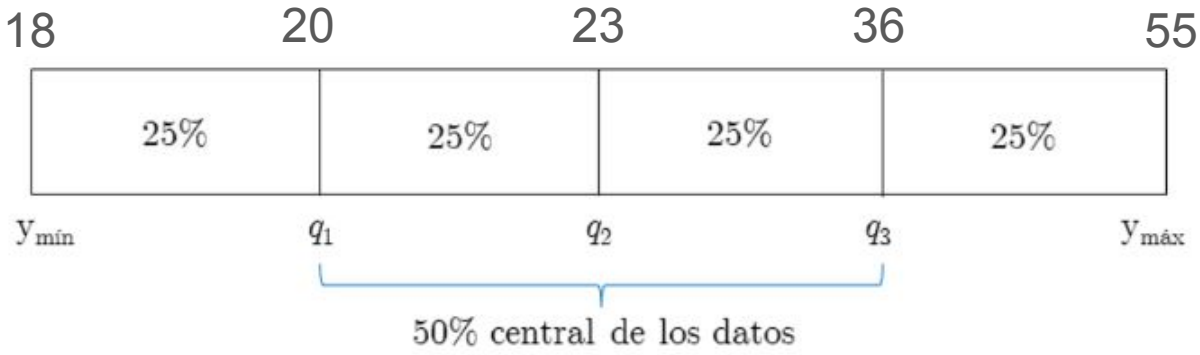

La mediana de edad es de 23 años. Es decir, el 50 % de los estudiantes relevados tienen hasta 23 años. El Rango Intercuartílico es de 16 años, variando entre 20 y 36 años.

Medidas

El **coeficiente de variación** es una medida de variación relativa y por lo tanto, útil para comparar la variabilidad de dos muestras, estén o no en la misma unidad.

Una cadena multinacional de comida rápida quiere evaluar no solo el tiempo promedio de espera, sino también la consistencia del servicio en sus distintas sucursales. Para ello selecciona 10 pedidos al azar en cada una y registra el tiempo (en minutos) transcurrido entre que el cliente hace el pedido y efectivamente lo retira. Con el objetivo de comparar la estabilidad del servicio y ajustar procesos, se calcula el coeficiente de variación de cada sucursal y se resumen los resultados en la siguiente tabla

Tiempo de espera			
Sucursal	**Promedio**	**Desvío E.**	Coef. Var.
A	5,48	2,81	51.28 %
B	3,33	2,4	72.07 %
C	6,54	3,33	50.91 %

$$cv = \frac{s}{\bar{y}}.100$$

Medidas

Descripción del problema (a y b)

7. Los siguientes datos corresponden a 20 observaciones del tiempo (en segundos) que un cliente esperó al teléfono al representante de un determinado servicio:
   7 - 7 - 15 - 21 - 15 - 22 - 40 - 8 - 40 - 6 - 18 - 14 - 5 - 7 - 8 - 3 - 8 - 4 - 40 - 5
   a) Identifique unidad de observación, población, población estadística.
   b) Indique si la población es finita o infinita.
   c) Realice el gráfico que considere adecuado teniendo en cuenta que son pocos datos.
   d) Plantee un parámetro que sea de interés estimar como objetivo en este problema.
   e) Calcule e interprete el parámetro seleccionado en el ítem d.
   f) ¿Cuál es la proporción de clientes que esperan más de 20 segundos?
   g) Realizar un boxplot en R. Describirlo

Valores atípicos

¿QUÉ PASA SI HAY CASOS ATÍPICOS?

Los casos atípicos pueden distorsionar las medidas, lo que puede llevar a conclusiones erróneas o incorrectas sobre los datos. Hay medidas más robustas que otras (por ejemplo la mediana y el rango intercuartílico).

En general, un valor se considera atípico cuando: es mayor que Q3 + 1,5.riq o bien es menor que Q1 - 1,5.riq

1. Preguntarse si son valores posibles de la variable.
2. Si no es así, ¿Por qué están? ¿Se pueden volver a observar?
3. Si no puedo, y no son valores posibles.. se pueden eliminar.
4. Si son valores posibles, conviene usar otras medidas de descripción (ej. Mediana y RIQ)

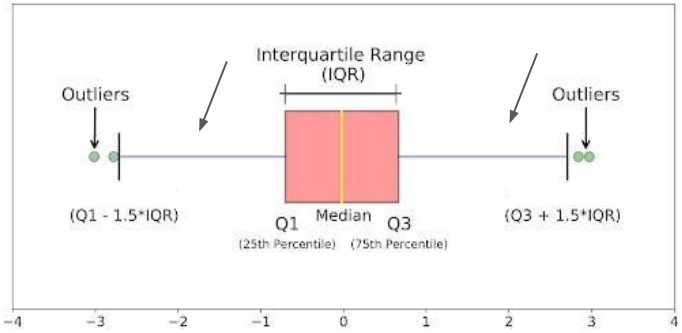

Valores atípicos

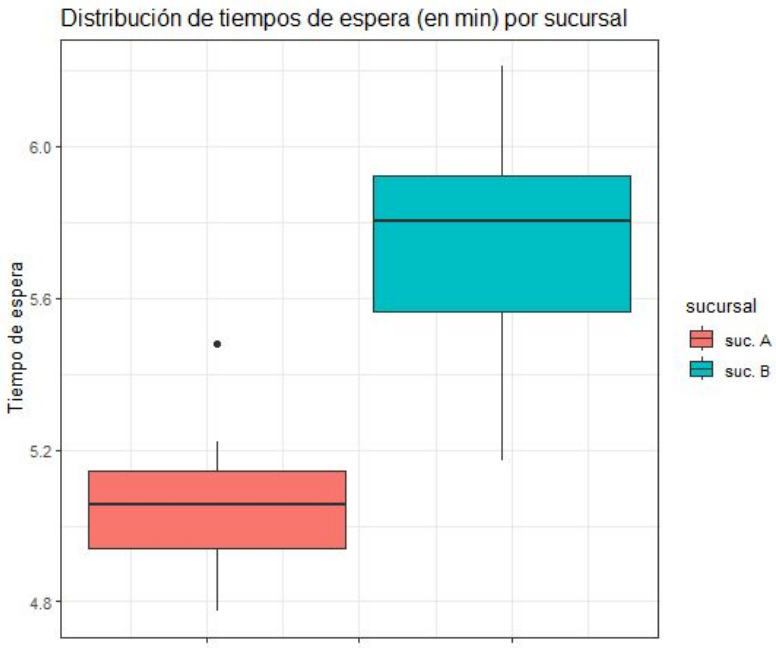

Una cadena multinacional de comida rápida sospecha que los tiempos de espera en una sucursal son notablemente distintos a los brindados en el servicio en general, donde se espera que **la mayoría de las personas demoren 5 minutos o menos en recibir sus pedidos**. Para evaluarlo, selecciona 10 pedidos al azar en cada sucursal y registra el tiempo (en minutos) entre que el cliente hace el pedido y efectivamente lo retira.

Defina población, variable y parámetro de interés. También identifique un objetivo en términos estadísticos.

Describa el histograma y las medidas presentadas a continuación:

sucursal	min	q1	mediana	mean	sd	q3	max	cv
suc. A	4.78	4.92	5.02	5.04	0.22	5.11	5.42	0.04
suc. B	4.90	6.14	6.38	6.11	0.33	6.46	6.63	0.09

La sucursal A presenta un menor promedio en las esperas analizadas, específicamente de 5.04 minutos con un desvío de 0.22 minutos.
Por otro lado, la sucursal B presenta un promedio de 6.11 minutos de espera, con un desvío de 0.33 minutos.

24. Para los siguientes conjuntos de datos se construyeron el histograma y el diagrama de caja correspondiente. A continuación se presentan los gráficos obtenidos:

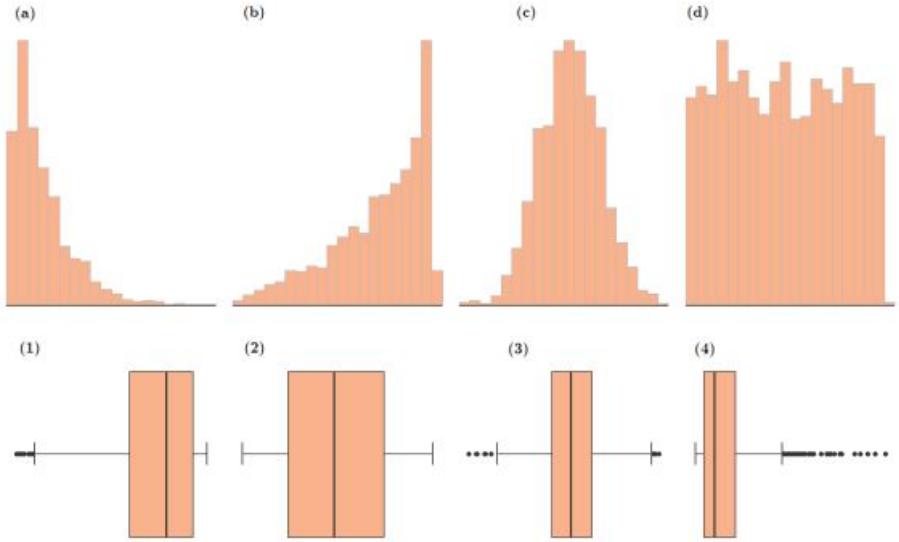

a) Relacione cada histograma con el diagrama de caja que representa el mismo conjunto de datos.

b) Las distribuciones (c) y (d) tienen el mismo rango. Indique cuál de las dos tiene mayor variancia. Justifique.

27. Una empresa de servicios informáticos cuenta con un sistema de atención telefónica de los clientes, habilitado de lunes a viernes, de 9 a 17 horas. Dos operadores capacitados atienden las llamadas y buscan solucionar los problemas y reclamos ellos mismos y derivan, si es necesario, la consulta a un especialista, que actúa como supervisor.

Cuando un cliente no puede comunicarse telefónicamente con la empresa porque los operadores están ocupados, el sistema le permite dejar un mensaje breve. Este mensaje es luego analizado directamente por el supervisor, que devuelve la llamada al cliente y trata de solucionar su problema.

En la empresa consideran que, si el número promedio diario de mensajes breves es mayor que 5, debe incorporarse un nuevo operador al servicio, para no restar tiempo al supervisor, que tiene asignadas además otras tareas. En los últimos 45 días hábiles se registró el número de mensajes breves.

A partir de estos datos, ¿qué decisión deben tomar en la empresa en relación a la contratación de un nuevo operador? Indique si sus conclusiones son preliminares o definitivas.

La planilla de volcado correspondiente se presenta a continuación:

Transformaciones lineales

Conociendo las **medidas resumen** para una variable Y, pueden obtenerse las medidas resumen de la variable transformada X habiéndose aplicado una transformación lineal tal que:

$$x_i = \alpha + \beta y_i$$

Si solo se **suma o resta una constante**, el promedio de la variable transformada se obtiene sumando o restando esa constante al promedio anterior. Lo mismo sucede con las medidas de posición (mínimo, máximo, percentiles). *¿Qué sucede con la varianza?*

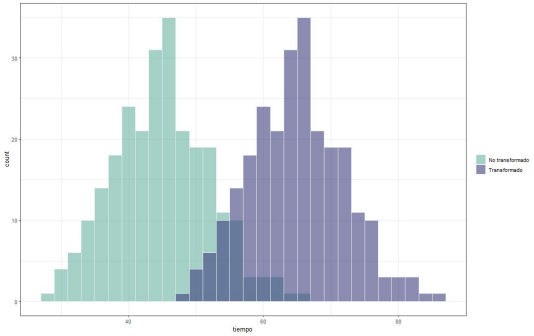

Si sólo se suma una constante (beta = 1) la distribución se traslada

Transformaciones lineales

Si solo se **multiplica** por un factor, el promedio transformado se obtiene multiplicando el promedio anterior por el factor, mientras que el desvío se obtiene multiplicando el desvío por el valor absoluto del factor. Las medidas de posición y dispersión (mínimo, máximo, percentiles, rango o rango intercuartílico) se obtienen multiplicando el factor a los valores de esas variables sin transformar.

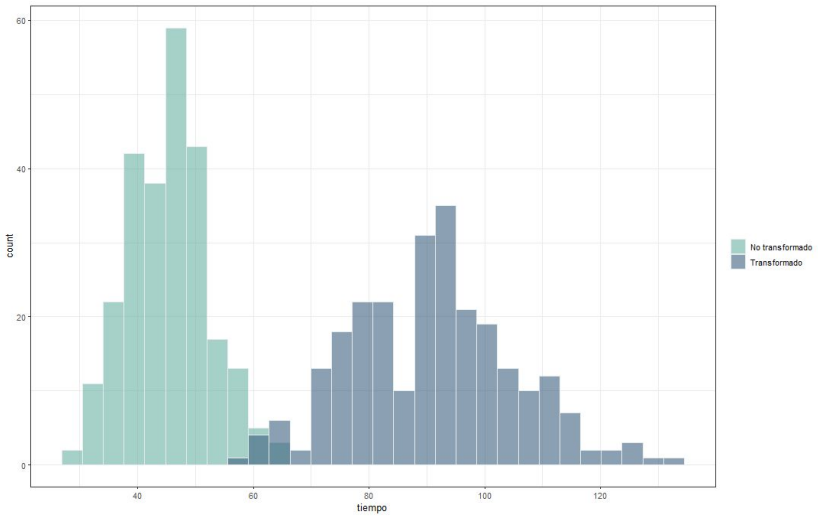

Si se multiplica una constante, se transforma la variable en posición y en dispersión

Transformaciones lineales

¿Qué sucede con el coeficiente de variación ante ambos escenarios?

$\bar{y} = 11.6$ $\quad$ $s_y = 2.7$

$\bar{x} = 11.6 + 5$ $\quad$ $s_x = 2.7$

$cv_y = \frac{2.7}{11.6} = 0.23$ $\quad$ $cv_x = \frac{2.7}{16.6}$

$\bar{y} = 11.6$ $\quad$ $s_y = 2.7$

$\bar{x} = 11.6 * 3$ $\quad$ $s_x = 2.7 * |3| = 8.1$

$cv_y = \frac{2.7}{11.6} = 0.23$ $\quad$ $cv_x = \frac{8.1}{34.8} = 0.23$

Variable Y	Variable X
$\hat{y}$	$\hat{x} = \alpha + \beta . \hat{y}$
s_y^2	$s_x^2 = \beta^2 . s_y^2$
s_y	$s_x = \lvert\beta\rvert . s_y$

Transformaciones lineales

20. El sueldo promedio actual de los empleados administrativos de una empresa es \$150000. En estos momentos se analizan dos propuestas de aumento de sueldo:
    - $Y = X + \$15000$ (aumentar en una suma fija)
    - $Y = a \cdot X$ (aumentar en un porcentaje)

    donde X representa el sueldo actual, Y representa el sueldo con aumento y a es una constante a determinar.

    a) Encuentre el valor de la constante a, tal que ambas propuestas arrojen igual sueldo promedio.

    b) ¿Resultarán semejantes las distribuciones de frecuencias de los sueldos con aumento para ambas propuestas? Justifique la respuesta.

    c) Compare el coeficiente de variación antes y después del aumento con ambas propuestas. Comente sus conclusiones.