Herramientas NLP Python

Aquí tienes el catálogo completo y resumido de todas las **herramientas, librerías y técnicas de la Unidad 3**, organizado bajo la misma metodología que venimos trabajando: **qué pregunta resuelve cada herramienta y en qué escenario práctico debe usarse**12.

🛠️ Catálogo Completo de Herramientas de la Unidad 3

---

1. Semejanza de Texto (*Text Similarity*)

Mide qué tan equivalentes o cercanos son dos textos23.

- 🔹 TfidfVectorizer + cosine_similarity (scikit-learn)
  - ❓ **¿Qué pregunta resuelve?** «*¿Qué tan parecidos son dos documentos evaluando la importancia matemática de las palabras que comparten?*»34
  - 💡 **¿Cuándo usarla?** En búsquedas por coincidencia vectorial, recomendadores de contenido básico o detección de duplicados en corpus limpios3more_horiz.
- 🔹 jaccard_similarity / jaccard_score (scikit-learn / Python)
  - ❓ **¿Qué pregunta resuelve?** «*¿Qué proporción de palabras distintas comparten dos conjuntos de texto respecto al total de palabras acumuladas entre ambos?*»6
  - 💡 **¿Cuándo usarla?** Para comparar presencia/ausencia de conjuntos de palabras o n-gramas donde el orden sintáctico no importa78.
- 🔹 dice_similarity (Coeficiente de Sørensen-Dice)
  - ❓ **¿Qué pregunta resuelve?** «*¿Qué tanto solapamiento hay entre dos conjuntos, dándole el doble de peso a las coincidencias para ser más sensible?*»910

- 💡 **¿Cuándo usarla?** En casos similares a Jaccard, pero cuando necesitas una métrica más benévola que premie con mayor fuerza las coincidencias exactas10.

- python-Levenshtein (Levenshtein.distance)
  - ❓ **¿Qué pregunta resuelve?** *«¿Cuántos retoques de caracteres (insertar, borrar, sustituir) hacen falta para transformar una palabra en otra?»*1112
  - 💡 **¿Cuándo usarla?** Para comparar la ortografía de palabras cortas individuales o medir errores de tipeo exactos a nivel de letras1213.
- thefuzz (process.extractBests)
  - ❓ **¿Qué pregunta resuelve?** *«¿Cómo realizo una búsqueda difusa (fuzzy search) en una columna de un DataFrame tolerando faltas de ortografía?»*1415
  - 💡 **¿Cuándo usarla?** Para buscar nombres, direcciones o productos en tablas de Pandas donde el usuario escribió con errores (ej. "Juan Peres" $\rightarrow$ "Juan Pérez")1416.
- jellyfish (jellyfish.jaro_winkler_similarity)
  - ❓ **¿Qué pregunta resuelve?** *«¿Qué tanto coinciden dos nombres propios o identificadores cortos, dándole prioridad a que coincidan al inicio (prefijo)?»*17more_horiz
  - 💡 **¿Cuándo usarla?** En limpieza o deduplicación de bases de datos de nombres de personas (ej. "Jon Smyth" vs "John Smith"), donde los errores suelen estar en las vocales finales o variantes fonéticas1819.

---

2. Estructura Gramatical y Entidades (POS, Noun Chunks y NER)

Estructuran el texto etiquetando funciones gramanticales y aislando conceptos o entidades20more_horiz.

- spaCy (es_core_news_lg)
  - ❓ **¿Qué pregunta resuelve?** *«¿Cómo etiqueto gramaticalmente cada palabra (POS), extraigo sintagmas nominales completos (noun_chunks) y detecto entidades estándar (PER, LOC, ORG, DATE)?»*20more_horiz

- 💡 **¿Cuándo usarla?** Es la herramienta industrial estándar para procesamiento rápido, robusto y eficiente en producción23.

- stanza (Stanford NLP)
  - ❓ **¿Qué pregunta resuelve?** *«¿Cómo construyo un árbol de dependencias sintácticas profundas (Universal Dependencies) con el máximo detalle morfosintáctico?»*2627
  - 💡 **¿Cuándo usarla?** En investigación lingüística avanzada o proyectos donde necesitas saber con precisión absoluta quién es el sujeto (nsubj), objeto (obj) o modificador (amod) de la oración2627.

- GLiNER (gliner_multi-v2.1)
  - ❓ **¿Qué pregunta resuelve?** *«¿Cómo reconozco entidades nombradas personalizadas en tiempo real sin tener un modelo previamente entrenado para esas clases (Zero-Shot NER)?»*2829
  - 💡 **¿Cuándo usarla?** Cuando necesitas extraer etiquetas que no existen en los modelos tradicionales (ej. "actor", "personaje ficticio", "síntoma", "libro") sin reentrenar la red2930.

---

3. Clasificación de Texto (*Text Classification*)

Asigna etiquetas categóricas a fragmentos de texto3132.

- TF-IDF + LogisticRegression / MultinomialNB (scikit-learn)
  - ❓ **¿Qué pregunta resuelve?** *«¿Cómo clasifico textos en categorías fijas mediante un modelo liviano, rápido y basado en palabras clave?»*3334
  - 💡 **¿Cuándo usarla?** Para clasificadores de alta velocidad, bajo cómputo y datasets pequeños o con vocabulario muy distintivo3536.

- Sentence Transformers + LogisticRegression
  - ❓ **¿Qué pregunta resuelve?** *«¿Cómo clasifico textos entendiendo la intención y el significado profundo en lugar de coincidir en palabras exactas?»*3537

- 💡 **¿Cuándo usarla?** Para clasificar intenciones de usuarios o tickets complejos donde las personas usan sinónimos, paráfrasis o redactan de formas variadas3536.

---

4. Análisis de Sentimientos (*Sentiment Analysis*)

Evalúa la polaridad, tono y emoción expresada en un texto3839.

- sentiment-analysis-spanish
  - ❓ **¿Qué pregunta resuelve?** *«¿Cómo obtengo de forma ultrarrápida una puntuación continua de polaridad (de 0 a 1) sobre un texto en español?»*4041
  - 💡 **¿Cuándo usarla?** Para análisis masivo e instantáneo de comentarios o reseñas cuando solo importa saber si el texto es positivo o negativo sin montar infraestructura pesada41.
- transformers.pipeline (nlptown/bert-base-multilingual-uncased-sentiment)
  - ❓ **¿Qué pregunta resuelve?** *«¿Cómo clasifico opiniones en una escala de 1 a 5 estrellas considerando el contexto multilingüe?»*4243
  - 💡 **¿Cuándo usarla?** En análisis de reseñas de productos o servicios que requieren medir la intensidad de la satisfacción en una escala discreta4344.
- Análisis de Sentimientos por Instrucción (LLMs)
  - ❓ **¿Qué pregunta resuelve?** *«¿Cómo descompongo un texto con opiniones compuestas o mixtas en un esquema estructurado (JSON) analizando aspecto por aspecto?»*4546
  - 💡 **¿Cuándo usarla?** Para comentarios complejos (ej. *"La comida estuvo riquísima pero la atención fue pésima"*) donde se debe evaluar la polaridad e intensidad de cada atributo por separado46.

---

5. Detección de Idioma (*Language Detection*)

Identifica el idioma en el que está escrito un texto47.

- langdetect (detect, detect_langs)

- ❓ **¿Qué pregunta resuelve?** *«¿Cómo detecto el código ISO del idioma de un texto usando perfiles de n-gramas y Naive Bayes?»*48more_horiz
- 💡 **¿Cuándo usarla?** Para filtrados rápidos de idioma en textos de longitud media o larga51.

🔹 fasttext-langdetect (ftlangdetect)

- ❓ **¿Qué pregunta resuelve?** *«¿Cómo identifico el idioma con máxima velocidad, alta precisión y tolerancia a palabras desconocidas o morfologías complejas?»*5253
- 💡 **¿Cuándo usarla?** En entornos de producción masivos, en tiempo real, o al procesar textos cortos e idiomas con variaciones morfológicas (hasta 176 idiomas)53more_horiz.

---

6. Traducción Automática (*Language Translation*)

Convierte texto de un idioma de origen a uno de destino56.

🔹 MarianMT / OPUS-MT (Helsinki-NLP en transformers)

- ❓ **¿Qué pregunta resuelve?** *«¿Cómo traduzco texto de forma directa y determinista entre un par de idiomas específico usando un modelo neuronal dedicado (NMT)?»*57more_horiz
- 💡 **¿Cuándo usarla?** En sistemas cerrados o locales de alto tráfico que requieren traducciones automáticas estables sin depender de pagos por API externa5860.

🔹 Traducción por Instrucción (LLMs)

- ❓ **¿Qué pregunta resuelve?** *«¿Cómo traduzco un texto aplicando restricciones personalizadas (registro formal, no traducir nombres propios o mantener formato)?»*6061
- 💡 **¿Cuándo usarla?** Para traducciones donde el tono, el contexto cultural o las reglas de formato son críticas6061.

🔹 Librerías Multi-Servicio (deep-translator / translators)

- ❓ **¿Qué pregunta resuelve?** *«¿Cómo me conecto fácilmente a múltiples servicios públicos de traducción (Google, PONS, Linguee, MyMemory) desde Python?»*6263
- 💡 **¿Cuándo usarla?** En scripts de automatización, prototipado rápido o cuando buscas traducir palabras sueltas obteniendo sinónimos (ej. PONS o Linguee)6465.

---

7. Resumen Automático (*Text Summarization*)

Produce una versión comprimida que conserva la información esencial de un documento66.

🔹 Resumen Extractivo (TextRank / Matriz TF-IDF + Coseno)

- ❓ **¿Qué pregunta resuelve?** *«¿Cómo selecciono y extraigo las oraciones originales más importantes de un texto sin modificar una sola palabra?»*66more_horiz
- 💡 **¿Cuándo usarlo?** En documentos legales, médicos o técnicos donde está prohibido alterar el texto original o correr riesgos de inventar información (alucinación)6668.

🔹 Resumen Abstractivo (Modelos dedicados BART/PEGASUS o LLMs por Prompt)

- ❓ **¿Qué pregunta resuelve?** *«¿Cómo redacto una síntesis nueva, fluida y parafraseada a partir de un texto largo?»*6970
- 💡 **¿Cuándo usarlo?** En boletines, artículos periodísticos o resúmenes ejecutivos donde prima la fluidez de lectura y la capacidad de síntesis creativa70.

💡 ¿Te sirve esta guía para repasar exactamente qué herramienta elegir ante cada caso de uso?