

7. BÚSQUEDAS INSPIRADAS EN LA NATURALEZA

(PARTE 2)

IA 3.2 - Programación III

1º C - 2026

Dr. Mauro Lucci

Optimización por Colonia de Hormigas

Ant Colony Optimization
(ACO)



La **optimización por colonia de hormigas** se inspira en el rastro de **feromonas** que usan las hormigas como medio de comunicación.




1. En cada iteración, una **población** de hormigas artificiales construye soluciones al problema guiadas por un rastro de feromonas.
2. Antes de pasar a la siguiente iteración, se ajusta la cantidad de feromonas por **depósito** y **evaporación**, para reflejar la experiencia acumulada durante la última iteración.

— — —



Analogía biológica

— — —



Algoritmo de ACO

— — —

```
1 function ACO(...) return solución
2   while no se cumple el criterio de parada do
3       cada hormiga construye una solución
4       actualizar el rastro de feromonas
5   return mejor solución encontrada
```

1. Construcción de soluciones

Una **población** de m hormigas construye soluciones de forma **incremental** y **estocástica**.

- Cada hormiga inicia con una solución **parcial** (puede ser vacía).
- En cada paso de construcción, la hormiga elige **probabilísticamente** un **componente de construcción** y aumenta su solución parcial.
- La probabilidad depende del nivel de feromonas y de la función de evaluación.



Ejemplo – TSP

— — —

Cada hormiga empieza en una ciudad aleatoria y, en cada paso de construcción, viaja probabilísticamente a una ciudad no visitada.

Las componentes de construcción son las aristas. Estando en i , la probabilidad de elegir la arista (i,j) es **proporcional** a:

$$\frac{\tau(i,j)}{dist(i,j)}$$

*La probabilidad es mayor
cuando hay más feromonas
o menos distancia.*

donde $\tau(i,j)$ y $dist(i,j)$ representan la cantidad de feromona y la distancia de la arista (i,j) , respectivamente.

2. Depósito y evaporación

Las feromonas transmiten la experiencia ganada a las futuras iteraciones, se **actualiza** por:

- **Depósito**. Incrementa el nivel de feromonas para reforzar componentes de construcción de buenas soluciones.
- **Evaporación**. Reduce periódicamente los niveles de feromona para evitar la convergencia prematura y favorecer la exploración de nuevas soluciones.



Ejemplo – TSP

La cantidad de feromonas $\tau(i,j)$ de cada arista (i,j) se actualiza:

$$\tau(i,j) \leftarrow (1 - \rho) \cdot \tau(i,j) + \sum_{1 \leq k \leq m: (i,j) \in \text{tour}_k} \frac{1}{\text{dist}(\text{tour}_k)}$$

Aristas usadas por muchas hormigas o contenidas en tours cortos reciben más feromonas.


donde $\rho \in (0,1)$ y $\text{dist}(\text{tour}_k)$ es el largo del tour encontrado por la k -ésima hormiga.

Es decir, se evapora el $\rho\%$ de la feromona acumulada y, por cada aparición de la arista en el tour de una hormiga, se deposita una cantidad de feromona inversamente proporcional al costo del tour.



Ejemplo – TSP

Vamos a simular algunas iteraciones de ACO. Usaremos el siguiente mapa con 5 ciudades.




El número de cada arista representa la distancia entre las ciudades.



Ejemplo – TSP

Empezamos inicializando la cantidad de feromonas en cada arista con un valor constante dado de entrada. Por ejemplo, $\tau(i,j) = 1$ para toda arista (i,j) .




Notaremos a la cantidad de feromona de cada arco con color rojo.

La cantidad de feromona inicial es un parámetro de ACO, el cual debe ser ajustado por experimentación.



Ejemplo – TSP

— — —




La primera hormiga inicia en una ciudad elegida al azar, por ejemplo, c_3 .

¿A dónde se mueva ahora? 🤔

La probabilidad de la arista (i,j) es proporcional a: $\frac{\tau(i,j)}{dist(i,j)}$



Ejemplo – TSP



Cociente entre la cantidad de feromona y la distancia de las aristas que salen de c_3 :

$$\left. \begin{array}{l} (c_3, c_0) \rightarrow 1/15 = 0,067 \\ (c_3, c_1) \rightarrow 1/10 = 0,1 \\ (c_3, c_2) \rightarrow 1/8 = 0,125 \\ (c_3, c_4) \rightarrow 1/7 = 0,143 \end{array} \right\} \text{Suma: } 0,435$$

**¡No siempre elige
la de mayor
probabilidad!**

La decisión es
aleatoria, con una
distribución
no-uniforme.


Probabilidades proporcionales (similar a GA):

$$\begin{array}{l} (c_3, c_0) \rightarrow 0,067 / 0,435 = 15\% \\ (c_3, c_1) \rightarrow 0,1 / 0,435 = 23\% \\ (c_3, c_2) \rightarrow 0,125 / 0,435 = 29\% \\ (c_3, c_4) \rightarrow 0,143 / 0,435 = 33\% \end{array} \quad \leftarrow \text{Elige por ej. } c_2$$



Ejemplo – TSP

— — —



Cociente entre la cantidad de feromona y la distancia:

$$\left. \begin{array}{l} (c_2, c_0) \rightarrow 1/9 = 0,111 \\ (c_2, c_1) \rightarrow 1/7 = 0,143 \\ (c_2, c_4) \rightarrow 1/10 = 0,1 \end{array} \right\} \text{Suma: } 0,354$$


Probabilidades proporcionales:

$$\begin{array}{l} (c_2, c_0) \rightarrow 0,111 / 0,354 = 31\% \\ (c_2, c_1) \rightarrow 0,143 / 0,354 = 40\% \leftarrow \text{Elige por ej. } c_1 \\ (c_2, c_4) \rightarrow 0,1 / 0,354 = 28\% \end{array}$$



Ejemplo – TSP

— — —




Ejercicio. Calcular las probabilidades de que la hormiga se mueva a la ciudad c_0 y c_4 .



Ejemplo – TSP

— — —



Ejercicio. Calcular las probabilidades de que la hormiga se mueva a la ciudad c_0 y c_4 .



Solución. Cociente entre la cantidad de feromona y la distancia:

$$(c_1, c_0) \rightarrow 1/8 = 0,125$$

$$(c_1, c_4) \rightarrow 1/14 = 0,071$$

Probabilidades proporcionales:


$$(c_1, c_0) \rightarrow 0,125 / 0,196 = 64\% \leftarrow \text{Elige por ej. } c_0$$

$$(c_1, c_4) \rightarrow 0,071 / 0,196 = 36\%$$



Ejemplo – TSP

— — —



Finalmente se mueve a la última ciudad no visitada c_4 y regresa a su ciudad inicial c_3 .

Este tour tiene distancia total:


$$8 + 7 + 8 + 20 + 7 = 50$$



Ejemplo – TSP

Tour hormiga 1

Costo: 50




Repetimos esta construcción para todas las hormigas.

Como la ciudad inicial y los movimientos son aleatorios, los tours construidos inicialmente por las hormigas tienden a ser muy diferentes entre sí.

Tour hormiga 2

Costo: 62




Supongamos que nuestra población tiene dos hormigas.



Ejemplo – TSP


Tour hormiga 1

Costo: 50



Tour hormiga 2

Costo: 62



Antes de pasar a la siguiente iteración, tenemos que actualizar la cantidad de feromonas según la fórmula:

$$\tau(i, j) \leftarrow (1 - \rho) \cdot \tau(i, j) + \sum_{1 \leq k \leq m: (i, j) \in \text{tour}_k} \frac{1}{\text{dist}(\text{tour}_k)}$$

Supongamos un valor de evaporación $\rho = 0,95$ (este parámetro requiere ser ajustado con experimentación).

Elegimos un valor de ρ alto adrede, para acelerar el efecto de la evaporación.




Ejemplo – TSP

$$\tau(i, j) \leftarrow (1 - \rho) \cdot \tau(i, j) + \sum_{1 \leq k \leq m: (i, j) \in \text{tour}_k} \frac{1}{\text{dist}(\text{tour}_k)}$$

Tour hormiga 1

Costo: 50




Empecemos actualizando la arista (0,1).

Notar que esta arista fue elegida por la **primera** hormiga, luego:

Tour hormiga 2

Costo: 62



$$\tau(0,1) \leftarrow 0,05 * 1 + 1/50 = 0,07$$




Ejemplo – TSP

$$\tau(i, j) \leftarrow (1 - \rho) \cdot \tau(i, j) + \sum_{1 \leq k \leq m: (i, j) \in \text{tour}_k} \frac{1}{\text{dist}(\text{tour}_k)}$$


Tour hormiga 1

Costo: 50



Tour hormiga 2

Costo: 62



Sigamos actualizando la arista (0,2).

Notar que esta arista no fue elegida por **ninguna** hormiga, luego:

$$\tau(0, 2) \leftarrow 0,05 * 1 = 0,05$$




Ejemplo – TSP

$$\tau(i, j) \leftarrow (1 - \rho) \cdot \tau(i, j) + \sum_{1 \leq k \leq m: (i, j) \in \text{tour}_k} \frac{1}{\text{dist}(\text{tour}_k)}$$


Tour hormiga 1

Costo: 50



Tour hormiga 2

Costo: 62



Sigamos actualizando la arista (0,3).

Notar que esta arista fue elegida por la **segunda** hormiga, luego:

$$\tau(0,3) \leftarrow 0,05 * 1 + 1/62 = 0,066$$




Ejemplo – TSP

$$\tau(i, j) \leftarrow (1 - \rho) \cdot \tau(i, j) + \sum_{1 \leq k \leq m: (i, j) \in \text{tour}_k} \frac{1}{\text{dist}(\text{tour}_k)}$$


Tour hormiga 1

Costo: 50



Tour hormiga 2

Costo: 62



Sigamos actualizando la arista (0,4).

Notar que esta arista fue elegida por **ambas** hormigas, luego:


$$\tau(0,4) \leftarrow 0,05 * 1 + 1/50 + 1/62 = 0,086$$

Y así sucesivamente...



Ejemplo – TSP

Entonces, en la siguiente iteración tenemos:







Ejemplo – TSP

— — —

Iteración 1



Iteración 2




Comparemos cómo cambian los porcentajes para una hormiga que inicia en c_4 en la primera y segunda iteración de ACO.




Ejemplo – TSP

Iteración 1



$$\begin{aligned}(C_4, C_0) &\rightarrow 0,05 / 0,364 = 14\% \\(C_4, C_1) &\rightarrow 0,071 / 0,364 = 19\% \\(C_4, C_2) &\rightarrow 0,1 / 0,364 = 27\% \\(C_4, C_3) &\rightarrow 0,143 / 0,364 = 39\%\end{aligned}$$

Iteración 2



$$\begin{aligned}(C_4, C_0) &\rightarrow 0,0043 / 0,0245 = 18\% \\(C_4, C_1) &\rightarrow 0,0036 / 0,0245 = 15\% \\(C_4, C_2) &\rightarrow 0,0066 / 0,0245 = 27\% \\(C_4, C_3) &\rightarrow 0,01 / 0,0245 = 41\%\end{aligned}$$

Elegido por
ambas hormigas.

No elegido por
ninguna hormiga.

Elegido por la
segunda hormiga, con
tour de costo 62.

Elegido por la
primera hormiga, con
tour de costo 50.



Ejercicio

— — —

Proponer un algoritmo de **ACO** para las **8-reinas**.

Elegir cuáles son los componentes de construcción y diseñar cómo las hormigas construyen las soluciones y cómo se actualiza el nivel de feromona.

Optimización por Enjambre de Partículas

Particle Swarm
Optimization (PSO)



La **optimización por enjambre de partículas** se inspira en el comportamiento de una bandada de aves, un cardumen de peces o un enjambre de insectos.


Un **enjambre** es una **población** de individuos (partículas) en movimiento que conjuntamente parecen moverse ordenadamente, pero donde cada individuo por separado sigue su propia trayectoria.

— — —



Optimización por Enjambre de Partículas

Modela un enjambre de partículas que exploran el espacio de búsqueda recordando su experiencia individual y aprovechando la experiencia colectiva.



[Link](#)

Componentes

- Cada **partícula** i tiene **posición** inicial $x_i = (x_{i1}, \dots, x_{in})$ en $\mathbb{R}^n$ que representa una solución y una **velocidad** inicial $v_i = (v_{i1}, \dots, v_{in})$.
- Maximizar/minimizar **función de fitness** $f : \mathbb{R}^n \rightarrow \mathbb{R}$.
- **Memoria individual**. Cada partícula i guarda su mejor posición **personal** $pbest_i$.
- **Memoria colectiva**. El enjambre guarda la mejor posición **global** $gbest$.

Ecuación de velocidad y posición


— — —

Cada partícula se mueve:

- siguiendo su propia trayectoria.
- acercándose a su mejor posición personal.
- acercándose a la mejor posición global.

Ecuación de velocidad y posición

— — —




$$\begin{aligned} v_i(t+1) = & w.v_i(t) \\ & + c_1.rand().(gbest - x_i(t)) \\ & + c_2.rand().(pbest_i - x_i(t)) \end{aligned}$$

$$x_i(t+1) = x_i(t) + v_i(t+1)$$

Ecuación de velocidad y posición

— — —



En cada iteración, la **velocidad** de la partícula i se acelera sumando:

- **Vector celeste**. Su velocidad multiplicada por un factor de inercia.
- **Vector rojo en línea de puntos**. Vector que apunta a gbest multiplicado por un número aleatorio y una constante c_1 .
- **Vector azul en línea de puntos**. Vector que apunta a pbest multiplicado por un número aleatorio y una constante c_2 .


La **posición** de la partícula i se actualiza sumando su última posición con el **vector verde en línea de puntos** (nueva velocidad).



Ejemplo

Vamos a simular algunas iteraciones de PSO para minimizar $x^2 + y^2$.

Superficie de $f(x, y) = x^2 + y^2$





Ejemplo – Datos de entrada

— — —

Partícula i	Posición x_i	Velocidad v_i
A	(4,3)	(1,0)
B	(-2,4)	(0,1)

Parámetros:

- $w = 1$
- $c_1 = 1$
- $c_2 = 1$

Suponer que el resultado de `rand(0,1)` siempre es 0.5




Ejemplo – Inicialización

— — —

Partícula i	Posición x_i	Velocidad v_i	Valor de fitness $f(x_i)$
A	(4,3)	(1,0)	$4^2+3^2 = 25$
B	(-2,4)	(0,1)	$(-2)^2+4^2 = 20$

Mejores posiciones:

- $pbest_A = (4,3)$
- $pbest_B = (-2,4)$
- $gbest = (-2,4)$





Ejemplo – Iteración 1

— — —

Partícula i	Posición x_i	Velocidad v_i	Valor de fitness $f(x_i)$
A	(4,3)	(1,0)	$4^2+3^2 = 25$
B	(-2,4)	(0,1)	$(-2)^2+4^2 = 20$

Mejores posiciones:

- $pbest_A = (4,3)$
- $pbest_B = (-2,4)$
- $gbest = (-2,4)$

Nuevas velocidades:

$$\begin{aligned} \bullet \quad v_A &\leftarrow w \cdot v_A + \text{rand}(0,1) \cdot c_1 \cdot \underbrace{(pbest_A - x_A)}_{(4,3) - (4,3) = (0,0)} + \text{rand}(0,1) \cdot c_2 \cdot \underbrace{(gbest - x_A)}_{(-2,4) - (4,3) = (-6,1)} \\ &= (1,0) + (0,0) + (-3,0.5) = (-2,0.5) \end{aligned}$$



Ejemplo – Iteración 1

— — —

Partícula i	Posición x_i	Velocidad v_i	Valor de fitness $f(x_i)$
A	(4,3)	(1,0)	$4^2+3^2 = 25$
B	(-2,4)	(0,1)	$(-2)^2+4^2 = 20$

Mejores posiciones:

- $pbest_A = (4,3)$
- $pbest_B = (-2,4)$
- $gbest = (-2,4)$

Nuevas velocidades:

$$\begin{aligned} \bullet \quad v_B &\leftarrow w \cdot v_B + \underbrace{\text{rand}(0,1) \cdot c_1 \cdot (pbest_B - x_B)}_{(-2,4) - (-2,4) = (0,0)} + \underbrace{\text{rand}(0,1) \cdot c_2 \cdot (gbest - x_B)}_{(-2,4) - (-2,4) = (0,0)} \\ &= (0,1) + (0,0) + (0,0) = (0,1) \end{aligned}$$



Ejemplo – Iteración 1

— — —

Partícula i	Posición x_i	Velocidad v_i	Valor de fitness $f(x_i)$
A	(4,3)	(1,0)	$4^2+3^2 = 25$
B	(-2,4)	(0,1)	$(-2)^2+4^2 = 20$


Nuevas posiciones:

- $v_A \leftarrow (-2, 0.5)$, $v_B \leftarrow (0, 1)$
- $x_A \leftarrow x_A + v_A = (4, 3) + (-2, 0.5) = (2, 3.5)$
- $x_B \leftarrow x_B + v_B = (-2, 4) + (0, 1) = (-2, 5)$



Ejemplo – Iteración 1

PSO sobre $f(x, y) = x^2 + y^2$






Ejemplo – Iteración 1

Partícula i	Posición $\mathbf{x}_i$	Velocidad $\mathbf{v}_i$	Valor de fitness $f(\mathbf{x}_i)$
A	(2,3.5)	(-2,0.5)	$2^2 + 3.5^2 = 16.25$
B	(-2,5)	(0,1)	$(-2)^2 + 5^2 = 29$

Mejores posiciones:

- $\text{pbest}_A = (2, 3.5)$
- $\text{pbest}_B = (-2, 4)$
- $\text{gbest} = (2, 3.5)$





Ejemplo – Iteración 2

— — —

Partícula i	Posición x_i	Velocidad v_i	Valor de fitness $f(x_i)$
A	(2,3.5)	(-2,0.5)	$2^2+3.5^2 = 16.25$
B	(-2,5)	(0,1)	$(-2)^2+5^2 = 29$

Mejores posiciones:

- $pbest_A = (2, 3.5)$
- $pbest_B = (-2, 4)$
- $gbest = (2, 3.5)$



Ejercicio. Hacer otra iteración de PSO.



Solución – Iteración 2

— — —

Partícula i	Posición x_i	Velocidad v_i	Valor de fitness $f(x_i)$
A	(2,3.5)	(-2,0.5)	$2^2+3.5^2 = 16.25$
B	(-2,5)	(0,1)	$(-2)^2+5^2 = 29$

Mejores posiciones:

- $pbest_A = (2,3.5)$
- $pbest_B = (-2,4)$
- $gbest = (2,3.5)$

Nuevas velocidades:

$$\begin{aligned} \bullet \quad v_A &\leftarrow w \cdot v_A + \underbrace{\text{rand}(0,1) \cdot c_1 \cdot (pbest_A - x_A)}_{(2,3.5) - (2,3.5) = (0,0)} + \underbrace{\text{rand}(0,1) \cdot c_2 \cdot (gbest - x_A)}_{(2,3.5) - (2,3.5) = (0,0)} \\ &= (-2,0.5) + (0,0) + (0,0) = (-2,0.5) \end{aligned}$$



Solución – Iteración 2

— — —

Partícula i	Posición x_i	Velocidad v_i	Valor de fitness $f(x_i)$
A	(2,3.5)	(-2,0.5)	$2^2+3.5^2 = 16.25$
B	(-2,5)	(0,1)	$(-2)^2+5^2 = 29$

Mejores posiciones:

- $pbest_A = (2,3.5)$
- $pbest_B = (-2,4)$
- $gbest = (2,3.5)$

Nuevas velocidades:

$$\begin{aligned} \bullet \quad v_B &\leftarrow w \cdot v_B + \underbrace{\text{rand}(0,1) \cdot c_1 \cdot (pbest_B - x_B)}_{(-2,4) - (-2,5) = (0,-1)} + \underbrace{\text{rand}(0,1) \cdot c_2 \cdot (gbest - x_B)}_{(2,3.5) - (-2,5) = (4,-1.5)} \\ &= (0,1) + (0,-0.5) + (2,-0.75) = (2,-0.25) \end{aligned}$$



Solución – Iteración 2

— — —

Partícula i	Posición x_i	Velocidad v_i	Valor de fitness $f(x_i)$
A	(2,3.5)	(-2,0.5)	$2^2+3.5^2 = 16.25$
B	(-2,5)	(0,1)	$(-2)^2+5^2 = 29$

Mejores posiciones:

- $pbest_A = (2, 3.5)$
- $pbest_B = (-2, 4)$
- $gbest = (2, 3.5)$


Nuevas posiciones:

- $v_A \leftarrow (-2, 0.5), v_B \leftarrow (2, -0.25)$
- $x_A \leftarrow x_A + v_A = (2, 3.5) + (-2, 0.5) = (0, 4)$
- $x_B \leftarrow x_B + v_B = (-2, 5) + (2, -0.25) = (0, 4.75)$



Solución – Iteración 2

PSO sobre $f(x, y) = x^2 + y^2$





Solución – Iteración 2

— — —

Partícula i	Posición x_i	Velocidad v_i	Valor de fitness $f(x_i)$
A	(0,4)	(-2,0.5)	$0^2+4^2 = 16$
B	(0,4.75)	(2,-0.25)	$0^2+4.75^2 = 22,56$

Mejores posiciones:

- $pbest_A = (0,4)$
- $pbest_B = (-2,4)$
- $gbest = (0,4)$

Algoritmo de PSO



— — —

```
1 function PSO(n, fitness) return partícula
2   iniciar posiciones y velocidades aleatorias para las n partículas
3   iniciar pbesti como la posición inicial de cada partícula i
4   inicial gbest como el pbesti que minimice fitness
5   while no se cumple el criterio de parada do
6       actualizar la velocidad de cada partícula
7       actualizar la posición de cada partícula
8       actualizar pbesti y gbest, si corresponde
9   return gbest
```






Ejemplos

$$f(x, y) = x^2 + (y + 1)^2 - 5\cos\left(\frac{3}{2}x + \frac{3}{2}\right) - 3\cos\left(2y - \frac{3}{2}\right)$$





Ejemplo





Resumen

— — —

- ❑ Existe una amplia gama de algoritmos de búsqueda inspirados en la **naturaleza**.
- ❑ Gran impacto en la resolución de grandes problemas de optimización.
- ❑ Muchos de ellos incorporan mecánicas **estocásticas**. Por ejemplo, el **recocido simulado** es una búsqueda local que permite moverse aleatoriamente a soluciones peores, pero esto es cada vez menos **probable** a medida que avanzan las iteraciones.
- ❑ Los **algoritmos genéticos**, la **optimización por colonia de hormigas** y la **optimización por enjambre de partículas** son búsquedas locales basadas en **poblaciones**.
- ❑ La optimización por enjambre de partículas se utiliza para optimizar funciones reales **no lineales**.